

Práctica 3.
Sorpresa: el problema de la comunicación con la realidad.

Profesor: Gustavo Landfried

Inferencia Bayesiana Causal 1
2do cuatrimestre 2025
UNSAM

Índice

1. Algoritmo suma-producto: inferencia por pasaje de mensajes.	5
2. La clase Gaussiana	7
2.1. Propiedades de la distribución Gaussiana	7
2.2. Implementar la clase Gaussiana	8
3. Estimación de habilidad por pasaje de mensajes	9
3.1. Mensajes descendentes: evidencia $P(D M)$	10
3.2. Mensajes ascendentes: verosimilitud $P(D H, M)$	11
4. Anexo 1. Gaussianas en una dimensión	14
4.1. Producto de gaussianas	14
4.2. Suma de gaussianas	15
4.3. Gaussiana por acumulada de Gaussiana.	16
4.4. Division de gaussianas	17

Sistemas de comunicación con la realidad

La realidad produce señales constantemente, pero como seres humanos percibimos apenas un pequeño subconjunto de ellas a través de instrumentos de medición imperfectos, como nuestros cuerpos o tecnologías, a través de epifenómenos observables del fenómeno oculto de interés. En este contexto, el problema fundamental de la teoría de la información es diseñar sistemas de comunicación con la realidad que permitan reconstruir los mensajes distorsionados e indirectos que percibimos, reproduciendo lo más fielmente posible el mensaje enviado por la realidad. En palabras de Claude Shannon [1].

The fundamental problem of communication is that of reproducing at one point either exactly or approximately a message selected at another point. (...). The significant aspect is that the actual message is one selected from a set of possible messages.

The system must be *designed* to operate for each possible selection, not just the one which will actually be chosen since this is unknown at the time of design.

Es importante destacar dos puntos de esta cita. El primero es que Shannon recuerda, en pleno siglo 20, la importancia de que el sistema de comunicación no se limite a seleccionar un único mensaje o hipótesis, como se solía hacer en su época, sino que considere todos los posibles mensajes alternativos como emerge de la aplicación estricta de las reglas de la probabilidad.

$$\underbrace{P(\text{Hipótesis, Datos})}_{\text{Creencia inicial compatible con los datos}} = \underbrace{P(\text{Hipótesis})}_{\text{Creencia inicial}} \underbrace{P(\text{Datos}|\text{Hipótesis})}_{\text{Sorpresas, fuente de información.}}$$

Las creencias sobre las hipótesis alternativas se actualizan preservando la creencia previa que sigue siendo compatible con los nuevos datos. Allí surge naturalmente que la sorpresa es el único filtro de la creencia previa y por lo tanto única fuente de información.

El segundo punto a destacar es que Shannon subraya que los sistemas de comunicación no vienen dados sino que se diseñan (*designed*). Sistemas alternativos comunican mensajes alternativos de la realidad. Si el mensaje que recibimos de la realidad no está dado sino que se construye: ¿cuál es entonces el mensaje enviado por la realidad? Debido a que los sistemas de comunicación alternativos son también hipótesis, su evaluación depende de la sorpresa contenida en la predicción que hace de los datos, $P(\text{Datos}|\text{Sistema})$.

En la primera unidad ya evaluamos dos sistemas de comunicación alternativos, que se diferenciaban únicamente por su modelo causal (Monty Hall vs Base), y calculamos sus predicciones $P(\text{Datos}|\text{Modelo Causal})$ para actualizar la creencia sobre los modelos. En el ejemplo del modelo Monty Hall, todas sus hipótesis internas (c, s, r) son observadas al final de cada episodio. En la teórica hemos demostrado la siguiente igualdad.

$$\begin{aligned} & -\log_2 \lim_{T \rightarrow \infty} P(\text{Datos}_T | \text{Modelo Causal})^{1/T} \\ &= \sum_{c,s,r} P(c, s, r | \text{Realidad Causal} = R) \cdot (-\log_2 P(c, s, r | \text{Modelo Causal} = M)) = \mathcal{H}(R, M) \end{aligned}$$

Esto es lo que descubre Shannon: la tasa de predicción a largo plazo ($\lim_{T \rightarrow \infty}$) expresada en órdenes de magnitud ($\log_2$) del sistema de comunicación es el negativo de la tasa de información en órdenes de magnitud que recibe el sistema, lo que se llama entropía cruzada $\mathcal{H}(R, M)$.

Shannon muestra además que la mínima tasa de información a la que puede aspirar un sistema de comunicación ocurre cuando la predicción que hace el sistema coincide con la probabilidad de generación de los datos por la realidad causal, $P(c, s, r | \text{Realidad Causal}) = P(c, s, r | \text{Modelo Causal})$. En este caso, la entropía cruzada se transforma en entropía.

$$\mathcal{H}(R) = \sum_{c,s,r} P(c, s, r | R) \cdot (-\log P(c, s, r | R))$$

Todo el resto de los sistemas de comunicación reciben información adicional, conocida como divergencia Kullback-Leibler.

$$\sum_{c,s,r} P(c, s, r|R) \cdot \underbrace{(\log P(c, s, r|R) - \log P(c, s, r|M))}_{\text{La diferencia de predicción en órdenes de magnitud}}$$

Estructura invariante del “dato”

Los datos se expresan como proposiciones funcionales pues siempre que midamos una cierta variable f (como la *habilidad*) sobre una unidad de análisis x (como Messi) deberíamos obtener el mismo valor h , al menos en un momento determinado.

$$\text{Habilidad}(\text{Messi}) = h$$

Sin embargo la habilidad es una **variable oculta** que debe inferirse a partir de sus consecuencias observables, como son el éxito o fracaso de las competencias en las que participó.

$$P(\text{Habilidad}(\text{Messi}) = h | \text{Datos})$$

La variable oculta de interés es la fuente desde donde la realidad causal emite señales que se codifican a través de sus **epifenómenos observables**, como Ganar/Perder. Debido a que existen otros epifenómenos potencialmente observables, su elección es una decisión de diseño del sistema de comunicación que se toma buscando que ellos transmitan información relevante de la variable oculta de interés.

Los epifenómenos no se observan efectivamente hasta que se aplica un determinado **procedimiento de medición**. Al existir muchos procedimientos alternativos. La elección de un procedimiento de medición particular es otra decisión de diseño del sistema de comunicación que involucra consideraciones relativas a la factibilidad de su aplicación y a su capacidad para detectar fielmente la señal producida por el epifenómeno (y no otros factores asociados). Para estudiar la habilidad de Messi, por ejemplo, sería razonable desarrollar una software que descargue todos los resultados de la página oficial fifa.com. Las señales efectivamente registradas (True/False) constituyen la base empírica sobre la que se evaluarán las hipótesis de habilidad alternativas.

La señal registrada del epifenómeno no sirve si no es interpretada (o decodificada) a través de un **modelo causal** que permita vincularla con la variable oculta, la habilidad de Messi. Por




Figura 1: Modelo causal que vincula la habilidad oculta con el resultado observado.

ejemplo, considerar sólo la frecuencia de éxitos como indicador de la habilidad de los individuos puede conducir a aproximaciones erróneas, fundamentalmente porque el valor de un éxito o un fracaso depende de la dificultad de los desafíos. Por esta razón, todos los modelos de habilidad ampliamente utilizados consideran que el resultado de la competencia o resolución de problema se produce en relación a otra entidad oculta, que puede ser la habilidad de la persona contra la que compiten o la dificultad intrínseca del problema. En la figura 1 especificamos el modelo

causal generativo en el que las habilidades ocultas causan los resultados observables a través de la diferencia de los desempeños ocultos, $d = p_i - p_j$, ambas variables aleatorias centradas en la verdadera habilidad, $p \sim \mathcal{N}(s, \beta^2)$. Quien haya obtenido mayor rendimiento gana, $r = (d > 0)$.

Dado el modelo causal y la señal registrada cada hipótesis de habilidad (o posible mensajes del sistema de comunicación), tiene asociada una sorpresa, lo que permite actualizar su distribución de creencias (o **posterior**). La distribución de creencias a priori sobre la habilidad de un individuo i , s_i , se suele representar mediante una distribución gaussiana, $p(s_i) = \mathcal{N}(s_i | \mu_i, \sigma_i^2)$. Por las




Figura 2: Predicción de los resultados

propiedades de la gaussiana (descritas en detalle en el anexo de la práctica anterior) ustedes pueden derivar el siguiente resultado: la distribución marginal de la variable que representa la diferencia de desempeños $p(d)$ (con distribución de probabilidad condicional determinística $p(d | p_i, p_j) = \mathbb{I}(d = p_i - p_j)$) es una gaussiana que está centrada en la diferencia de las medias de las distribuciones de habilidad a priori $(\mu_i - \mu_j)$, y que tiene como varianza la incertidumbre de ambas estimaciones (σ) y la varianza de ambos rendimientos (β), $\mathcal{N}(d | \mu_i - \mu_j, 2\beta^2 + \sigma_i^2 + \sigma_j^2)$. Por lo tanto, la predicción a priori o evidencia de un resultado ganador es la densidad acumulada (Φ) de todos los valores positivos de la gaussiana de diferencia de desempeños:

$$\underbrace{P(r)}_{\text{Evidencia}} = 1 - \Phi\left(0 \mid \underbrace{\mu_i - \mu_j}_{\text{Diferencia esperada}}, \underbrace{2\beta^2 + \sigma_i^2 + \sigma_j^2}_{\text{Incertidumbre total}}\right). \quad (1)$$

La evidencia es la verosimilitud marginal $p(r)$, la predicción a priori del resultado observado realizada con la contribución de todas las hipótesis elementales de habilidad.

Para calcular el posterior sobre la habilidad $p(s_i | r)$ necesitamos la verosimilitud, $p(r | s_i)$. En el anexo de la práctica anterior se ofrecen todas las propiedades de la distribución gaussiana que se requieren para llegar a la siguiente expresión analítica exacta.

$$\underbrace{p(s_i | r)}_{\text{Posterior}} \propto \underbrace{1 - \Phi(0 | s_i - \mu_j, 2\beta^2 + \sigma_j^2)}_{\text{Verosimilitud } P(r | s_i)} \underbrace{\mathcal{N}(s_i | \mu_i, \sigma_i^2)}_{\text{Prior } p(s_i)}. \quad (2)$$

Donde el posterior normalizado se obtiene dividiendo el lado derecho con la evidencia, $P(r)$.

En este momento me interesa que noten las similitudes y diferencias entre la verosimilitud y la evidencia. La verosimilitud $p(r | s_i)$, a diferencia de la evidencia $p(r)$, supone que la habilidad oculta s_i es conocida. Y si revisan con detalle la diferencia entre ambas expresiones, van a ver que lo que se expresaba usando la media de la estimación μ_i en la evidencia, se reemplaza directamente por el valor de habilidad s_i , y que la incertidumbre asociadas a esa estimación σ_i no aparece cuando reemplazamos μ_i por s_i . Cuando estudiemos flujo de inferencia en modelos causales volveremos a ver esta expresión y verán como emerge naturalmente.

El posterior no es más que la densidad del prior no filtrada por la verosimilitud. La sorpresa, definida como el complemento de la verosimilitud, funciona como un filtro para el prior. En la región de hipótesis de muy alta habilidad, donde el resultado ganador no nos hubiera generado casi ninguna sorpresa ($\lim_{s_i \rightarrow \infty} P(r | s_i) = 1$), el posterior recibe casi toda la densidad del prior.




Figura 3: Actualización de creencias para el caso ganador.

En cambio, en la región de hipótesis de muy baja habilidad, donde el resultado habría generado mucha sorpresa ($\lim_{s_i \rightarrow -\infty} P(r|s_i) = 0$), el posterior no recibe casi nada de la densidad del prior.

Estos 5 elementos son invariante en el diseño de los sistemas de comunicación.

- **Fuente:** el estado *real* de la variable oculta *habilidad*(Messi)
 ↓ Realidad causal
- **Codificador:** el epifenómeno observable Ganar/Perder
 ↓ Realidad causal
- **Canal:** el procedimiento de medición *Scraper* de **fifa.com**
 ↓ Señal percibida D (True/False)
- **Decodificador:** la interpretación de la señal Modelo Causal
 ↓ La sorpresa o verosimilitud $P(d|h, M)$
- **Mensaje:** el posterior $P(habilidad(Messi) = h|d, M)$

La estructura invariante de los sistemas de comunicación con la realidad puede resumirse en el siguiente esquema.





Figura 4: Esquema de sistema de comunicación general propuesto por Shannon.

Si modificamos cualquiera de esos 5 elementos, la variable oculta de interés, el epifenómeno observable, el procedimiento de medición, el modelo causal, y el método de estimación del mensaje, entonces tendremos sistemas de comunicación alternativos.

1. Algoritmo suma-producto: inferencia por pasaje de mensajes.

La aplicación de las (dos) reglas de la probabilidad pueden descomponerse como pasaje de mensajes entre los nodos de la red causal que especifica su probabilidad conjunta.

Los *factor graph* (figura 5a) son un tipo de especificación gráfica alternativa a la redes bayesianas, en las cuales la distribución de probabilidad condicional pasan a formar parte como nodos del grafo, vinculadas a las variables que son sus parámetros. El uso de esta especificación gráfica nueva



(a) Factor graph. Nodos: variables y funciones. Ejes: la variable es parámetro de la función.

$$P(x) = \prod_{f \in v(x)} m_{f \rightarrow x}(x)$$

La marginal de x es producto de todos los mensajes entrantes

$$m_{x \rightarrow f}(x) = \prod_{h \in v(x) \setminus \{f\}} m_{h \rightarrow x}(x)$$

Las variables envían para adelante el producto de los mensajes que recibe de atrás

$$m_{f \rightarrow x}(x) = \sum_{\mathbf{h}} \left(f(\mathbf{h}, x) \prod_{h \in v(f) \setminus \{x\}} m_{h \rightarrow f}(h) \right)$$

Los factores envían para adelante el producto de lo que reciben de atrás con signo mismo, integrando por las variables de atrás

Figura 5: Sum-product algorithm, pasaje de mensajes en factor graphs.

está justificado en el hecho de que las reglas de la probabilidad pueden computarse localmente como pasaje de mensajes entre los nodos de la red.

El *sum-product algorithm* [2] aprovecha la estructura de la distribución de probabilidad conjunta, impuesta por el modelo causal, para aplicar eficientemente las reglas de la probabilidad. Cualquier modelo puede factorizarse en el producto de probabilidades condicionales. Haciendo uso de las independencias entre las variables, nuestro modelo (figura ??) puede factorizarse como,

$$p(\mathbf{s}, \mathbf{p}, d, r) = p(s_1)p(s_2)p(p_1|s_1)p(p_2|s_2)p(d|\mathbf{p})P(r|d) \quad (3)$$

En la figura 6 mostramos esta factorización gráficamente. Este tipo de representaciones, conocidas como *factor graph*, son gráficos con dos tipos de nodos: nodos variables (círculos blancos), y nodos funciones (cuadrados negros). Los ejes entre nodos variables y nodos funciones representan la relación matemática “la variable v es argumento de la función f ”. En nuestro caso queremos computar dos marginales, el posterior proporcional de las habilidades $p(s_i, r)$ y la probabilidad a priori del resultado $p(r)$. El *sum-product algorithm* es una forma general de descomponer las reglas de la probabilidad como mensajes que se envían los nodos del *factor graph*. Hay dos tipos de mensajes: los mensajes que envían los nodos variables a sus funciones vecinas ($m_{v \rightarrow f}(v)$); y los mensajes que envían los nodos funciones a sus variables vecinas ($m_{f \rightarrow v}(v)$). El primero codifica una porción de la regla del producto.

$$m_{v \rightarrow f}(v) = \prod_{h \in n(v) \setminus \{f\}} m_{h \rightarrow v}(v) \quad (\text{paso del producto})$$

donde $n(v)$ representa el conjunto de vecinos del nodo v . En pocas palabras, los mensajes que envía una variable v es simplemente la multiplicación de los mensajes que recibió del resto de sus vecinos $h \in n(v)$ salvo f . Los mensajes que envían los nodos funciones codifican una parte de la regla de la suma.

$$m_{f \rightarrow v}(v) = \int \cdots \int \left(f(\mathbf{h}, v) \prod_{h \in n(f) \setminus \{v\}} m_{h \rightarrow f}(h) \right) d\mathbf{h} \quad (\text{paso de la suma})$$

donde $\mathbf{h} = n(f) \setminus \{v\}$ es el conjunto de todos los vecinos de f salvo v , y $f(\mathbf{h}, v)$ representa la función f , evaluada en todos sus argumentos. En pocas palabras, los mensajes que envía una función f también es la multiplicación de los mensajes que recibió del resto de sus vecinos $h \in n(f)$ salvo v , por sí misma $f(\cdot)$, integrando (o sumando) sobre $\mathbf{h}$. Finalmente, la distribución de probabilidad




Figura 6: Forma gráfica de representar la factorización de la distribución conjunta inducida por el modelo causal básico (ecuación (3)). Los cuadrados negros representan las funciones, los círculos blancos representan las variable, y los ejes entre ellos representan la relación matemática “la variable es argumento de la función”.

marginal de una variable v es simplemente la multiplicación de los mensajes que v recibe de todos sus vecinos.

$$p(v) = \prod_{h \in n(v)} m_{h \rightarrow v} \quad (\text{probabilidad marginal})$$

Este algoritmo codifica la mínima cantidad de pasos que se requieren para calcular cualquier distribución de probabilidad marginal.

2. La clase Gaussiana

En esta sección revisamos primero la propiedades para realizar inferencia exacta mediante pasaje de mensajes en el modelo de habilidad y luego implementamos una clase de python **Gaussian** con los métodos $+$, $-$, $*$, $/$, $>$, que serán usados en el siguiente ejercicio como motor de inferencia.

2.1. Propiedades de la distribución Gaussiana

En esta sección enumeramos las propiedades que necesitamos para realizar inferencia exacta usando el modelo derivar los mensajes exactos y aproximados que surgen del *sum-product algorithm*. La primera propiedad establece que el producto de dos distribuciones gaussianas, ambas evaluadas en el mismo punto x , pueden expresarse como la producto de otras dos distribuciones gaussianas con sólo una de ellas evaluada en x .

$$\mathcal{N}(x|\mu_1, \sigma_1^2) \mathcal{N}(x|\mu_2, \sigma_2^2) \stackrel{4.1}{=} \mathcal{N}(\mu_1|\mu_2, \sigma_1^2 + \sigma_2^2) \mathcal{N}(x|\mu_*, \sigma_*^2) \quad (\text{Producto de gaussianas})$$

con $\sigma_*^2 = \left(\frac{1}{\sigma_1^2} + \frac{1}{\sigma_2^2} \right)^{-1}$ y $\mu_* = \left(\frac{\mu_1}{\sigma_1^2} + \frac{\mu_2}{\sigma_2^2} \right) \sigma_*^2$. Algo similar ocurre con la división de dos distribuciones gaussianas, ambas evaluadas en el mismo punto x .

$$\mathcal{N}(x|\mu_1, \sigma_1^2) / \mathcal{N}(x|\mu_2, \sigma_2^2) \stackrel{4.4}{\propto} \mathcal{N}(x|\mu_{\div}, \sigma_{\div}^2) / \mathcal{N}(\mu_1|\mu_2, \sigma_1^2 + \sigma_2^2) \quad (\text{División de gaussianas})$$

con $\sigma_{\div}^2 = \left(\frac{1}{\sigma_1^2} - \frac{1}{\sigma_2^2}\right)^{-1}$ y $\mu_{\div} = (\frac{\mu_1}{\sigma_1^2} - \frac{\mu_2}{\sigma_2^2})\sigma_{\div}^2$. La función indicadora $\mathbb{I}(\cdot = \cdot)$ vale 1 cuando la igualdad es verdadera y 0 en caso contrario. Se usa para representar distribuciones de probabilidad de variables discretas no aleatorias, como el resultado de las partidas dada la diferencia de desempeños $p(r|d)$. De la misma forma, la función delta de Dirac $\delta(\cdot = \cdot)$ se usa para representar distribuciones de probabilidad de variables continuas no aleatoria, es la diferencia de desempeños dados los rendimientos de los agentes $p(d|\mathbf{p})$. Cuando permite remplazar variable dentro de una integral,

$$\iint \delta(x = h(y, z)) f(x) g(y) dx dy = \int f(h(y, z)) g(y) dy \quad (\text{Función delta de dirac})$$

la dimensionalidad del problema se reduce. Usaremos además las propiedades que se derivan de la simetría de gaussianas.

$$\mathcal{N}(x|\mu, \sigma^2) = \mathcal{N}(\mu|x, \sigma^2) = \mathcal{N}(-\mu|-x, \sigma^2) = \mathcal{N}(-x|-\mu, \sigma^2) \quad (\text{Simetría de gaussianas})$$

La estandarización de la gaussiana,

$$\mathcal{N}(x|\mu, \sigma^2) = \mathcal{N}((x - \mu)/\sigma|0, 1) \quad (\text{Estandarización de gaussianas})$$

La igualdad entre la distribución gaussiana y la derivada de la su acumulada,

$$\frac{\partial}{\partial x} \Phi(x|\mu, \sigma^2) = \mathcal{N}(x|\mu, \sigma^2) \quad (\text{Derivada de la gaussiana acumulada})$$

que vale por definición. La simetría de la distribución gaussiana acumulada.

$$\Phi(0|\mu, \sigma^2) = 1 - \Phi(0|-\mu, \sigma^2) \quad (\text{Simetría de la gaussiana acumulada})$$

2.2. Implementar la clase Gaussian

Implementar la clase **Gaussian** para realizar inferencia por pasaje de mensajes en el modelo de estimación de habilidad. Se representa mediante dos parámetros, la media y el desvío estándar.

```
N1 = Gaussian(mu = 1.0, sigma = 1.0); N2 = Gaussian(1.0, 2.0)
```

Code 1: Inicialización de distribuciones gaussianas

La clase sobre escribe los operadores suma (+), resta (-), producto (*) y división (/) con las principales propiedades requeridas para computar las distribuciones marginales en el modelo TrueSkill Through Time.

$$\mathcal{N}(x|\mu_1, \sigma_1^2) \mathcal{N}(x|\mu_2, \sigma_2^2) \stackrel{4.1}{\propto} \mathcal{N}(x|\mu_*, \sigma_*^2) \quad (\text{N1} * \text{N2})$$

$$\mathcal{N}(x|\mu_1, \sigma_1^2) / \mathcal{N}(x|\mu_2, \sigma_2^2) \stackrel{4.4}{\propto} \mathcal{N}(x|\mu_{\div}, \sigma_{\div}^2) \quad (\text{N1} / \text{N2})$$

$$\iint \delta(t = x + y) \mathcal{N}(x|\mu_1, \sigma_1^2) \mathcal{N}(y|\mu_2, \sigma_2^2) dx dy \stackrel{4.2}{=} \mathcal{N}(t|\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2) \quad (\text{N1} + \text{N2})$$

$$\iint \delta(t = x - y) \mathcal{N}(x|\mu_1, \sigma_1^2) \mathcal{N}(y|\mu_2, \sigma_2^2) dx dy \stackrel{4.2}{=} \mathcal{N}(t|\mu_1 - \mu_2, \sigma_1^2 + \sigma_2^2) \quad (\text{N1} - \text{N2})$$

Aunque estas propiedades son ampliamente conocidas, adjuntamos sus demostraciones completas en el anexo.

Implementar los métodos de la clase **Gaussian** que se encuentra disponible en el archivo **Gaussian.py**

3. Estimación de habilidad por pasaje de mensajes

Conocer cómo aprenden las personas a lo largo del tiempo es importante en muchos aspectos de la vida, especialmente en el sistema educativo, deportivo y laboral. Dado que la habilidad es una variable oculta, debemos estimarla a partir de sus consecuencias observables directas: el éxito o fracaso en la resolución de problemas y competencias. Considerar sólo la frecuencia de éxitos como indicador de la habilidad de los individuos puede conducir a aproximaciones erróneas, fundamentalmente porque el valor de un éxito o un fracaso depende de la dificultad de los desafíos. Por esta razón, todos los modelos de habilidad ampliamente utilizados consideran que el resultado de la resolución de problemas se produce en relación a otra entidad oculta, que puede ser la habilidad de la persona contra la que compiten o la dificultad intrínseca del problema. Arpad Elo [3] desarrolla en la década del 60' una metodología de estimación de habilidad para la Federación de Ajedrez de los Estados Unidos (USCF), adoptada hasta el día de hoy por la Federación Internacional de Ajedrez (FIDE) ¹.

Aplicado a ajedrez, el modelo causal Elo supone que las habilidades (*skills*) ocultas de dos agentes i y j , $s_i, s_j \in \mathbb{R}$, generan el resultado observable $r \in \{\text{Ganar}, \text{Perder}\}$ a través de la diferencia $d \in \mathbb{R}$ de sus desempeños aleatorios $p_i, p_j \in \mathbb{R}$. En la figura 7 especificamos la versión “gaussiana” del modelo Elo (descrita en el trabajo de Herbrich et. al [4]) utilizando la notación de redes bayesianas.





Figura 7: Modelo generativo en el que las habilidades causan los resultados observables a través de la diferencia de los desempeños ocultos, $d = p_i - p_j$, ambas variables aleatorias centradas en la verdadera habilidad, $p \sim \mathcal{N}(s, \beta^2)$. Quien haya obtenido mayor rendimiento gana, $r = (d > 0)$. Las variables observables se pintan de gris, las ocultas en blanco, y las constantes se muestran como puntos negros.

El modelo causal supone que las personas exhiben desempeños aleatorios, que varían alrededor de su verdadera habilidad con un desvío estándar β , $\mathcal{N}(p | s, \beta^2)$. Una vez que se generan los desempeños, el resultado queda determinado pues, según el modelo, gana la persona que obtuvo mayor desempeño, $r = (p_i > p_j)$. El parámetro β^2 , es el mismo para todos los agentes, y actúa como la escala de las estimaciones: habilidades a un β de distancia, $s_i - s_j = \beta$, implica 76% de probabilidad de ganar, $P(p_i > p_j | s_i, s_j) \approx 0,76$, independientemente del valor absoluto de las habilidades s_i y s_j .

En presencia de equipos, el modelo supone que el desempeño de los equipos t es la suma de los desempeños de sus integrantes, y que el equipo con mayor desempeño gana, $r = (t_i > t_j)$. En la figura 8 mostramos la factorización gráfica del modelo Elo que incorpora equipos. En este ejemplo, tenemos dos equipos con dos jugadores cada uno. Toda partida con dos equipos tiene solución analítica exacta.

¹Los primeros modelos causales, propuestos hace casi un siglo por Thurstone y Zermelo, ya suponían que la probabilidad de un resultado observado r depende del rendimiento p (*performance*) del agente i y de su oponente j , $P(r | p_i, p_j)$. El campo siguió progresando con los trabajos de Bradley y Terry y Mosteller, que permitió a Arpad Elo [3] desarrollar su metodología.



$$f_{s_i} = \mathcal{N}(s_i | \mu_i, \sigma^2) \quad f_{p_i} = \mathcal{N}(p_i | s_i, \beta^2) \quad f_{t_e} = \delta(t_e = \sum_{i \in A_e} p_i) \quad f_d = \delta(d = t_a - t_b) \quad f_r = \mathbb{I}(d > 0)$$

Figura 8: Factorización gráfica de una partida con dos equipos de dos jugadores. El modelo Elo incorpora una variable nueva, t , que modela el desempeño de los equipos.

3.1. Mensajes descendentes: evidencia $P(D|M)$.

En esta sección mostramos los pasos para calcular la evidencia exacta (mensajes descendentes) de una partida con dos equipos. Sólo necesitamos el *sum-product algorithm* y las propiedades arriba mencionadas. Empezaremos primero con los mensajes “descendentes”, desde los priors al resultado, hasta calcular la evidencia, y seguiremos con los mensajes “ascendentes”, desde el resultado observado a los priors, hasta calcular el posterior de cada agente. Siguiendo el paso de la suma del *sum-product algorithm* y la factorización del modelo presentado en la figura 8, podemos ver que los mensajes que envían los factores de habilidad f_{s_i} a la variable s_i no son otra cosa más que el prior.

$$m_{f_{s_i} \rightarrow s_i}(s_i) = \mathcal{N}(s_i | \mu_i, \sigma_i^2) \quad (\text{s1})$$

```
s1 = Gaussian(); s2 = Gaussian(); s3 = Gaussian(); s4 = Gaussian()
```

Code 2: Prior de la habilidades

Tenemos acceso a este mensaje llamando al atributo `prior` de la clase `Player`. Podemos ver también, siguiendo el paso del producto del *sum-product algorithm* y la factorización del modelo, que el mensaje que envía la variable s_i al factor rendimiento f_{p_i} es nuevamente el prior. Debido a que es trivial calcular los mensajes que envían las variables (siempre es el producto de los mensajes que reciben de atrás), vamos a evitar escribirlos. Veamos entonces el mensaje que envían los factores rendimiento f_{p_i} a su variable p_i .

$$\begin{aligned} m_{f_{p_i} \rightarrow p_i}(p_i) &= \int \mathcal{N}(p_i | s_i, \beta^2) \mathcal{N}(s_i | \mu_i, \sigma_i^2) ds_i \\ &= \iint \delta(p_i = s_i + o) \underbrace{\mathcal{N}(o | 0, \beta^2)}_{\text{ruido}} \mathcal{N}(s_i | \mu_i, \sigma_i^2) ds_i do \quad (\text{p1} = \text{s1} + \text{o}) \\ &= \mathcal{N}(p_i | \mu_i, \beta^2 + \sigma_i^2) \end{aligned}$$

Hemos introducido una variable extra al modelo, para poder representar al desempeño p_i de un jugador como la suma de su habilidad oculta s_i y un ruido aleatorio centrado en 0, o . De esta forma podemos ver que el operador suma (+) que implementamos en nuestra clase `Gaussian`, aplicado entre el prior de s_i y la variable aleatoria o codifica el mensaje que el factor f_{p_i} envía a la variable p_i .

```
o = Gaussian(0, 1) # ruido
p1 = s1 + o; p2 = s2 + o; p3 = s3 + o; p4 = s4 + o
```

Code 3: Computando el desempeño individual a priori

El mensaje que envían los factores equipos f_{t_e} a la variable equipo t_e es una integral sobre todas las variables de desempeño individual,

$$m_{f_{t_e} \rightarrow t_e}(t_e) = \iint \delta(t_e = p_i + p_j) \mathcal{N}(p_i | \mu_i, \beta^2 + \sigma_i^2) \mathcal{N}(p_j | \mu_j, \beta^2 + \sigma_j^2) dp_i dp_j$$

$$= \mathcal{N}(t_e | \underbrace{\mu_i + \mu_j}_{\mu_e}, \underbrace{2\beta^2 + \sigma_i^2 + \sigma_j^2}_{\sigma_e^2}) \quad (\text{ta} = \text{p1} + \text{p2})$$

donde la función delta de Dirac impone la restricción de que la suma de los desempeños individuales sea igual a un valor de rendimiento del equipo t_e constante. Haciendo uso de las propiedades podemos resolver esta integral de forma analítica, obteniendo como resultado que el desempeño a priori de los equipos es una distribución gaussiana centrada en la suma de las estimaciones medias $\mu_e = \mu_i + \mu_j$ con una varianza que incluye tanto las incertidumbres de las estimaciones, $\sigma_i^2 + \sigma_j^2$, como la varianza de los rendimientos individuales, $\beta^2 + \beta^2$. Tenemos acceso a este mensaje cuando usamos el operador $+$ de la clase **Gaussian** para sumar los desempeños de los agentes,

```
ta = p1 + p2; tb = p3 + p4
```

Code 4: Computando el desempeño a priori de los equipos

El siguiente mensaje, que envía el factor diferencia f_{d_1} a la variable diferencia d_1 es,

$$m_{f_d \rightarrow d}(d) = \iint \delta(d = t_a - t_b) \mathcal{N}(t_a | \mu_a, \sigma_a^2) \mathcal{N}(t_b | \mu_b, \sigma_b^2) dt_a dt_b$$

$$= \mathcal{N}(d | \underbrace{\mu_a - \mu_b}_{\substack{\text{Diferencia : } \psi \\ \text{esperada}}}, \underbrace{\sigma_a^2 + \sigma_b^2}_{\substack{\text{incertidumbre : } \vartheta^2 \\ \text{total}}}) = \mathcal{N}(d | \psi, \vartheta^2) \quad (\text{d} = \text{ta} - \text{tb})$$

La diferencia de desempeños a priori es una distribución gaussiana centrada en la diferencia esperada a priori $\psi = \mu_a - \mu_b$ con una varianza $\vartheta^2 = \sigma_a^2 + \sigma_b^2$ que incluye la incertidumbre de ambos equipos. Tenemos acceso a este mensaje cuando usamos el operador $-$ de la clase **Gaussian** para obtener la diferencia de los desempeños de los equipos,

```
d = ta - tb
```

Code 5: Computando la diferencia de desempeños a priori

El último mensaje descendente, el que envía el factor f_r a la variable r , permite computar la evidencia, es decir la predicción a priori del resultado observado.

$$m_{f_r \rightarrow r}(r) = \int \mathbb{I}(d > 0) \mathcal{N}(d | \psi, \vartheta^2) dd = 1 - \Phi(0 | \psi, \vartheta^2) \quad (\text{evidence})$$

Tenemos acceso a este mensaje calculando el valor acumulado desde 0 hasta ∞ de la distribución de diferencia de desempeños de los equipos.

```
e = 1.0 - cdf(0, d.mu, d.sigma)
```

Code 6: Computando la predicción a priori del resultado observado (o evidencia)

Donde **e** contiene el valor de la ecuación **evidence**.

3.2. Mensajes ascendentes: verosimilitud $P(D|H, M)$.

La necesidad de aproximar el posterior de las habilidades, que en su expresión exacta (vista en la teórica), puede resolverse aproximando el posterior de la la diferencia de desempeños, que es una gaussiana truncada.

$$p(d | \text{Gana}) \propto \mathcal{N}(d | \psi, \vartheta^2) \mathbb{I}(d > 0) \quad (4)$$

Se sabe que la familia exponencial, a la que pertenece la distribución gaussiana, minimiza la divergencia Kullback-Leibler respecto de la verdadera distribución p , $KL(p||q)$, cuando ambas

tienen mismos momentos [5]. Sea $E(d|d > 0)$ y $V(d|d > 0)$ la esperanza y la varianza de $p(d|\text{Gana})$, luego la gaussiana que mejor aproxima a $p(d|\text{Gana})$ es

$$\hat{p}(d|\text{Gana}) = \mathcal{N}(d|\hat{\psi}, \hat{\vartheta}^2) = \mathcal{N}(d|E(d|d > 0), V(d|d > 0)) \quad (d > 0)$$

En nuestra clase **Gaussian**, implementamos el método *greater than __gt__(self, threshold)* para que realice automáticamente la aproximación de la gaussiana truncada.

```
d_approx = d > 0
```

Code 7: Computando la aproximación de la diferencia de desempeños

donde la distribución de diferencias **d** fue inicializada en el código 5. Dada $\hat{p}(d|\text{Gana})$, podemos calcular el resto de los mensaje ascendentes usando las operaciones de la clase **Gaussian**. Para derivar el primer mensaje ascendente aproximado, vamos a usar el hecho de que la marginal de la diferencia d y el resultado Gana se puede calcular como el producto de los mensajes entrantes a la variable d en el *factor graph* que tiene al resultado como variable observada.

$$p(d, \text{Gana}) = \underbrace{m_{f_d \rightarrow d}(d)}_{\text{Prior}} \underbrace{m_{f_r \rightarrow d}(d)}_{\text{Likelihood}} = p(d)P(\text{Gana}|d)$$

y que el likelihood de la variable d , $m_{f_r \rightarrow d}(d)$, es igual al mensaje ascendente que envía la variable d al factor f_d , $m_{d \rightarrow f_d}(d)$.

$$\begin{aligned} m_{d \rightarrow f_d}(d) &= m_{f_r \rightarrow d}(d) = \frac{p(d, \text{Gana})}{p(d)} \\ &\propto \frac{p(d|\text{Gana})}{p(d)} \approx \frac{\hat{p}(d|\text{Gana})}{p(d)} \quad (\text{lh}_d) \\ &= \frac{\mathcal{N}(d|\hat{\psi}, \hat{\vartheta}^2)}{\mathcal{N}(d|\psi, \vartheta^2)} = N(d, \psi_{\div}, \vartheta_{\div}^2) \end{aligned}$$

El operador división $/$ implementado en el métodos *__div__(self, M)* de nuestra clase **Gaussian** devuelve la gaussiana $N(d, \psi_{\div}, \vartheta_{\div}^2)$, que es el likelihood aproximado de la variable d .

```
lh_d = d_approx / d
```

Code 8: Computando el primer mensaje aproximado

Todos estos mensajes aproximados pueden ser interpretados como verosimilitudes porque contienen la información del resultado observado. El mensaje aproximado que el factor diferencia f_d envía a la variables de desempeño del equipo ganador t_a es,

$$\begin{aligned} \hat{m}_{f_d \rightarrow t_a}(t_a) &= \iint \underbrace{\delta(d = t_a - t_b)}_{t_a = d + t_b} \mathcal{N}(d_1|\psi_{\div}, \vartheta_{\div}^2) \mathcal{N}(t_b|\mu_b, \sigma_b^2) dd dt_b \\ &= \int \mathcal{N}(t_a - t_b|\psi_{\div}, \vartheta_{\div}^2) \mathcal{N}(t_b|\mu_b, \sigma_b^2) dt_b = \mathcal{N}(t_a | \mu_b + \psi_{\div}, \vartheta_{\div}^2 + \sigma_b^2) \end{aligned} \quad (\text{lh}_{ta})$$

Lo que se resume en nuestro operador $+$.

```
lh_ta = lh_d + tb
```

Code 9: Likelihood aproximado del desempeño del equipo a , t_a .

El mensaje aproximado que el factor desempeño de equipo f_{t_a} envía a la variables de desempeño individual p_1 es,

$$\hat{m}_{f_{t_a} \rightarrow p_1}(p_1) = \iint \underbrace{\delta(t_a = p_1 + p_2)}_{p_1 = t_a - p_2} \mathcal{N}(t_a | \mu_b + \psi_{\div}, \vartheta_{\div}^2 + \sigma_b^2) \mathcal{N}(p_2|\mu_2, \sigma_2^2 + \beta^2) dt_a dp_2 \quad (\text{lh}_{p1})$$

Lo que se resume en nuestro operador $-$.

```
lh_p1 = lh_ta - p2
```

Code 10: Likelihood aproximado del desempeño del jugador 1, p_1 .

El mensaje aproximado que el factor de desempeño individual f_{p_1} envía a la variables de habilidad s_1 es,

$$\begin{aligned}\hat{m}_{f_{p_1} \rightarrow s_1}(s_1) &= \int \mathcal{N}(p_1|s_1, \beta^2) \mathcal{N}(p_1|\mu_1 - \psi + \psi_{\div}, \vartheta_{\div}^2 + \vartheta^2 - \sigma_1^2 - \beta^2) dp_1 \\ \hat{m}_{f_{p_1} \rightarrow s_1}(s_1) &= \iint \underbrace{\delta(p_1 = s_1 + o)}_{s_1 = p_1 - o} \mathcal{N}(o|0, \beta^2) \mathcal{N}(p_1|\mu_1 - \psi + \psi_{\div}, \vartheta_{\div}^2 + \vartheta^2 - \sigma_1^2 - \beta^2) dp do \quad (\text{lh_s}) \\ &= \mathcal{N}(s_1|\mu_1 - \psi + \psi_{\div}, \vartheta_{\div}^2 + \vartheta^2 - \sigma_1^2)\end{aligned}$$

Donde o representa el ruido descrito en el segundo mensaje descendente.

```
lh_s1 = lh_p1 - o
```

Code 11: Likelihood aproximado de la habilidad.

Finalmente, el posterior proporcional aproximado de la variable s_1 se obtiene multiplicando los mensajes que recibe de sus factores vecinos.

$$\hat{p}(s_1, r) = \mathcal{N}(s_1|\mu_1, \sigma_1^2) \mathcal{N}(s_1|\mu_1 - \psi + \psi_{\div}, \vartheta_{\div}^2 + \vartheta^2 - \sigma_1^2) \quad (\text{posterior})$$

Tenemos acceso al posterior normalizado usando el operador `*` de la clase `Gaussian`.

```
posterior_s1 = s1 * lh_s1
print(posterior_s1)
> N(mu=2.361, sigma=5.516)
```

Code 12: Computando el posterior aproximado

Referencias

- [1] Shannon CE. A mathematical theory of communication. Bell system technical journal. 1948;27(3):379–423.
- [2] Kschischang FR, Frey BJ, Loeliger HA. Factor Graphs and the Sum-Product Algorithm. 2001;47(2):498–519. doi:10.1109/18.910572.
- [3] Elo AE. The Rating of Chess Players, Past and Present. Ishi Press; 2008.
- [4] Herbrich R, Minka R, Graepel T. TrueSkill™: A Bayesian Skill Rating System. In: Schölkopf B, Platt J, Hoffman T, editors. of the in Advances in Neural Information Processing Systems. Cambridge, MA: MIT Press; 2006. p. 569–576. Available from: <https://proceedings.neurips.cc/paper/2006/file/f44ee263952e65b3610b8ba51229d1f9-Paper.pdf>.
- [5] Minka T. Divergence Measures and Message Passing. Microsoft Research; 2005. MSR-TR-2005-173. Available from: <https://www.microsoft.com/en-us/research/publication/divergence-measures-and-message-passing/>.

4. Anexo 1. Gaussianas en una dimensión

4.1. Producto de gaussianas

El problema que tenemos que resolver es

$$\int \mathcal{N}(x|\mu_1, \sigma_1^2) \mathcal{N}(x|\mu_2, \sigma_2^2) dx \quad (5)$$

Por definición ,

$$\begin{aligned} \mathcal{N}(x|y, \beta^2) \mathcal{N}(x|\mu, \sigma^2) &= \frac{1}{\sqrt{2\pi}\sigma_1} e^{-\frac{(x-\mu_1)^2}{2\sigma_1^2}} \frac{1}{\sqrt{2\pi}\sigma_2} e^{-\frac{(x-\mu_2)^2}{2\sigma_2^2}} \\ &= \frac{1}{2\pi\sigma_1\sigma_2} \exp\left(-\underbrace{\left(\frac{(x-\mu_1)^2}{2\sigma_1^2} + \frac{(x-\mu_2)^2}{2\sigma_2^2}\right)}_{\theta}\right) \end{aligned} \quad (6)$$

Luego ,

$$\theta = \frac{\sigma_2^2(x^2 + \mu_1^2 - 2x\mu_1) + \sigma_1^2(x^2 + \mu_2^2 - 2x\mu_2)}{2\sigma_1^2\sigma_2^2} \quad (7)$$

Expando y reordeno los factores por potencias de x

$$\frac{(\sigma_1^2 + \sigma_2^2)x^2 - (2\mu_1\sigma_2^2 + 2\mu_2\sigma_1^2)x + (\mu_1^2\sigma_2^2 + \mu_2^2\sigma_1^2)}{2\sigma_1^2\sigma_2^2} \quad (8)$$

Divido al numerador y el denominador por el factor de x^2

$$\frac{x^2 - 2\frac{(\mu_1\sigma_2^2 + \mu_2\sigma_1^2)}{(\sigma_1^2 + \sigma_2^2)}x + \frac{(\mu_1^2\sigma_2^2 + \mu_2^2\sigma_1^2)}{(\sigma_1^2 + \sigma_2^2)}}{2\frac{\sigma_1^2\sigma_2^2}{(\sigma_1^2 + \sigma_2^2)}} \quad (9)$$

Esta ecuación es cuadrática en x , y por lo tanto es proporcional a una función de densidad gaussiana con desvío

$$\sigma_{\times} = \sqrt{\frac{\sigma_1^2\sigma_2^2}{\sigma_1^2 + \sigma_2^2}} \quad (10)$$

y media

$$\mu_{\times} = \frac{(\mu_1\sigma_2^2 + \mu_2\sigma_1^2)}{(\sigma_1^2 + \sigma_2^2)} \quad (11)$$

Dado que un término $\varepsilon = 0$ puede ser agregado para completar el cuadrado en θ , esta prueba es suficiente cuando no se necesita una normalización.

$$\varepsilon = \frac{\mu_{\times}^2 - \mu_{\times}^2}{2\sigma_{\times}^2} = 0 \quad (12)$$

Al agregar este término a θ tenemos

$$\theta = \frac{x^2 - 2\mu_{\times}x + \mu_{\times}^2}{2\sigma_{\times}^2} + \underbrace{\frac{(\mu_1^2\sigma_2^2 + \mu_2^2\sigma_1^2)}{(\sigma_1^2 + \sigma_2^2)} - \mu_{\times}^2}_{\varphi} \quad (13)$$

Reorganizando φ

$$\begin{aligned}
\varphi &= \frac{\frac{(\mu_1^2\sigma_2^2 + \mu_2^2\sigma_1^2)}{(\sigma_1^2 + \sigma_2^2)} - \left(\frac{(\mu_1\sigma_2^2 + \mu_2\sigma_1^2)}{(\sigma_1^2 + \sigma_2^2)}\right)^2}{2\frac{\sigma_1^2\sigma_2^2}{\sigma_1^2 + \sigma_2^2}} \\
&= \frac{(\sigma_1^2 + \sigma_2^2)(\mu_1^2\sigma_2^2 + \mu_2^2\sigma_1^2) - (\mu_1\sigma_2^2 + \mu_2\sigma_1^2)^2}{\sigma_1^2 + \sigma_2^2} \frac{1}{2\sigma_1^2\sigma_2^2} \\
&= \frac{(\mu_1^2\sigma_1^2\sigma_2^2 + \mu_2^2\sigma_1^4 + \mu_1^2\sigma_2^4 + \mu_2^2\sigma_1^2\sigma_2^2) - (\mu_1^2\sigma_2^4 + 2\mu_1\mu_2\sigma_1^2\sigma_2^2 + \mu_2^2\sigma_1^4)}{\sigma_1^2 + \sigma_2^2} \frac{1}{2\sigma_1^2\sigma_2^2} \\
&= \frac{(\sigma_1^2\sigma_2^2)(\mu_1^2 + \mu_2^2 - 2\mu_1\mu_2)}{\sigma_1^2 + \sigma_2^2} \frac{1}{2\sigma_1^2\sigma_2^2} = \frac{\mu_1^2 + \mu_2^2 - 2\mu_1\mu_2}{2(\sigma_1^2 + \sigma_2^2)} = \frac{(\mu_1 - \mu_2)^2}{2(\sigma_1^2 + \sigma_2^2)}
\end{aligned} \tag{14}$$

Luego ,

$$\theta = \frac{(x - \mu_{\times})^2}{2\sigma_{\times}^2} + \frac{(\mu_1 - \mu_2)^2}{2(\sigma_1^2 + \sigma_2^2)} \tag{15}$$

Colocando θ en su lugar

$$\begin{aligned}
\mathcal{N}(x|y, \beta^2)\mathcal{N}(x|\mu, \sigma^2) &= \frac{1}{2\pi\sigma_1\sigma_2} \exp\left(-\underbrace{\left(\frac{(x - \mu_{\times})^2}{2\sigma_{\times}^2} + \frac{(\mu_1 - \mu_2)^2}{2(\sigma_1^2 + \sigma_2^2)}\right)}_{\theta}\right) \\
&= \frac{1}{2\pi\sigma_1\sigma_2} \exp\left(-\frac{(x - \mu_{\times})^2}{2\sigma_{\times}^2}\right) \exp\left(-\frac{(\mu_1 - \mu_2)^2}{2(\sigma_1^2 + \sigma_2^2)}\right)
\end{aligned} \tag{16}$$

Multiplicando por $\sigma_{\times}\sigma_{\times}^{-1}$

$$\frac{\overbrace{\sigma_1\sigma_2}^{\sigma_{\times}}}{\sqrt{\sigma_1^2 + \sigma_2^2}} \frac{1}{\sigma_{\times}} \frac{1}{2\pi\cancel{\sigma_1\sigma_2}} \exp\left(-\frac{(x - \mu_{\times})^2}{2\sigma_{\times}^2}\right) \exp\left(-\frac{(\mu_1 - \mu_2)^2}{2(\sigma_1^2 + \sigma_2^2)}\right) \tag{17}$$

Luego ,

$$\frac{1}{\sqrt{2\pi}\sigma_{\times}} \exp\left(-\frac{(x - \mu_{\times})^2}{2\sigma_{\times}^2}\right) \frac{1}{\sqrt{2\pi(\sigma_1^2 + \sigma_2^2)}} \exp\left(-\frac{(\mu_1 - \mu_2)^2}{2(\sigma_1^2 + \sigma_2^2)}\right) \tag{18}$$

Retonando a la integral

$$\begin{aligned}
I &= \int \mathcal{N}(x|\mu_{\times}, \sigma_{\times}^2) \overbrace{\mathcal{N}(\mu_1|\mu_2, \sigma_1^2 + \sigma_2^2)}^{\text{Escalar independiente de } x} dx \\
&= \mathcal{N}(\mu_1|\mu_2, \sigma_1^2 + \sigma_2^2) \underbrace{\int \mathcal{N}(x|\mu_{\times}, \sigma_{\times}^2) dx}_{\text{Integra 1}} \\
&= \mathcal{N}(\mu_1|\mu_2, \sigma_1^2 + \sigma_2^2)
\end{aligned} \tag{19}$$

4.2. Suma de gaussianas

Demostración por inducción,

Casos base

$$P(1) := \int \delta(t_1 = x_1) \mathcal{N}(x_1|\mu_1, \sigma_1^2) dx_1 = \mathcal{N}(t_1|\mu_1, \sigma_1^2) \tag{20}$$

La proposición $P(1)$ es verdadera dada las propiedades de la función delta de dirac.

$$\begin{aligned}
P(2) &:= \iint \delta(t_2 = x_1 + x_2) \mathcal{N}(x_1 | \mu_1, \sigma_1^2) \mathcal{N}(x_2 | \mu_2, \sigma_2^2) dx_1 dx_2 \\
&\stackrel{21,1}{=} \int \mathcal{N}(x_1 | \mu_1, \sigma_1^2) \mathcal{N}(t_2 - x_1 | \mu_2, \sigma_2^2) dx_1 \\
&\stackrel{21,2}{=} \int \mathcal{N}(x_1 | \mu_1, \sigma_1^2) \mathcal{N}(x_1 | t_2 - \mu_2, \sigma_2^2) dx_1 \\
&\stackrel{*}{=} \int \underbrace{\mathcal{N}(t_2 | \mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2)}_{\text{const.}} \underbrace{\mathcal{N}(x_1 | \mu_*, \sigma_*^2)}_1 dx_1 \\
&= \mathcal{N}(t_2 | \mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2)
\end{aligned} \tag{21}$$

Donde $\stackrel{21,1}{=}$ vale por las propiedades de la función delta de dirac, $\stackrel{21,2}{=}$ vale por la simetría de las gaussianas, y $\stackrel{*}{=}$ vale por la demostración de multiplicación de normales en la sección 4.1. Luego, vale $P(2)$.

Paso inductivo $P(n) \Rightarrow P(n+1)$

Dado ,

$$P(n) := \int \cdots \int \delta(t_n = \sum_{i=1}^n x_i) \left(\prod_{i=1}^n \mathcal{N}(x_i | \mu_i, \sigma_i^2) \right) dx_1 \dots dx_n = \mathcal{N}(t | \sum_{i=1}^n \mu_i, \sum_{i=1}^n \sigma_i^2) \tag{22}$$

Queremos ver que $P(n+1)$ es válida.

$$P(n+1) := \int \cdots \int \delta(t_{n+1} = x_{n+1} + \sum_{i=1}^n x_i) \left(\prod_{i=1}^n \mathcal{N}(x_i | \mu_i, \sigma_i^2) \right) \mathcal{N}(x_{n+1} | \mu_{n+1}, \sigma_{n+1}^2) dx_1 \dots dx_n dx_{n+1} \tag{23}$$

Por independencia

$$\int \mathcal{N}(x_{n+1} | \mu_{n+1}, \sigma_{n+1}^2) \left(\int \cdots \int \delta(t_{n+1} = x_{n+1} + \sum_{i=1}^n x_i) \left(\prod_{i=1}^n \mathcal{N}(x_i | \mu_i, \sigma_i^2) \right) dx_1 \dots dx_n \right) dx_{n+1} \tag{24}$$

Por hipótesis inductiva

$$\int \mathcal{N}(x_{n+1} | \mu_{n+1}, \sigma_{n+1}^2) \mathcal{N}(t_{n+1} - x_{n+1} | \sum_{i=1}^n \mu_i, \sum_{i=1}^n \sigma_i^2) dx_{n+1} \tag{25}$$

Por la demostración de la sección 4.1

$$\mathcal{N}(t_{n+1} | \mu_{n+1} + \sum_{i=1}^n \mu_i, \sigma_{n+1}^2 + \sum_{i=1}^n \sigma_i^2) dx_{n+1} \tag{26}$$

Luego, $P(n+1)$ es válida.

4.3. Gaussiana por acumulada de Gaussiana.

Queremos resolver la integral

$$f(x) = \int \mathcal{N}(y; \mu_1, \sigma_1^2) \Phi(y + x; \mu_2, \sigma_2^2) dy \tag{27}$$

Para ello trabajamos con la derivada $\frac{\partial}{\partial x} f(x) = \theta(x)$,

$$\theta(x) = \frac{\partial}{\partial x} \int \mathcal{N}(y; \mu_1, \sigma_1^2) \Phi(y + x | \mu_2, \sigma_2^2) dy \tag{28}$$

$$\theta(x) = \int \mathcal{N}(y|\mu_1, \sigma_1^2) \frac{\partial}{\partial x} \Phi(y+x|\mu_2, \sigma_2^2) dy \quad (29)$$

La derivada de Φ es justamente una Gaussiana,

$$\begin{aligned} \theta(x) &= \int \mathcal{N}(y|\mu_1, \sigma_1^2) \mathcal{N}(y+x|\mu_2, \sigma_2^2) dy \\ &= \int \mathcal{N}(y|\mu_1, \sigma_1^2) \mathcal{N}(y|\mu_2 - x, \sigma_2^2) dy \end{aligned} \quad (30)$$

Por la demostración de la sección 4.1 sabemos

$$\theta(x) = \mathcal{N}(\mu_1|\mu_2 - x, \sigma_1^2 + \sigma_2^2) \quad (31)$$

Por simetría

$$\theta(x) = \mathcal{N}(x|\mu_2 - \mu_1, \sigma_1^2 + \sigma_2^2) \quad (32)$$

Retornando a $f(x)$

$$f(x) = \Phi(x|\mu_2 - \mu_1, \sigma_1^2 + \sigma_2^2) \quad (33)$$

4.4. Division de gaussianas

$$\kappa = \frac{\mathcal{N}(x|\mu_f, \sigma_f^2)}{\mathcal{N}(x|\mu_g, \sigma_g^2)} = \mathcal{N}(x|\mu_f, \sigma_f^2) \mathcal{N}(x|\mu_g, \sigma_g^2)^{-1} \quad (34)$$

Por definición

$$\begin{aligned} \kappa &= \frac{1}{\sqrt{2\pi}\sigma_f} e^{-\left(\frac{(x-\mu_f)^2}{2\sigma_f^2}\right)} \left(\frac{1}{\sqrt{2\pi}\sigma_g} e^{-\left(\frac{(x-\mu_g)^2}{2\sigma_g^2}\right)} \right)^{-1} \\ &= \frac{1}{\sqrt{2\pi}\sigma_f} e^{-\left(\frac{(x-\mu_f)^2}{2\sigma_f^2}\right)} \frac{\sqrt{2\pi}\sigma_g}{1} e^{\left(\frac{(x-\mu_g)^2}{2\sigma_g^2}\right)} \\ &= \frac{\sigma_g}{\sigma_f} \exp\left(- \underbrace{\left(\frac{(x-\mu_f)^2}{2\sigma_f^2} - \frac{(x-\mu_g)^2}{2\sigma_g^2} \right)}_{\theta} \right) \end{aligned} \quad (35)$$

Reorganizando θ

$$\begin{aligned} \theta &= \frac{(x-\mu_f)^2}{2\sigma_f^2} - \frac{(x-\mu_g)^2}{2\sigma_g^2} = \frac{\sigma_g^2(x-\mu_f)^2 - \sigma_f^2(x-\mu_g)^2}{2\sigma_f^2\sigma_g^2} \\ &= \frac{\sigma_g^2(x^2 + \mu_f^2 - 2\mu_fx) - \sigma_f^2(x^2 + \mu_g^2 - 2\mu_gx)}{2\sigma_f^2\sigma_g^2} \end{aligned} \quad (36)$$

Expandimos y ordenamos en base x ,

$$\begin{aligned} \theta &= ((\sigma_g^2 - \sigma_f^2)x^2 - 2(\sigma_g^2\mu_f - \sigma_f^2\mu_g)x + (\sigma_g^2\mu_f^2 - \sigma_f^2\mu_g^2)) \frac{1}{2\sigma_f^2\sigma_g^2} \\ &= \left(x^2 - \frac{2(\sigma_g^2\mu_f - \sigma_f^2\mu_g)}{(\sigma_g^2 - \sigma_f^2)} x + \frac{(\sigma_g^2\mu_f^2 - \sigma_f^2\mu_g^2)}{(\sigma_g^2 - \sigma_f^2)} \right) \frac{(\sigma_g^2 - \sigma_f^2)}{2\sigma_f^2\sigma_g^2} \end{aligned} \quad (37)$$

Esto es cuadrático en x . Dado que un término $\varepsilon = 0$, independiente de x puede ser agregado para completar el cuadrado en θ , esta prueba es suficiente para determinar la media y la varianza cuando no es necesario normalizar.

$$\sigma_{\div} = \sqrt{\frac{\sigma_f^2 \sigma_g^2}{(\sigma_g^2 - \sigma_f^2)}} \quad (38)$$

$$\mu_{\div} = \frac{(\sigma_g^2 \mu_f - \sigma_f^2 \mu_g)}{(\sigma_g^2 - \sigma_f^2)} \quad (39)$$

agregado $\varepsilon = \frac{\mu_{\div}^2 - \mu_{\div}^2}{2\sigma_{\div}^2} = 0$

$$\theta = \frac{x^2 - 2\mu_{\div}x + \mu_{\div}^2}{2\sigma_{\div}^2} + \underbrace{\frac{(\sigma_g^2 \mu_f^2 - \sigma_f^2 \mu_g^2)}{(\sigma_g^2 - \sigma_f^2)} - \mu_{\div}^2}_{\varphi} \quad (40)$$

Reorganizando φ

$$\begin{aligned} \varphi &= \left(\frac{(\sigma_g^2 \mu_f^2 - \sigma_f^2 \mu_g^2)}{(\sigma_g^2 - \sigma_f^2)} - \left(\frac{(\sigma_g^2 \mu_f - \sigma_f^2 \mu_g)}{(\sigma_g^2 - \sigma_f^2)} \right)^2 \right) \frac{(\sigma_g^2 - \sigma_f^2)}{2\sigma_f^2 \sigma_g^2} \\ &= \left((\sigma_g^2 \mu_f^2 - \sigma_f^2 \mu_g^2)(\sigma_g^2 - \sigma_f^2) - ((\sigma_g^2 \mu_f - \sigma_f^2 \mu_g))^2 \right) \frac{1}{2\sigma_f^2 \sigma_g^2 (\sigma_g^2 - \sigma_f^2)} \\ &= (\cancel{\sigma_g^4 \mu_f^2} - \sigma_f^2 \sigma_g^2 \mu_f^2 - \sigma_f^2 \sigma_g^2 \mu_g^2 + \cancel{\sigma_f^4 \mu_g^2} - (\cancel{\sigma_g^4 \mu_f^2} + \cancel{\sigma_f^4 \mu_g^2} - 2\sigma_f^2 \sigma_g^2 \mu_f \mu_g)) \frac{1}{2\sigma_f^2 \sigma_g^2 (\sigma_g^2 - \sigma_f^2)} \end{aligned} \quad (41)$$

Cancelando $\sigma_f^2 \sigma_g^2$

$$\varphi = \frac{-\mu_g^2 - \mu_f^2 + 2\mu_f \mu_g}{2(\sigma_g^2 - \sigma_f^2)} = \frac{-(\mu_g - \mu_f)^2}{2(\sigma_g^2 - \sigma_f^2)} \quad (42)$$

Luego θ

$$\theta = \frac{(x - \mu_{\div})^2}{2\sigma_{\div}^2} - \frac{(\mu_g - \mu_f)^2}{2(\sigma_g^2 - \sigma_f^2)} \quad (43)$$

Volviendo a la expresión original

$$\begin{aligned} \kappa &= \frac{\sigma_g}{\sigma_f} \exp \left(-\frac{(x - \mu_{\div})^2}{2\sigma_{\div}^2} + \frac{(\mu_g - \mu_f)^2}{2(\sigma_g^2 - \sigma_f^2)} \right) \\ &= \frac{\sigma_g}{\sigma_f} \exp \left(-\frac{(x - \mu_{\div})^2}{2\sigma_{\div}^2} \right) \exp \left(\frac{(\mu_g - \mu_f)^2}{2(\sigma_g^2 - \sigma_f^2)} \right) \end{aligned} \quad (44)$$

Multiplicando por $\frac{\sqrt{2\pi} \sigma_{\div}}{\sqrt{2\pi} \sigma_{\div}} \frac{\sqrt{\sigma_g^2 - \sigma_f^2}}{\sqrt{\sigma_g^2 - \sigma_f^2}} = 1$,

$$\begin{aligned} \kappa &= \frac{1}{\sqrt{2\pi} \sigma_{\div}} e^{-\frac{(x - \mu_{\div})^2}{2\sigma_{\div}^2}} \left(\frac{1}{\sqrt{2\pi(\sigma_g^2 - \sigma_f^2)}} e^{-\frac{(\mu_g - \mu_f)^2}{2(\sigma_g^2 - \sigma_f^2)}} \right)^{-1} \frac{\sigma_{\div}}{\sqrt{\sigma_g^2 - \sigma_f^2}} \frac{\sigma_g}{\sigma_f} \\ &= \frac{\mathcal{N}(x|\mu_{\div}, \sigma_{\div})}{\mathcal{N}(\mu_g|\mu_f, \sigma_g^2 - \sigma_f^2)} \frac{\sigma_g^2}{\sigma_g^2 - \sigma_f^2} \end{aligned} \quad (45)$$