

Sorpresa: el problema de la comunicación con la realidad

Semana 3

La estructura invariante del dato científico.
Construcción de sistemas de comunicación con la realidad. Tasa de información. Evaluación de sistemas alternativos por su tasa de sorpresa.

Bibliografía Semana 3

- MacKay. *Information theory, inference and learning algorithms*.. Cambridge university press; 2003 ([Descargar](#)). (lecturas 1.1, 2.4-6, 4.1) Lecturas muy cortas. MacKay tiene su curso en Youtube ([Ver](#)).

Otras:

- Kelly. *A New Interpretation of Information Rate*.; Bell System Technical Journal. 1956. ([Descargar](#)). (lectura paper)

Base empírica

¿Cuál es el dato de la realidad?

¿Cuál es el conjunto de elementos del mundo
que sirven de evidencia indubitable (dato)?

Base empírica


¿Cuál es el dato de la realidad?

- BE Filosófica: $\emptyset$

Base empírica

¿Cuál es el dato de la realidad?


- BE Filosófica: $\emptyset$
- BE Epistemológica: Precios



Base empírica

¿Cuál es el dato de la realidad?


- BE Filosófica: $\emptyset$
- BE Epistemológica: Precios
- Teoría: Inflación



Base empírica

¿Cuál es el dato de la realidad?


- BE Filosófica: $\emptyset$
- BE Epistemológica: Precios
- BE Metodológica₁: Inflación



Base empírica

¿Cuál es el dato de la realidad?


- BE Filosófica: $\emptyset$
- BE Epistemológica: Precios
- BE Metodológica₁: Inflación
- Teoría: Producto Bruto Interno



Base empírica

¿Cuál es el dato de la realidad?


- BE Filosófica: $\emptyset$
- BE Epistemológica: Precios
- BE Metodológica₁: Inflación
- BE Metodológica₂: Producto Bruto Interno



Base empírica

¿Cuál es el dato de la realidad?


- BE Filosófica: $\emptyset$
- BE Epistemológica: Precios
- BE Metodológica₁: Inflación
- BE Metodológica₂: Producto Bruto Interno
- Teoría: Política pública



Base empírica


¿Cuál es el dato de la realidad?

Depende del conjunto de supuestos
que una comunidad no pone en duda!



Base empírica

El dato se construye



Los datos como funciones proposicionales

$$f(x) = y$$

x **Unidad de análisis** (UA)

f **Variable** de la unidad de análisis (V)

y **Resultado** o valor de la variable (R)

Los datos como funciones proposicionales

$$f(x) = y$$

x **Unidad de análisis** (UA)

f **Variable** de la unidad de análisis (V)

y **Resultado** o valor de la variable (R)

$$Altura(\text{Gustavo}) = 1.77\text{m}$$

Los datos como funciones proposicionales

$$f(x) = y$$

x **Unidad de análisis** (UA)

f **Variable** de la unidad de análisis (V)

y **Resultado** o valor de la variable (R)

Ideología(Partido Comunista) = Comunista

Los datos como funciones proposicionales

$$f(x) = y$$

x **Unidad de análisis** (UA)

f **Variable** de la unidad de análisis (V)

y **Resultado** o valor de la variable (R)

$Ideología(\text{Partido Comunista}) = \text{Comunista}$

$P(Ideología(\text{Partido Comunista}) = \text{Comunista}) = 0.8$

Los datos como funciones proposicionales

$$f(x) = y$$

x **Unidad de análisis** (UA)

f **Variable** de la unidad de análisis (V)

y **Resultado** o valor de la variable (R)

$$Habilidad(\text{Maradona}) > Habilidad(\text{Messi})$$

Los datos como funciones proposicionales

$$f(x) = y$$


x **Unidad de análisis** (UA)

f **Variable** de la unidad de análisis (V)


y **Resultado** o valor de la variable (R)

El significado preciso de la función depende de la **operacionalización**

La estructura invariante del dato empírico




La estructura invariante del dato empírico



- **Fuente:** el estado *real* de la variable

La estructura invariante del dato empírico




- **Fuente:** el estado *real* de la variable

habilidad(Messi)

Pregunta de investigación (el problema de conocimiento)


La estructura invariante del dato empírico



- Fuente: el estado *real* de la variable
- **Codificador**: epifenómeno

habilidad(Messi)

La estructura invariante del dato empírico




- Fuente: el estado *real* de la variable
- **Codificador**: epifenómeno

habilidad(Messi)
Ganar/Perder

Examen de representatividad: que la dimensión exprese lo relevante de la variable.

La estructura invariante del dato empírico




- Fuente: el estado *real* de la variable
- Codificador: epifenómeno
- **Mensaje enviado**

habilidad(Messi)
Ganar/Perder

Examen de representatividad: que la dimensión exprese lo relevante de la variable.

La estructura invariante del dato empírico




- Fuente: el estado *real* de la variable
- Codificador: epifenómeno
- **Mensaje enviado**

habilidad(Messi)
Ganar/Perder
Realidad Causal

Examen de representatividad: que la dimensión exprese lo relevante de la variable.

La estructura invariante del dato empírico




- Fuente: el estado *real* de la variable
- Codificador: epifenómeno
- Mensaje enviado, **señal enviada**

habilidad(Messi)
Ganar/Perder
Realidad Causal

Examen de representatividad: que la dimensión exprese lo relevante de la variable.


La estructura invariante del dato empírico



- Fuente: el estado *real* de la variable
- Codificador: epifenómeno
 - Mensaje enviado, señal enviada
- **Perceptor**: el instrumento de medición

habilidad(Messi)
Ganar/Perder
Realidad Causal

La estructura invariante del dato empírico




- Fuente: el estado *real* de la variable
- Codificador: epifenómeno
 - Mensaje enviado, señal enviada
- **Perceptor**: el instrumento de medición

habilidad(Messi)
Ganar/Perder
Realidad Causal
Scraper de fifa.com

Examen de confiabilidad: que el procedimiento detecte fielmente la señal enviada.

La estructura invariante del dato empírico




- Fuente: el estado *real* de la variable
- Codificador: epifenómeno
 - Mensaje enviado, señal enviada
- Perceptor: el instrumento de medición
 - **Señal recibida**: base empírica

habilidad(Messi)
Ganar/Perder
Realidad Causal
Scraper de fifa.com

Examen de confiabilidad: que el procedimiento detecte fielmente la señal enviada.

La estructura invariante del dato empírico




- Fuente: el estado *real* de la variable
- Codificador: epifenómeno
 - Mensaje enviado, señal enviada
- Perceptor: el instrumento de medición
 - **Señal recibida**: base empírica

habilidad(Messi)
Ganar/Perder
Realidad Causal
Scraper de fifa.com
True/False

Examen de confiabilidad: que el procedimiento detecte fielmente la señal enviada.


La estructura invariante del dato empírico



- Fuente: el estado *real* de la variable
- Codificador: epifenómeno
 - Mensaje enviado, señal enviada
- Perceptor: el instrumento de medición
 - Señal recibida: base empírica
- **Decodificador**: la interpretación

habilidad(Messi)
Ganar/Perder
Realidad Causal
Scraper de fifa.com
True/False

La estructura invariante del dato empírico




- Fuente: el estado *real* de la variable
- Codificador: epifenómeno
 - Mensaje enviado, señal enviada
- Perceptor: el instrumento de medición
 - Señal recibida: base empírica
- **Decodificador**: la interpretación

habilidad(Messi)
Ganar/Perder
Realidad Causal
Scraper de fifa.com
True/False
Modelo Causal

Hipótesis indicadora: los elementos necesarios para hacer inferencia.

La estructura invariante del dato empírico




- Fuente: el estado *real* de la variable
- Codificador: epifenómeno
 - Mensaje enviado, señal enviada
- Perceptor: el instrumento de medición
 - Señal recibida: base empírica
- Decodificador: la interpretación
 - **Mensaje recibido**: la inferencia

habilidad(Messi)
Ganar/Perder
Realidad Causal
Scraper de fifa.com
True/False
Modelo Causal

Hipótesis indicadora: los elementos necesarios para hacer inferencia.

La estructura invariante del dato empírico



- Fuente: el estado *real* de la variable
- Codificador: epifenómeno
 - Mensaje enviado, señal enviada
- Perceptor: el instrumento de medición
 - Señal recibida: base empírica
- Decodificador: la interpretación
 - **Mensaje recibido**: la inferencia

habilidad(Messi)

Ganar/Perder

Realidad Causal

Scraper de fifa.com


True/False

Modelo Causal

Verosimilitud: $P(\text{Indicador}|h, M)$

Hipótesis indicadora: los elementos necesarios para hacer inferencia.

La estructura invariante del dato empírico



- Fuente: el estado *real* de la variable
- Codificador: epifenómeno
 - Mensaje enviado, señal enviada
- Perceptor: el instrumento de medición
 - Señal recibida: base empírica
- Decodificador: la interpretación
 - Mensaje recibido: la inferencia
- **Destino**: la estimación

habilidad(Messi)

Ganar/Perder

Realidad Causal


Scraper de fifa.com

True/False

Modelo Causal

Verosimilitud: $P(\text{Indicador}|h, M)$

La estructura invariante del dato empírico



- Fuente: el estado *real* de la variable
- Codificador: epifenómeno
 - Mensaje enviado, señal enviada
- Perceptor: el instrumento de medición
 - Señal recibida: base empírica
- Decodificador: la interpretación
 - Mensaje recibido: la inferencia
- **Destino**: la estimación

habilidad(Messi)

Ganar/Perder

Realidad Causal

Scraper de fifa.com

True/False

Modelo Causal

Verosimilitud: $P(\text{Indicador}|h, M)$

Posterior: $P(\text{habilidad}(\text{Messi}) = h|I, M)$

Teoría de la información

El problema de la comunicación con la realidad

Teoría de la información

El problema de la comunicación con la realidad

Quisiéramos que el mensaje recibido sea igual al enviado

Teoría de la información

El problema de la comunicación con la realidad

Quisiéramos que el mensaje recibido sea igual al enviado

Soluciones

Física: acercarme para escuchar mejor

Inferencia: interpretar la señal con ruido

Teoría de la información

El problema de la comunicación con la realidad

Quisiéramos que el mensaje recibido sea igual al enviado

Soluciones

Física: acercarme para escuchar mejor

Inferencia: interpretar la señal con ruido

Teoría de la información

El problema de la comunicación con la realidad

Quisiéramos que el mensaje recibido sea igual al enviado

Soluciones


Física: acercarme para escuchar mejor

Inferencia: interpretar la señal con ruido

¿Cómo exactamente?

Estimación de habilidad


De la federación internacional de ajedrez



Estimación de habilidad



De la federación internacional de ajedrez

Habilidad




Estimación de habilidad

De la federación internacional de ajedrez




Estimación de habilidad

De la federación internacional de ajedrez





$$P(d > 0 \mid s_a, s_b, M)$$



Estimación de habilidad

De la federación internacional de ajedrez

$$P(d > 0 \mid s_a, s_b, M) = 1 - \Phi\left(\frac{s_a - s_b}{\sqrt{2}\beta}\right)$$




Estimación de habilidad

De la federación internacional de ajedrez

$$P(d > 0 \mid s_a, s_b, \mathbf{M}) = 1 - \Phi\left(\frac{s_a - s_b}{\sqrt{2}\beta}\right)$$

Habilidad




$$s_a^{\text{new}} = s_a^{\text{old}} + \Delta$$

Estimación de habilidad

De la federación internacional de ajedrez

$$P(d > 0 \mid s_a, s_b, \mathbf{M}) = 1 - \Phi\left(\frac{s_a - s_b}{\sqrt{2}\beta}\right)$$

Habilidad



$$s_a^{\text{new}} = s_a^{\text{old}} + \Delta$$


$$\Delta = \underbrace{(1 - P(d > 0 \mid s_a, s_b))}_{\text{Sorpresa}}$$

Estimación de habilidad

De la federación internacional de ajedrez

$$P(d > 0 \mid s_a, s_b, \mathbf{M}) = 1 - \Phi\left(\frac{s_a - s_b}{\sqrt{2}\beta}\right)$$

Habilidad



$$s_a^{\text{new}} = s_a^{\text{old}} + \Delta$$


$$\Delta = \underbrace{(1 - P(d > 0 \mid s_a, s_b))}_{\text{Sorpresa}} \underbrace{(-1)^{(1-r)}}_{\text{Signo}}$$

Estimación de habilidad

De la federación internacional de ajedrez

$$P(d > 0 \mid s_a, s_b, M) = 1 - \Phi\left(\frac{s_a - s_b}{\sqrt{2}\beta}\right)$$

Habilidad



$$s_a^{\text{new}} = s_a^{\text{old}} + \Delta$$

$$\Delta = \underbrace{(1 - P(d > 0 \mid s_a, s_b))}_{\text{Sorpresa}} \underbrace{(-1)^{(1-r)}}_{\text{Signo}}$$


Problemas:

- Actualización simétrica

Estimación de habilidad

De la federación internacional de ajedrez

$$P(d > 0 \mid s_a, s_b, M) = 1 - \Phi \left(\frac{s_a - s_b}{\sqrt{2}\beta} \right)$$



$$s_a^{\text{new}} = s_a^{\text{old}} + \Delta$$

$$\Delta = \underbrace{(1 - P(d > 0 \mid s_a, s_b))}_{\text{Sorpresa}} \underbrace{(-1)^{(1-r)}}_{\text{Signo}}$$


Problemas:

- Actualización simétrica
- Jugadores nuevos desconocidos

Estimación de habilidad

De la federación internacional de ajedrez

$$P(d > 0 \mid s_a, s_b, M) = 1 - \Phi\left(\frac{s_a - s_b}{\sqrt{2}\beta}\right)$$



$$s_a^{\text{new}} = s_a^{\text{old}} + \Delta$$

$$\Delta = \underbrace{(1 - P(d > 0 \mid s_a, s_b))}_{\text{Sorpresa}} \underbrace{(-1)^{(1-r)}}_{\text{Signo}}$$


Problemas:

- Actualización simétrica
- Jugadores nuevos desconocidos
- No tiene en cuenta la incertidumbre

Estimación de habilidad

De la federación internacional de ajedrez

$$P(d > 0 \mid s_a, s_b, M) = 1 - \Phi\left(\frac{s_a - s_b}{\sqrt{2}\beta}\right)$$



$$s_a^{\text{new}} = s_a^{\text{old}} + \Delta K_a$$

$$\Delta = \underbrace{(1 - P(d > 0 \mid s_a, s_b))}_{\text{Sorpresa}} \underbrace{(-1)^{(1-r)}}_{\text{Signo}}$$

Problemas:

- Actualización simétrica
- Jugadores nuevos desconocidos
- No tiene en cuenta la incertidumbre

Estimación de habilidad

¿Cómo se resuelven todos esos problemas?

Estimación de habilidad

Aplicación estricta de las reglas de la probabilidad

$$P(\text{Hipótesis}|\text{Datos}, \text{Modelo}) = \frac{\overbrace{P(\text{Hipótesis}, \text{Datos}|\text{Modelo})}^{\text{Creencia compatible con los datos}}}{P(\text{Datos}|\text{Modelo})}$$

Estimación de habilidad

Aplicación estricta de las reglas de la probabilidad

$$P(\text{Hipótesis}|\text{Datos}, \text{Modelo}) = \frac{\overbrace{P(\text{Hipótesis}, \text{Datos}|\text{Modelo})}^{\text{Creencia compatible con los datos}}}{P(\text{Datos}|\text{Modelo})}$$

$$P(\text{Hipótesis}, \text{Datos}|\text{Modelo}) = P(\text{Hipótesis}|\text{Modelo}) P(\text{Datos}|\text{Hipótesis}, \text{Modelo})$$

Estimación de habilidad


Aplicación estricta de las reglas de la probabilidad

$$P(\text{Hipótesis}|\text{Datos}, \text{Modelo}) = \frac{\overbrace{P(\text{Hipótesis}, \text{Datos}|\text{Modelo})}^{\text{Creencia compatible con los datos}}}{P(\text{Datos}|\text{Modelo})}$$

$$\underbrace{P(\text{Hipótesis}, \text{Datos}|\text{Modelo})}_{\text{Creencia inicial compatible con los datos}} = \underbrace{P(\text{Hipótesis}|\text{Modelo})}_{\text{Creencia inicial}} \underbrace{P(\text{Datos}|\text{Hipótesis}, \text{Modelo})}_{\text{Sorpresa fuente de información.}}$$


Estimación de habilidad

Siglo 21: Aplicación estricta de las reglas de la probabilidad




Estimación de habilidad

Siglo 21: Aplicación estricta de las reglas de la probabilidad




Teorema de Bayes.




Estimación de habilidad

Siglo 21: Aplicación estricta de las reglas de la probabilidad




Teorema de Bayes.




Estimación de habilidad

Siglo 21: Aplicación estricta de las reglas de la probabilidad




Teorema de Bayes.




Estimación de habilidad

Siglo 21: Aplicación estricta de las reglas de la probabilidad




Teorema de Bayes.




Estimación de habilidad

Siglo 21: Aplicación estricta de las reglas de la probabilidad




Teorema de Bayes.



$$P(\text{Gana} | \text{Habilidad} = +\infty) = 1$$


Estimación de habilidad

Siglo 21: Aplicación estricta de las reglas de la probabilidad



$$P(\text{Gana} | \text{Habilidad} = -\infty) = 0$$

Teorema de Bayes.



$$P(\text{Gana} | \text{Habilidad} = +\infty) = 1$$

Sorpresa

Fuente de información

Sorpresa

Fuente de información

Información para las hipótesis.

$$P(\text{Datos} | \text{Hipótesis}_i, \text{Modelo})$$

Sorpresa

Fuente de información

Información para las hipótesis.

$$P(\text{Datos} | \text{Hipótesis}_i, \text{Modelo})$$

Información para los modelos.

$$P(\text{Datos} | \text{Modelo}_i)$$

Sorpresa

Fuente de información

$$P(\text{Datos}_T = \{d_1, d_2, \dots, d_T\} | \text{Modelo}_i)$$

Sorpresa

Fuente de información

$$P(\text{Datos}_T = \{d_1, d_2, \dots, d_T\} | \text{Modelo}_i) = P(d_1 | \text{Modelo}_i) P(d_2 | d_1, \text{Modelo}) \dots$$

Sorpresas

Fuente de información

$$P(\text{Datos}_T = \{d_1, d_2, \dots, d_T\} | \text{Modelo}_i) = P(d_1 | \text{Modelo}_i) P(d_2 | d_1, \text{Modelo}_i) \dots \approx 0$$

Sorpresas

Fuente de información

$$P(\text{Datos}_T = \{d_1, d_2, \dots, d_T\} | \text{Modelo}_i) = P(d_1 | \text{Modelo}_i) P(d_2 | d_1, \text{Modelo}) \dots \approx 0$$

Predicción en órdenes de magnitud

$$\log P(\text{Datos}_T | \text{Modelo}_i) = \log P(d_1 | \text{Modelo}_i) + \log P(d_2 | d_1, \text{Modelo}) \dots$$

Sorpresa

Fuente de información

$$P(\text{Datos}_T = \{d_1, d_2, \dots, d_T\} | \text{Modelo}_i) = P(d_1 | \text{Modelo}_i) P(d_2 | d_1, \text{Modelo}) \dots \approx 0$$

Predicción en órdenes de magnitud

$$\log P(\text{Datos}_T | \text{Modelo}_i) = \log P(d_1 | \text{Modelo}_i) + \log P(d_2 | d_1, \text{Modelo}) \dots$$

Tasa de predicción

$$\underbrace{P(\text{Datos}_T | \text{Modelo}_i)^{1/T}}_{\text{Media geométrica}}$$

Predicción en órdenes de magnitud

$$\log_2 P(\text{Datos})$$

Predicción en órdenes de magnitud

$$\log_2 P(\text{Datos})$$

¿Cuál es la menor cantidad de preguntas Sí/No que se necesitan para identificar un entero entre 0 y 15?

Predicción en órdenes de magnitud

$$\log_2 P(\text{Datos})$$

¿Cuál es la menor cantidad de preguntas Sí/No que se necesitan para identificar un entero entre 0 y 15?

1) $x \bmod 16 \geq 8$ 

Predicción en órdenes de magnitud

$\log_2 P(\text{Datos})$

¿Cuál es la menor cantidad de preguntas Sí/No que se necesitan para identificar un entero entre 0 y 15?

- 1) $x \bmod 16 \geq 8$ 
- 2) $x \bmod 8 \geq 4$ 

Predicción en órdenes de magnitud

$\log_2 P(\text{Datos})$

¿Cuál es la menor cantidad de preguntas Sí/No que se necesitan para identificar un entero entre 0 y 15?

- 1) $x \bmod 16 \geq 8$ 
- 2) $x \bmod 8 \geq 4$ 
- 3) $x \bmod 4 \geq 2$ 

Predicción en órdenes de magnitud

$$\log_2 P(\text{Datos})$$

¿Cuál es la menor cantidad de preguntas Sí/No que se necesitan para identificar un entero entre 0 y 15?

- 1) $x \bmod 16 \geq 8$ 
- 2) $x \bmod 8 \geq 4$ 
- 3) $x \bmod 4 \geq 2$ 
- 4) $x \bmod 2 \geq 1$ 

Predicción en órdenes de magnitud

$$\log_2 P(\text{Datos} = \{d_1 = 0, d_2 = 1, d_3 = 1, d_4 = 0\})$$

¿Cuál es la menor cantidad de preguntas Sí/No que se necesitan para identificar un entero entre 0 y 15?

- 1) $x \bmod 16 \geq 8$  $d_1 = 0$
- 2) $x \bmod 8 \geq 4$  $d_2 = 1$
- 3) $x \bmod 4 \geq 2$  $d_3 = 1$
- 4) $x \bmod 2 \geq 1$  $d_4 = 0$

Predicción en órdenes de magnitud

$$\log_2 P(\text{Datos} = \{d_1 = 0, d_2 = 1, d_3 = 1, d_4 = 0\})$$

¿Cuál es la menor cantidad de preguntas Sí/No que se necesitan para identificar un entero entre 0 y 15?

- 1) $x \bmod 16 \geq 8$  $d_1 = 0$
- 2) $x \bmod 8 \geq 4$  $d_2 = 1$
- 3) $x \bmod 4 \geq 2$  $d_3 = 1$
- 4) $x \bmod 2 \geq 1$  $d_4 = 0$

¿Qué número es?

Predicción en órdenes de magnitud

$$\log_2 P(\text{Datos} = \{d_1 = 0, d_2 = 1, d_3 = 1, d_4 = 0\})$$

¿Cuál es la menor cantidad de preguntas Sí/No que se necesitan para identificar un entero entre 0 y 15?

- 1) $x \bmod 16 \geq 8$  $d_1 = 0$
- 2) $x \bmod 8 \geq 4$  $d_2 = 1$
- 3) $x \bmod 4 \geq 2$  $d_3 = 1$
- 4) $x \bmod 2 \geq 1$  $d_4 = 0$

$$d_1 2^3 + d_2 2^2 + d_3 2^1 + d_4 2^0$$

Predicción en órdenes de magnitud

$$\log_2 P(\text{Datos} = \{d_1 = 0, d_2 = 1, d_3 = 1, d_4 = 0\})$$

¿Cuál es la menor cantidad de preguntas Sí/No que se necesitan para identificar un entero entre 0 y 15?

- 1) $x \bmod 16 \geq 8$  $d_1 = 0$
- 2) $x \bmod 8 \geq 4$  $d_2 = 1$
- 3) $x \bmod 4 \geq 2$  $d_3 = 1$
- 4) $x \bmod 2 \geq 1$  $d_4 = 0$

$$d_1 2^3 + d_2 2^2 + d_3 2^1 + d_4 2^0 = 0 + 4 + 2 + 0 = 6$$

Predicción en órdenes de magnitud

$$\log_2 P(\text{Datos} = \{d_1 = 0, d_2 = 1, d_3 = 1, d_4 = 0\}) = \sum_i \log_2 P(d_i)$$

¿Cuál es la menor cantidad de preguntas Sí/No que se necesitan para identificar un entero entre 0 y 15?

- 1) $x \bmod 16 \geq 8$  $d_1 = 0$
- 2) $x \bmod 8 \geq 4$  $d_2 = 1$
- 3) $x \bmod 4 \geq 2$  $d_3 = 1$
- 4) $x \bmod 2 \geq 1$  $d_4 = 0$

$$d_1 2^3 + d_2 2^2 + d_3 2^1 + d_4 2^0 = 0 + 4 + 2 + 0 = 6$$

Predicción en órdenes de magnitud

$$\log_2 P(\text{Datos} = \{d_1 = 0, d_2 = 1, d_3 = 1, d_4 = 0\}) = \sum_i \log_2 P(d_i)$$

¿Cuál es la menor cantidad de preguntas Sí/No que se necesitan para identificar un entero entre 0 y 15?

- 1) $x \bmod 16 \geq 8$  $d_1 = 0$
- 2) $x \bmod 8 \geq 4$  $d_2 = 1$
- 3) $x \bmod 4 \geq 2$  $d_3 = 1$
- 4) $x \bmod 2 \geq 1$  $d_4 = 0$

$$d_1 2^3 + d_2 2^2 + d_3 2^1 + d_4 2^0 = 0 + 4 + 2 + 0 = 6$$

$$\log_2 P(\text{Dato} = (x \bmod N \geq N/2)) = \log_2 \frac{1}{2}$$

Predicción en órdenes de magnitud

$$\log_2 P(\text{Datos} = \{d_1 = 0, d_2 = 1, d_3 = 1, d_4 = 0\}) = \sum_i \log_2 P(d_i) = -4$$

¿Cuál es la menor cantidad de preguntas Sí/No que se necesitan para identificar un entero entre 0 y 15?

- 1) $x \bmod 16 \geq 8$  $d_1 = 0$
- 2) $x \bmod 8 \geq 4$  $d_2 = 1$
- 3) $x \bmod 4 \geq 2$  $d_3 = 1$
- 4) $x \bmod 2 \geq 1$  $d_4 = 0$

$$d_1 2^3 + d_2 2^2 + d_3 2^1 + d_4 2^0 = 0 + 4 + 2 + 0 = 6$$

$$\log_2 P(\text{Dato} = (x \bmod N \geq N/2)) = \log_2 \frac{1}{2}$$

Predicción en órdenes de magnitud

- Información en bits

$$\log_2 P(\text{Datos} = \{d_1 = 0, d_2 = 1, d_3 = 1, d_4 = 0\}) = \sum_i \log_2 P(d_i) = -4$$

¿Cuál es la menor cantidad de preguntas Sí/No que se necesitan para identificar un entero entre 0 y 15?

- 1) $x \bmod 16 \geq 8$  $d_1 = 0$
- 2) $x \bmod 8 \geq 4$  $d_2 = 1$
- 3) $x \bmod 4 \geq 2$  $d_3 = 1$
- 4) $x \bmod 2 \geq 1$  $d_4 = 0$

$$d_1 2^3 + d_2 2^2 + d_3 2^1 + d_4 2^0 = 0 + 4 + 2 + 0 = 6$$

$$\log_2 P(\text{Dato} = (x \bmod N \geq N/2)) = \log_2 \frac{1}{2}$$

Predicción en órdenes de magnitud

- Información en bits

$$-\log_2 P(\text{Datos} = \{d_1 = 0, d_2 = 1, d_3 = 1, d_4 = 0\}) = \sum_i \log_2 P(d_i) = 4$$

¿Cuál es la menor cantidad de preguntas Sí/No que se necesitan para identificar un entero entre 0 y 15?

- 1) $x \bmod 16 \geq 8$  $d_1 = 0$
- 2) $x \bmod 8 \geq 4$  $d_2 = 1$
- 3) $x \bmod 4 \geq 2$  $d_3 = 1$
- 4) $x \bmod 2 \geq 1$  $d_4 = 0$

$$d_1 2^3 + d_2 2^2 + d_3 2^1 + d_4 2^0 = 0 + 4 + 2 + 0 = 6$$

$$\log_2 P(\text{Dato} = (x \bmod N \geq N/2)) = \log_2 \frac{1}{2}$$

Predicción en órdenes de magnitud

- Información en bits

$$-\log_2 P(\text{Datos} = \{d_1 = 0, d_2 = 1, d_3 = 1, d_4 = 0\}) = \sum_i \log_2 P(d_i) = 4$$

Información de Shannon

$$-\log_2 P(\text{Datos} | \dots)$$

Predicción en órdenes de magnitud

- Información en bits

$$-\log_2 P(\text{Datos} = \{d_1 = 0, d_2 = 1, d_3 = 1, d_4 = 0\}) = \sum_i \log_2 P(d_i) = 4$$

Información de Shannon

$$-\log_2 P(\text{Datos} | \dots)$$
$$=$$

$$\log_2 P(d_1 | \dots) + \log_2 P(d_2 | d_1 \dots) + \log_2 P(d_3 | d_2, d_1 \dots) + \log_2 P(d_4 | d_3, d_2, d_1 \dots)$$

Información en órdenes de magnitud

Información de Shannon

Submarino:


8								
7								
6								
5								
4								
3								
2								
1								
	A	B	C	D	E	F	G	H

Información en órdenes de magnitud

Información de Shannon

$$P(A1 = 1) = 1/64$$

Submarino:




Información en órdenes de magnitud

Información de Shannon

$$-\log_2 P(A1 = 1) = 6 \text{ bits}$$

Submarino:



Información en órdenes de magnitud

Información de Shannon

$$-\log_2 P(A1 = 0) = \log_2 64/63 = 0.0227 \text{ bit}$$

Submarino:

8								
7								
6								
5								
4								
3								
2								
1	x							
	A	B	C	D	E	F	G	H

Información en órdenes de magnitud

Información de Shannon

Submarino:

8								
7								
6								
5								
4								
3								
2	x							
1	x							
	A	B	C	D	E	F	G	H

$$-\log_2 P(A1 = 0) = \log_2 64/63 = 0.0227 \text{ bit}$$

$$-\log_2 P(A2 = 0|A1 = 0) = \log_2 63/62$$

Información en órdenes de magnitud

Información de Shannon

Submarino:

8								
7								
6								
5								
4								
3								
2	x							
1	x							
	A	B	C	D	E	F	G	H

$$-\log_2 P(A1 = 0) = \log_2 64/63 = 0.0227 \text{ bit}$$

$$-\log_2 P(A2 = 0|A1 = 0) = \log_2 63/62 = 0.0230 \text{ bit}$$

Información en órdenes de magnitud

Información de Shannon

Submarino:

8	x	x	x	x				
7	x	x	x	x				
6	x	x	x	x				
5	x	x	x	x				
4	x	x	x	x				
3	x	x	x	x				
2	x	x	x	x				
1	x	x	x	x				
	A	B	C	D	E	F	G	H

$$-\log_2 P(A1 = 0) = \log_2 64/63 = 0.0227 \text{ bit}$$

$$-\log_2 P(A2 = 0|A1 = 0) = \log_2 63/62 = 0.0230 \text{ bit}$$

$$\log_2 64/63 + \log_2 63/62 + \cdots + \log_2 33/32$$

Información en órdenes de magnitud

Información de Shannon

Submarino:

8	x	x	x	x				
7	x	x	x	x				
6	x	x	x	x				
5	x	x	x	x				
4	x	x	x	x				
3	x	x	x	x				
2	x	x	x	x				
1	x	x	x	x				
	A	B	C	D	E	F	G	H

$$-\log_2 P(A1 = 0) = \log_2 64/63 = 0.0227 \text{ bit}$$

$$-\log_2 P(A2 = 0|A1 = 0) = \log_2 63/62 = 0.0230 \text{ bit}$$

$$\log_2 64/63 + \log_2 63/62 + \cdots + \log_2 33/32$$

$$0.0227 + 0.0230 + \cdots + 0.0430 = 1.0 \text{ bit}$$

Información en órdenes de magnitud

Información de Shannon

Submarino:

8	x	x	x	x			x	x
7	x	x	x	x			x	x
6	x	x	x	x			x	x
5	x	x	x	x			x	x
4	x	x	x	x			x	x
3	x	x	x	x			x	x
2	x	x	x	x			x	x
1	x	x	x	x			x	x
	A	B	C	D	E	F	G	H

$$-\log_2 P(A1 = 0) = \log_2 64/63 = 0.0227 \text{ bit}$$

$$-\log_2 P(A2 = 0|A1 = 0) = \log_2 63/62 = 0.0230 \text{ bit}$$

$$\log_2 64/63 + \log_2 63/62 + \cdots + \log_2 33/32$$

$$\log_2 32/31 + \log_2 31/30 + \cdots + \log_2 17/16 = 2.0 \text{ bit}$$

Información en órdenes de magnitud

Información de Shannon

Submarino:

8	x	x	x	x			x	x
7	x	x	x	x			x	x
6	x	x	x	x			x	x
5	x	x	x	x			x	x
4	x	x	x	x			x	x
3	x	x	x	x			x	x
2	x	x	x	x			x	x
1	x	x	x	x			x	x
	A	B	C	D	E	F	G	H

$$-\log_2 P(A1 = 0) = \log_2 64/63 = 0.0227 \text{ bit}$$

$$-\log_2 P(A2 = 0|A1 = 0) = \log_2 63/62 = 0.0230 \text{ bit}$$

$$\log_2 64/63 + \log_2 63/62 + \cdots + \log_2 33/32$$

$$\log_2 32/31 + \log_2 31/30 + \cdots + \log_2 17/16 + \underbrace{\log_2 16/1}_{4.0 \text{ bit}} = 6.0 \text{ bit}$$

Información en órdenes de magnitud

Información de Shannon

Submarino:

8	x	x	x	x			x	x
7	x	x	x	x			x	x
6	x	x	x	x			x	x
5	x	x	x	x			x	x
4	x	x	x	x			x	x
3	x	x	x	x			x	x
2	x	x	x	x			x	x
1	x	x	x	x			x	x
	A	B	C	D	E	F	G	H

$$-\log_2 P(A1 = 0) = \log_2 64/63 = 0.0227 \text{ bit}$$

$$-\log_2 P(A2 = 0|A1 = 0) = \log_2 63/62 = 0.0230 \text{ bit}$$

$$\log_2 64/63 + \log_2 63/62 + \cdots + \log_2 33/32$$

$$\log_2 32/31 + \log_2 31/30 + \cdots + \log_2 17/16 + \underbrace{\log_2 16/1}_{4.0 \text{ bit}} = 6.0 \text{ bit}$$

$$\log_2 \frac{64}{63} + \log_2 \frac{63}{62} + \cdots + \log_2 \frac{n+1}{n} + \log_2 \frac{n}{1}$$

Información en órdenes de magnitud

Información de Shannon

Submarino:

8	x	x	x	x			x	x
7	x	x	x	x			x	x
6	x	x	x	x			x	x
5	x	x	x	x			x	x
4	x	x	x	x			x	x
3	x	x	x	x			x	x
2	x	x	x	x			x	x
1	x	x	x	x			x	x
A B C D E F G H								

$$-\log_2 P(A1 = 0) = \log_2 64/63 = 0.0227 \text{ bit}$$

$$-\log_2 P(A2 = 0|A1 = 0) = \log_2 63/62 = 0.0230 \text{ bit}$$

$$\log_2 64/63 + \log_2 63/62 + \cdots + \log_2 33/32$$

$$\log_2 32/31 + \log_2 31/30 + \cdots + \log_2 17/16 + \underbrace{\log_2 16/1}_{4.0 \text{ bit}} = 6.0 \text{ bit}$$

$$\log_2 \frac{64}{\cancel{63}} + \log_2 \frac{\cancel{63}}{62} + \cdots + \log_2 \frac{n+1}{n} + \log_2 \frac{n}{1}$$

Información en órdenes de magnitud

Información de Shannon

Submarino:

8	x	x	x	x			x	x
7	x	x	x	x			x	x
6	x	x	x	x			x	x
5	x	x	x	x			x	x
4	x	x	x	x			x	x
3	x	x	x	x			x	x
2	x	x	x	x			x	x
1	x	x	x	x			x	x
A B C D E F G H								

$$-\log_2 P(A1 = 0) = \log_2 64/63 = 0.0227 \text{ bit}$$

$$-\log_2 P(A2 = 0|A1 = 0) = \log_2 63/62 = 0.0230 \text{ bit}$$

$$\log_2 64/63 + \log_2 63/62 + \cdots + \log_2 33/32$$

$$\log_2 32/31 + \log_2 31/30 + \cdots + \log_2 17/16 + \underbrace{\log_2 16/1}_{4.0 \text{ bit}} = 6.0 \text{ bit}$$

$$\log_2 \frac{64}{\cancel{63}} + \log_2 \frac{\cancel{63}}{\cancel{62}} + \cdots + \log_2 \frac{\cancel{n+1}}{\cancel{n}} + \log_2 \frac{\cancel{n}}{1}$$

Información en órdenes de magnitud

Información de Shannon

Submarino:

8	x	x	x	x			x	x
7	x	x	x	x			x	x
6	x	x	x	x			x	x
5	x	x	x	x			x	x
4	x	x	x	x			x	x
3	x	x	x	x			x	x
2	x	x	x	x			x	x
1	x	x	x	x			x	x
A B C D E F G H								

$$-\log_2 P(A1 = 0) = \log_2 64/63 = 0.0227 \text{ bit}$$

$$-\log_2 P(A2 = 0|A1 = 0) = \log_2 63/62 = 0.0230 \text{ bit}$$

$$\log_2 64/63 + \log_2 63/62 + \cdots + \log_2 33/32$$

$$\log_2 32/31 + \log_2 31/30 + \cdots + \log_2 17/16 + \underbrace{\log_2 16/1}_{4.0 \text{ bit}} = 6.0 \text{ bit}$$

$$\log_2 \frac{64}{\cancel{63}} + \log_2 \frac{\cancel{63}}{\cancel{62}} + \cdots + \log_2 \frac{\cancel{n+1}}{\cancel{n}} + \log_2 \frac{\cancel{n}}{1} = \log_2 \frac{64}{1} = 6.0 \text{ bit}$$


Información en órdenes de magnitud

Información de Shannon

Hasta ahora medimos la información
contenida en observaciones individuales.


Información en órdenes de magnitud

Información de Shannon




¿Podemos calcular la tasa de información de los sistemas de comunicación alternativos?

Tasa de información de los sistemas de comunicación




¿Podemos calcular la tasa de información de los sistemas de comunicación alternativos?

Tasa de información de los sistemas de comunicación



¿Preferimos sistemas de comunicación
con mayor o con menor tasa de información?


Tasa de información de los sistemas de comunicación



1/2

0

1/2



1/3

0

2/3



Tasa de información

de los sistemas de comunicación

$$P(\text{Modelo}_i, \text{Datos}_T) = P(\text{Modelo}_i) \underbrace{P(\text{Datos}_T = \{(c_0, s_0, r_0), (c_1, s_1, r_1), \dots\} | \text{Modelo}_i)}_{\text{La \textbf{información} está en la \textbf{sorpresa} de la predicción}}$$

Tasa de información

de los sistemas de comunicación

$$P(\text{Modelo}_i, \text{Datos}_T) = P(\text{Modelo}_i) \underbrace{P(\text{Datos}_T = \{(c_0, s_0, r_0), (c_1, s_1, r_1), \dots\} | \text{Modelo}_i)}_{\text{La \textbf{información} está en la \textbf{sorpresa} de la predicción}}$$

$$P(\text{Datos}_T | \text{Modelo} = M) = \prod_t^T P(c_t, s_t, r_t | M)$$

Tasa de información de los sistemas de comunicación

$$P(\text{Modelo}_i, \text{Datos}_T) = P(\text{Modelo}_i) \underbrace{P(\text{Datos}_T = \{(c_0, s_0, r_0), (c_1, s_1, r_1), \dots\} | \text{Modelo}_i)}_{\text{La \textbf{información} está en la \textbf{sorpresa} de la predicción}}$$

$$\begin{aligned} P(\text{Datos}_T | \text{Modelo} = M) &= \prod_t^T P(c_t, s_t, r_t | M) \\ &= \prod_{i,j,k} P(c = i, s = j, r = k | M)^{n_{ijk}} \end{aligned}$$

Tasa de información de los sistemas de comunicación

$$P(\text{Modelo}_i, \text{Datos}_T) = P(\text{Modelo}_i) \underbrace{P(\text{Datos}_T = \{(c_0, s_0, r_0), (c_1, s_1, r_1), \dots\} | \text{Modelo}_i)}_{\text{La \textbf{información} está en la \textbf{sorpresa} de la predicción}}$$

$$\begin{aligned} P(\text{Datos}_T | \text{Modelo} = M) &= \prod_t^T P(c_t, s_t, r_t | M) \\ &= \prod_{i,j,k} P(c = i, s = j, r = k | M)^{n_{ijk}} \end{aligned}$$

con n_{ijk} la cantidad de observaciones de $(c = i, s = j, r = k)$.

Tasa de información

de los sistemas de comunicación

$$P(\text{Modelo}_i, \text{Datos}_T) = P(\text{Modelo}_i) \underbrace{P(\text{Datos}_T = \{(c_0, s_0, r_0), (c_1, s_1, r_1), \dots\} | \text{Modelo}_i)}_{\text{La \textbf{información} está en la \textbf{sorpresa} de la predicción}}$$

$$\begin{aligned} P(\text{Datos}_T | \text{Modelo} = M) &= \prod_t^T P(c_t, s_t, r_t | M) \\ &= \prod_{i,j,k} P(c = i, s = j, r = k | M)^{n_{ijk}} \\ &= \text{tasaDePrediccion}^T \end{aligned}$$

Tasa de información de los sistemas de comunicación

$$P(\text{Modelo}_i, \text{Datos}_T) = P(\text{Modelo}_i) \underbrace{P(\text{Datos}_T = \{(c_0, s_0, r_0), (c_1, s_1, r_1), \dots\} | \text{Modelo}_i)}_{\text{La \textbf{información} está en la \textbf{sorpresa} de la predicción}}$$

$$\begin{aligned} P(\text{Datos}_T | \text{Modelo} = M) &= \prod_t^T P(c_t, s_t, r_t | M) \\ &= \prod_{i,j,k} P(c = i, s = j, r = k | M)^{n_{ijk}} \\ &= \text{tasaDePrediccion}^T \end{aligned}$$

la tasaDePrediccion es la media geométrica $(P(d_1|M)P(d_2|d_1, M) \dots)^{1/T}$.

Tasa de información de los sistemas de comunicación

$$P(\text{Modelo}_i, \text{Datos}_T) = P(\text{Modelo}_i) \underbrace{P(\text{Datos}_T = \{(c_0, s_0, r_0), (c_1, s_1, r_1), \dots\} | \text{Modelo}_i)}_{\text{La \textbf{información} está en la \textbf{sorpresa} de la predicción}}$$

$$\begin{aligned} P(\text{Datos}_T | \text{Modelo} = M) &= \prod_t^T P(c_t, s_t, r_t | M) \\ &= \prod_{i,j,k} P(c = i, s = j, r = k | M)^{n_{ijk}} \end{aligned}$$

$$\underbrace{P(\text{Datos}_T | \text{Modelo} = M)^{\frac{1}{T}}}_{\text{Tasa de predicción}} = \text{tasaDePrediccion}$$

Tasa de información

de los sistemas de comunicación

$$P(\text{Modelo}_i, \text{Datos}_T) = P(\text{Modelo}_i) \underbrace{P(\text{Datos}_T = \{(c_0, s_0, r_0), (c_1, s_1, r_1), \dots\} | \text{Modelo}_i)}_{\text{La \textbf{información} está en la \textbf{sorpresa} de la predicción}}$$

$$\begin{aligned} P(\text{Datos}_T | \text{Modelo} = M) &= \prod_t^T P(c_t, s_t, r_t | M) \\ &= \prod_{i,j,k} P(c = i, s = j, r = k | M)^{n_{ijk}} \\ \underbrace{P(\text{Datos}_T | \text{Modelo} = M)^{\frac{1}{T}}}_{\text{Tasa de predicción}} &= \prod_{i,j,k} P(c = i, s = j, r = k | M)^{n_{ijk}/T} \end{aligned}$$

Tasa de información de los sistemas de comunicación

$$P(\text{Modelo}_i, \text{Datos}_T) = P(\text{Modelo}_i) \underbrace{P(\text{Datos}_T = \{(c_0, s_0, r_0), (c_1, s_1, r_1), \dots\} | \text{Modelo}_i)}_{\text{La \textbf{información} está en la \textbf{sorpresa} de la predicción}}$$

$$\begin{aligned} P(\text{Datos}_T | \text{Modelo} = M) &= \prod_t^T P(c_t, s_t, r_t | M) \\ &= \prod_{i,j,k} P(c = i, s = j, r = k | M)^{n_{ijk}} \\ \lim_{T \rightarrow \infty} \underbrace{P(\text{Datos}_T | \text{Modelo} = M)^{\frac{1}{T}}}_{\text{Tasa de predicción temporal}} &= \prod_{i,j,k} P(c = i, s = j, r = k | M)^{p_{ijk}} \end{aligned}$$

Tasa de información de los sistemas de comunicación

$$P(\text{Modelo}_i, \text{Datos}_T) = P(\text{Modelo}_i) \underbrace{P(\text{Datos}_T = \{(c_0, s_0, r_0), (c_1, s_1, r_1), \dots\} | \text{Modelo}_i)}_{\text{La \textbf{información} está en la \textbf{sorpresa} de la predicción}}$$

$$\begin{aligned} P(\text{Datos}_T | \text{Modelo} = M) &= \prod_t^T P(c_t, s_t, r_t | M) \\ &= \prod_{i,j,k} P(c = i, s = j, r = k | M)^{n_{ijk}} \\ \lim_{T \rightarrow \infty} \underbrace{P(\text{Datos}_T | \text{Modelo} = M)^{\frac{1}{T}}}_{\text{Tasa de predicción temporal}} &= \prod_{i,j,k} P(c = i, s = j, r = k | M)^{p_{ijk}} \end{aligned}$$

con $p_{ijk} = P(c = i, s = j, r = k | \text{Realidad Causal})$

Tasa de información de los sistemas de comunicación

$$P(\text{Modelo}_i, \text{Datos}_T) = P(\text{Modelo}_i) \underbrace{P(\text{Datos}_T = \{(c_0, s_0, r_0), (c_1, s_1, r_1), \dots\} | \text{Modelo}_i)}_{\text{La \textbf{información} está en la \textbf{sorpresa} de la predicción}}$$

$$\begin{aligned} P(\text{Datos}_T | \text{Modelo} = M) &= \prod_t^T P(c_t, s_t, r_t | M) \\ &= \prod_{i,j,k} P(c = i, s = j, r = k | M)^{n_{ijk}} \end{aligned}$$

$$\log \lim_{T \rightarrow \infty} \underbrace{P(\text{Datos}_T | \text{Modelo} = M)^{\frac{1}{T}}}_{\substack{\text{Tasa de predicción temporal} \\ \text{en órdenes de magnitud}}} = \log \prod_{i,j,k} P(c = i, s = j, r = k | M)^{p_{ijk}}$$

con $p_{ijk} = P(c = i, s = j, r = k | \text{Realidad Causal})$

Tasa de información de los sistemas de comunicación

$$P(\text{Modelo}_i, \text{Datos}_T) = P(\text{Modelo}_i) \underbrace{P(\text{Datos}_T = \{(c_0, s_0, r_0), (c_1, s_1, r_1), \dots\} | \text{Modelo}_i)}_{\text{La \textbf{información} está en la \textbf{sorpresa} de la predicción}}$$

$$\begin{aligned} P(\text{Datos}_T | \text{Modelo} = M) &= \prod_t^T P(c_t, s_t, r_t | M) \\ &= \prod_{i,j,k} P(c = i, s = j, r = k | M)^{n_{ijk}} \end{aligned}$$

$$\log \lim_{T \rightarrow \infty} \underbrace{P(\text{Datos}_T | \text{Modelo} = M)^{\frac{1}{T}}}_{\substack{\text{Tasa de predicción temporal} \\ \text{en órdenes de magnitud}}} = \sum_{i,j,k} p_{ijk} \log P(c = i, s = j, r = k | M)$$

$$\text{con } p_{ijk} = P(c = i, s = j, r = k | \text{Realidad Causal})$$

Tasa de información de los sistemas de comunicación

$$P(\text{Modelo}_i, \text{Datos}_T) = P(\text{Modelo}_i) \underbrace{P(\text{Datos}_T = \{(c_0, s_0, r_0), (c_1, s_1, r_1), \dots\} | \text{Modelo}_i)}_{\text{La \textbf{información} está en la \textbf{sorpresa} de la predicción}}$$

$$\begin{aligned} P(\text{Datos}_T | \text{Modelo} = M) &= \prod_t^T P(c_t, s_t, r_t | M) \\ &= \prod_{i,j,k} P(c = i, s = j, r = k | M)^{n_{ijk}} \end{aligned}$$

$$\log \lim_{T \rightarrow \infty} \underbrace{P(\text{Datos}_T | \text{Modelo} = M)^{\frac{1}{T}}}_{\substack{\text{Tasa de predicción temporal} \\ \text{en órdenes de magnitud}}} = \underbrace{\sum_{i,j,k} p_{ijk} \log P(c = i, s = j, r = k | M)}_{\substack{\text{Valor esperado de la informa-} \\ \text{ción en órdenes de magnitud}}}$$

Tasa de información de los sistemas de comunicación

$$P(\text{Modelo}_i, \text{Datos}_T) = P(\text{Modelo}_i) \underbrace{P(\text{Datos}_T = \{(c_0, s_0, r_0), (c_1, s_1, r_1), \dots\} | \text{Modelo}_i)}_{\text{La \textbf{información} está en la \textbf{sorpresa} de la predicción}}$$


$$\begin{aligned} P(\text{Datos}_T | \text{Modelo} = M) &= \prod_t^T P(c_t, s_t, r_t | M) \\ &= \prod_{i,j,k} P(c = i, s = j, r = k | M)^{n_{ijk}} \end{aligned}$$

$$\log \lim_{T \rightarrow \infty} \underbrace{P(\text{Datos}_T | \text{Modelo} = M)^{\frac{1}{T}}}_{\text{Tasa de predicción temporal en órdenes de magnitud}} = \underbrace{\sum_{i,j,k} p_{ijk} \log P(c = i, s = j, r = k | M)}_{\begin{array}{l} \text{Valor esperado de la información} \\ \text{—} \\ \text{en órdenes de magnitud} \end{array}}$$

Tasa de información de los sistemas de comunicación

$$\begin{array}{c} \text{Tasa de predicción en} \\ \text{órdenes de magnitud} \\ \hline -\log \lim_{T \rightarrow \infty} P(\text{Datos}_T | \text{Modelo Causal})^{1/T} \\ \\ = \\ \sum_{c,s,r} \underbrace{P(c, s, r | \text{Realidad Causal})}_{\text{Probabilidad de que se genere el dato}} \cdot \underbrace{\left(-\log P(c, s, r | \text{Modelo Causal}) \right)}_{\text{Información en órdenes de magnitud}} \\ \hline \text{Entropía cruzada} \\ \text{Tasa de información} \\ \text{del sistema de comunicación} \end{array}$$

No hay modelo de inteligencia artificial que pueda tener mejor desempeño que el modelo causal que se corresponde con la realidad causal subyacente



VS

ChatGPT $\infty.0$



Entropía cruzada

Tasa de información del sistema de comunicación

$$\mathcal{H}(\text{Realidad}_{\underset{R}{}}, \text{Modelo}_{\underset{M}{}} \text{ causal}) = \sum_{c,s,r} P(c, s, r|R) \cdot (-\log P(c, s, r|M))$$

Entropía cruzada

Tasa de información del sistema de comunicación

$$\mathcal{H}(\text{Realidad}_{\underset{R}{R}} \text{ causal}, \text{Modelo}_{\underset{M}{M}} \text{ causal}) = \sum_{c,s,r} P(c, s, r|R) \cdot (-\log P(c, s, r|M))$$

- Caso: $P(c, s, r|R) = P(c, s, r|M)$

Entropía cruzada

Tasa de información del sistema de comunicación

$$\mathcal{H}(\text{Realidad}_{\underset{R}{R}} \text{ causal}, \text{Modelo}_{\underset{M}{M}} \text{ causal}) = \sum_{c,s,r} P(c, s, r|R) \cdot (-\log P(c, s, r|M))$$

- Caso: $P(c, s, r|R) = P(c, s, r|M)$

$$\mathcal{H}(R, M) = \mathcal{H}(R) = \mathcal{H}(M) = \underbrace{\sum_{c,s,r} P(c, s, r) \cdot (-\log P(c, s, r))}_{\text{Entropía}}$$

Entropía cruzada

Tasa de información del sistema de comunicación

$$\mathcal{H}(\text{Realidad}_{\underset{R}{\text{causal}}}, \text{Modelo}_{\underset{M}{\text{causal}}}) = \sum_{c,s,r} P(c, s, r|R) \cdot (-\log P(c, s, r|M))$$

- Caso: $P(c, s, r|R) = P(c, s, r|M)$

$$\mathcal{H}(R, M) = \mathcal{H}(R) = \mathcal{H}(M) = \underbrace{\sum_{c,s,r} P(c, s, r) \cdot (-\log P(c, s, r))}_{\text{Entropía}}$$

- Caso: $P(c, s, r|R) \neq P(c, s, r|M)$

Entropía cruzada

Tasa de información del sistema de comunicación

$$\mathcal{H}(\text{Realidad}_{\underset{R}{R}} \text{ causal}, \text{Modelo}_{\underset{M}{M}} \text{ causal}) = \sum_{c,s,r} P(c, s, r|R) \cdot (-\log P(c, s, r|M))$$

- Caso: $P(c, s, r|R) = P(c, s, r|M)$

$$\mathcal{H}(R, M) = \mathcal{H}(R) = \mathcal{H}(M) = \underbrace{\sum_{c,s,r} P(c, s, r) \cdot (-\log P(c, s, r))}_{\text{Entropía}}$$

- Caso: $P(c, s, r|R) \neq P(c, s, r|M)$

$$\mathcal{H}(R, M) = \mathcal{H}(R) + \underbrace{\sum_{c,s,r} P(c, s, r|R) \cdot \left(-\log \frac{P(c, s, r|M)}{P(c, s, r|R)}\right)}_{\text{Divergencia KL } \mathcal{D}_{KL}(R||M)}$$

Unidad 3

Parte 2

Estimación de habilidad por pasaje de mensajes



Unidad 3

Parte 2


Estimación de habilidad por pasaje de mensajes

- Herbrich et al. **TrueSkill: A Bayesian Skill Rating System**. Advances in Neural Information Processing Systems. 2006. ([Descargar](#)). Lectura: paper completo.

Más adelante (Unidad 7):

- Dangauthier et al. *Trueskill through time: Revisiting the history of chess*. Advances in Neural Information Processing Systems. 2008. ([Descargar](#)). Lectura: paper completo.

TrueSkill



$$f_{s_i} = \mathcal{N}(s_i | \mu_i, \sigma^2) \quad f_{p_i} = \mathcal{N}(p_i | s_i, \beta^2) \quad f_{t_e} = \mathbb{I}(t_e = \sum_{i \in A_e} p_i) \quad f_d = \mathbb{I}(d = t_a - t_b) \quad f_r = \mathbb{I}(d > 0)$$

Propiedades

$$\mathcal{N}(x|\mu, \sigma^2) = \mathcal{N}(\mu|x, \sigma^2) = \mathcal{N}(-\mu|-x, \sigma^2) = \mathcal{N}(-x|-\mu, \sigma^2)$$

Propiedades

$$\mathcal{N}(x|\mu, \sigma^2) = \mathcal{N}(\mu|x, \sigma^2) = \mathcal{N}(-\mu|-x, \sigma^2) = \mathcal{N}(-x|-\mu, \sigma^2)$$

$$\mathcal{N}(x|\mu, \sigma^2) = \mathcal{N}\left(\frac{X - \mu}{\sigma} | 0, 1\right)$$

Propiedades

$$\mathcal{N}(x|\mu, \sigma^2) = \mathcal{N}(\mu|x, \sigma^2) = \mathcal{N}(-\mu|-x, \sigma^2) = \mathcal{N}(-x|-\mu, \sigma^2)$$

$$\mathcal{N}(x|\mu, \sigma^2) = \mathcal{N}\left(\frac{X - \mu}{\sigma} | 0, 1\right)$$

$$\frac{\partial}{\partial x} \Phi(x|\mu, \sigma^2) = \mathcal{N}(x|\mu, \sigma^2)$$

Propiedades

$$\mathcal{N}(x|\mu, \sigma^2) = \mathcal{N}(\mu|x, \sigma^2) = \mathcal{N}(-\mu|-x, \sigma^2) = \mathcal{N}(-x|-\mu, \sigma^2)$$

$$\mathcal{N}(x|\mu, \sigma^2) = \mathcal{N}\left(\frac{X - \mu}{\sigma} | 0, 1\right)$$

$$\frac{\partial}{\partial x} \Phi(x|\mu, \sigma^2) = \mathcal{N}(x|\mu, \sigma^2)$$

$$\int \int_{-\infty}^{\infty} \mathbb{I}(x = h(y, z)) f(x) g(y) dx dy = \int_{-\infty}^{\infty} f(h(y, z)) g(y) dy$$

Propiedades


$$\mathcal{N}(x|\mu, \sigma^2) = \mathcal{N}(\mu|x, \sigma^2) = \mathcal{N}(-\mu|-x, \sigma^2) = \mathcal{N}(-x|-\mu, \sigma^2)$$

$$\mathcal{N}(x|\mu, \sigma^2) = \mathcal{N}\left(\frac{X - \mu}{\sigma} | 0, 1\right)$$


$$\frac{\partial}{\partial x} \Phi(x|\mu, \sigma^2) = \mathcal{N}(x|\mu, \sigma^2)$$

$$\iint_{-\infty}^{\infty} \mathbb{I}(x = h(y, z)) f(x) g(y) dx dy = \int_{-\infty}^{\infty} f(h(y, z)) g(y) dy$$


$$\int_{-\infty}^{\infty} N(x|\mu_x, \sigma_x^2) N(x|\mu_y, \sigma_y^2) dx \stackrel{*}{=} \int_{-\infty}^{\infty} \underbrace{N(\mu_x|\mu_y, \sigma_x^2 + \sigma_y^2)}_{\text{constante}} \underbrace{N(x|\mu_*, \sigma_*^2) dx}_{\text{integral 1}}$$




$$m_{f_{s_i} \rightarrow s_i}(s_i) =$$




$$m_{f_{s_i} \rightarrow s_i}(s_i) = \mathcal{N}(s_i | \mu_i, \sigma_i^2)$$




$$m_{s_i \rightarrow f_{p_i}}(s_i) =$$




$$m_{s_i \rightarrow f_{p_i}}(s_i) = \mathcal{N}(s_i | \mu_i, \sigma_i^2)$$




$$m_{f_{p_i} \rightarrow p_i}(p_i) =$$




$$m_{f_{p_i} \rightarrow p_i}(p_i) =$$




$$m_{f_{p_i} \rightarrow p_i}(p_i) = \int \mathcal{N}(p_i | s_i, \beta^2) \mathcal{N}(s_i | \mu_i, \sigma_i^2) ds_i$$




$$m_{f_{p_i} \rightarrow p_i}(p_i) = \int \mathcal{N}(p_i | s_i, \beta^2) \mathcal{N}(s_i | \mu_i, \sigma_i^2) ds_i = \int \mathcal{N}(s_i | p_i, \beta^2) \mathcal{N}(s_i | \mu_i, \sigma_i^2) ds_i$$




$$\begin{aligned}
 m_{f_{p_i} \rightarrow p_i}(p_i) &= \int \mathcal{N}(p_i | s_i, \beta^2) \mathcal{N}(s_i | \mu_i, \sigma_i^2) ds_i = \int \mathcal{N}(s_i | p_i, \beta^2) \mathcal{N}(s_i | \mu_i, \sigma_i^2) ds_i \\
 &= \int \underbrace{\mathcal{N}(p_i | \mu_i, \beta^2 + \sigma_i^2)}_{\text{const.}} \underbrace{\mathcal{N}(s_i | \mu_*, \sigma_*^2)}_1 ds_i
 \end{aligned}$$




$$\begin{aligned}
 m_{f_{p_i} \rightarrow p_i}(p_i) &= \int \mathcal{N}(p_i | s_i, \beta^2) \mathcal{N}(s_i | \mu_i, \sigma_i^2) ds_i = \int \mathcal{N}(s_i | p_i, \beta^2) \mathcal{N}(s_i | \mu_i, \sigma_i^2) ds_i \\
 &= \int \underbrace{\mathcal{N}(p_i | \mu_i, \beta^2 + \sigma_i^2)}_{\text{const.}} \underbrace{\mathcal{N}(s_i | \mu_*, \sigma_*^2)}_1 ds_i = \mathcal{N}(p_i | \mu_i, \beta^2 + \sigma_i^2)
 \end{aligned}$$




$$m_{p_i \rightarrow f_{t_e}}(p_i) =$$




$$m_{p_i \rightarrow f_{t_e}}(p_i) = \mathcal{N}(p_i | \mu_i, \beta^2 + \sigma_i^2)$$




$$m_{f_{t_e} \rightarrow t_e}(t_e) =$$




$$m_{f_{t_e} \rightarrow t_e}(t_e) = \iint \mathbb{I}(t_e = p_i + p_j) \mathcal{N}(p_i | \mu_i, \beta^2 + \sigma_i^2) \mathcal{N}(p_j | \mu_j, \beta^2 + \sigma_j^2) dp_i dp_j$$




$$\begin{aligned}
 m_{f_{t_e} \rightarrow t_e}(t_e) &= \iint \mathbb{I}(t_e = p_i + p_j) \mathcal{N}(p_i | \mu_i, \beta^2 + \sigma_i^2) \mathcal{N}(p_j | \mu_j, \beta^2 + \sigma_j^2) dp_i dp_j \\
 &= \int \mathcal{N}(p_i | \mu_i, \beta^2 + \sigma_i^2) \mathcal{N}(t_e - p_i | \mu_j, \beta^2 + \sigma_j^2) dp_i
 \end{aligned}$$




$$\begin{aligned}
 m_{f_{t_e} \rightarrow t_e}(t_e) &= \iint \mathbb{I}(t_e = p_i + p_j) \mathcal{N}(p_i | \mu_i, \beta^2 + \sigma_i^2) \mathcal{N}(p_j | \mu_j, \beta^2 + \sigma_j^2) dp_i dp_j \\
 &= \int \mathcal{N}(p_i | \mu_i, \beta^2 + \sigma_i^2) \mathcal{N}(t_e - p_i | \mu_j, \beta^2 + \sigma_j^2) dp_i \\
 &= \int \underbrace{\mathcal{N}(t_e | \mu_i + \mu_j, 2\beta^2 + \sigma_i^2 + \sigma_j^2)}_{\text{const.}} \underbrace{\mathcal{N}(p_i | \mu_*, \sigma_*^2)}_1 dp_i
 \end{aligned}$$




$$\begin{aligned}
 m_{f_{t_e} \rightarrow t_e}(t_e) &= \iint \mathbb{I}(t_e = p_i + p_j) \mathcal{N}(p_i | \mu_i, \beta^2 + \sigma_i^2) \mathcal{N}(p_j | \mu_j, \beta^2 + \sigma_j^2) dp_i dp_j \\
 &= \int \mathcal{N}(p_i | \mu_i, \beta^2 + \sigma_i^2) \mathcal{N}(t_e - p_i | \mu_j, \beta^2 + \sigma_j^2) dp_i \\
 &= \mathcal{N}(t_e | \mu_i + \mu_j, 2\beta^2 + \sigma_i^2 + \sigma_j^2)
 \end{aligned}$$




$$\begin{aligned}
 m_{f_{t_e} \rightarrow t_e}(t_e) &= \iint \mathbb{I}(t_e = p_i + p_j) \mathcal{N}(p_i | \mu_i, \beta^2 + \sigma_i^2) \mathcal{N}(p_j | \mu_j, \beta^2 + \sigma_j^2) dp_i dp_j \\
 &= \int \mathcal{N}(p_i | \mu_i, \beta^2 + \sigma_i^2) \mathcal{N}(t_e - p_i | \mu_j, \beta^2 + \sigma_j^2) dp_i \\
 &= \mathcal{N}(t_e | \underbrace{\mu_i + \mu_j}_{\mu_e}, \underbrace{2\beta^2 + \sigma_i^2 + \sigma_j^2}_{\sigma_e^2})
 \end{aligned}$$




$$m_{f_d \rightarrow d}(d) =$$




$$m_{f_d \rightarrow d}(d) = \iint \mathbb{I}(d = t_a - t_b) \mathcal{N}(t_a | \mu_a, \sigma_a^2) \mathcal{N}(t_b | \mu_b, \sigma_b^2) dt_a dt_b$$




$$\begin{aligned}
 m_{f_d \rightarrow d}(d) &= \iint \mathbb{I}(d = t_a - t_b) \mathcal{N}(t_a | \mu_a, \sigma_a^2) \mathcal{N}(t_b | \mu_b, \sigma_b^2) dt_a dt_b \\
 &= \int \mathcal{N}(d + t_b | \mu_a, \sigma_a^2) \mathcal{N}(t_b | \mu_b, \sigma_b^2) dt_b
 \end{aligned}$$




$$\begin{aligned}
 m_{f_d \rightarrow d}(d) &= \iint \mathbb{I}(d = t_a - t_b) \mathcal{N}(t_a | \mu_a, \sigma_a^2) \mathcal{N}(t_b | \mu_b, \sigma_b^2) dt_a dt_b \\
 &= \int \mathcal{N}(t_b | \mu_a - d, \sigma_a^2) \mathcal{N}(t_b | \mu_b, \sigma_b^2) dt_b
 \end{aligned}$$




$$\begin{aligned}
 m_{f_d \rightarrow d}(d) &= \iint \mathbb{I}(d = t_a - t_b) \mathcal{N}(t_a | \mu_a, \sigma_a^2) \mathcal{N}(t_b | \mu_b, \sigma_b^2) dt_a dt_b \\
 &= \int \mathcal{N}(t_b | \mu_a - d, \sigma_a^2) \mathcal{N}(t_b | \mu_b, \sigma_b^2) dt_b \\
 &= \int \underbrace{\mathcal{N}(d | \mu_a - \mu_b, \sigma_a^2 + \sigma_b^2)}_{\text{const.}} \underbrace{\mathcal{N}(t_b | \mu_*, \sigma_*^2)}_1 dt_b
 \end{aligned}$$




$$\begin{aligned}
 m_{f_d \rightarrow d}(d) &= \iint \mathbb{I}(d = t_a - t_b) \mathcal{N}(t_a | \mu_a, \sigma_a^2) \mathcal{N}(t_b | \mu_b, \sigma_b^2) dt_a dt_b \\
 &= \int \mathcal{N}(t_b | \mu_a - d, \sigma_a^2) \mathcal{N}(t_b | \mu_b, \sigma_b^2) dt_b \\
 &= \mathcal{N}(d | \mu_a - \mu_b, \sigma_a^2 + \sigma_b^2)
 \end{aligned}$$




$$\begin{aligned}
 m_{f_d \rightarrow d}(d) &= \iint \mathbb{I}(d = t_a - t_b) \mathcal{N}(t_a | \mu_a, \sigma_a^2) \mathcal{N}(t_b | \mu_b, \sigma_b^2) dt_a dt_b \\
 &= \int \mathcal{N}(t_b | \mu_a - d, \sigma_a^2) \mathcal{N}(t_b | \mu_b, \sigma_b^2) dt_b \\
 &= \mathcal{N}(d | \underbrace{\mu_a - \mu_b}_{\text{Diferencia esperada } \delta}, \underbrace{\sigma_a^2 + \sigma_b^2}_{\text{Varianza total } \vartheta})
 \end{aligned}$$




$$\begin{aligned}
 m_{f_d \rightarrow d}(d) &= \iint \mathbb{I}(d = t_a - t_b) \mathcal{N}(t_a | \mu_a, \sigma_a^2) \mathcal{N}(t_b | \mu_b, \sigma_b^2) dt_a dt_b \\
 &= \int \mathcal{N}(t_b | \mu_a - d, \sigma_a^2) \mathcal{N}(t_b | \mu_b, \sigma_b^2) dt_b \\
 &= \mathcal{N}(d | \underbrace{\mu_a - \mu_b}_{\text{Diferencia esperada } \delta}, \underbrace{\sigma_a^2 + \sigma_b^2}_{\text{Varianza total } \vartheta^2}) = \mathcal{N}(d | \delta, \vartheta^2)
 \end{aligned}$$




$$m_{f_r \rightarrow r}(r) =$$




$$m_{f_r \rightarrow r}(r) = \int \mathbb{I}(d > 0) \mathcal{N}(d | \delta, \vartheta^2) dd$$



$$\begin{aligned}
 m_{f_r \rightarrow r}(r) &= \int \mathbb{I}(d > 0) \mathcal{N}(d|\delta, \vartheta^2) dd \\
 &= \int_0^\infty \mathcal{N}(d|\delta, \vartheta^2) dd
 \end{aligned}$$




$$\begin{aligned}
 m_{f_r \rightarrow r}(r) &= \int \mathbb{I}(d > 0) \mathcal{N}(d|\delta, \vartheta^2) dd \\
 &= \int_0^\infty \mathcal{N}(d|\delta, \vartheta^2) dd \\
 &= 1 - \Phi(0|\delta, \vartheta^2)
 \end{aligned}$$




$$\begin{aligned}
 m_{f_r \rightarrow r}(r) &= \int \mathbb{I}(d > 0) \mathcal{N}(d|\delta, \vartheta^2) dd \\
 &= \int_0^\infty \mathcal{N}(d|\delta, \vartheta^2) dd \\
 &= 1 - \Phi(0|\delta, \vartheta^2) = \Phi\left(\frac{\delta}{\vartheta}\right)
 \end{aligned}$$

Evidencia


$$P(\text{Resultado}|\text{Modelo}) = 1 - \Phi\left(0 \mid \underbrace{(\overbrace{\mu_1 + \mu_2}^{\mu_a}) - (\overbrace{\mu_3 + \mu_4}^{\mu_b})}_{\text{Diferencia esperada: } \delta}, \underbrace{2\beta^2 + \overbrace{\sigma_1^2 + \sigma_2^2}^{\sigma_a^2} + 2\beta^2 + \overbrace{\sigma_3^2 + \sigma_4^2}^{\sigma_b^2}}_{\text{incertidumbre total: } \vartheta^2}\right)$$




Mensajes ascendentes




$$m_{f_r \rightarrow d}(d) =$$




$$m_{f_r \rightarrow d}(d) = \mathbb{I}(d > 0)$$




$$m_{f_d \rightarrow t_a}(t_a) =$$




$$m_{f_d \rightarrow t_a}(t_a) = \iint \mathbb{I}(d = t_a - t_b) \mathbb{I}(d > 0) \mathcal{N}(t_b | \mu_b, \sigma_b^2) dt_b dd$$




$$m_{f_d \rightarrow t_a}(t_a) = \int \mathbb{I}(t_a > t_b) \mathcal{N}(t_b | \mu_b, \sigma_b^2) dt_b$$




$$m_{f_d \rightarrow t_a}(t_a) = \int \mathbb{I}(t_a > t_b) \mathcal{N}(t_b | \mu_b, \sigma_b^2) dt_b$$







$$m_{f_d \rightarrow t_a}(t_a) = \int \mathbb{I}(t_a > t_b) \mathcal{N}(t_b | \mu_b, \sigma_b^2) dt_b$$

$$= \Phi(t_a | \mu_b, \sigma_b^2)$$







$$m_{f_{t_a} \rightarrow p_1}(p_1) =$$




$$m_{f_{t_a} \rightarrow p_1}(p_1) = \iint \mathbb{I}(t_a = p_1 + p_2) \mathcal{N}(p_2 | \mu_2, \sigma_2^2 + \beta^2) \Phi(t_a | \mu_b, \sigma_b^2) dt_a dp_2$$



$$m_{f_{t_a} \rightarrow p_1}(p_1) = \int \mathcal{N}(p_2 | \mu_2, \sigma_2^2 + \beta^2) \Phi(p_1 + p_2 | \mu_b, \sigma_b^2) dp_2$$




$$m_{f_{t_a} \rightarrow p_1}(p_1) = \int \mathcal{N}(p_2 | \mu_2, \sigma_2^2 + \beta^2) \Phi(p_1 | \mu_b - p_2, \sigma_b^2) dp_2$$




$$m_{f_{t_a} \rightarrow p_1}(p_1) = \int \mathcal{N}(p_2 | \mu_2, \sigma_2^2 + \beta^2) \Phi(p_1 | \mu_b - p_2, \sigma_b^2) dp_2$$

$$\frac{\partial}{\partial p_1} m_{f_{t_a} \rightarrow p_1}(p_1) = \frac{\partial}{\partial p_1} \int \mathcal{N}(p_2 | \mu_2, \sigma_2^2 + \beta^2) \Phi(p_1 | \mu_b - p_2, \sigma_b^2) dp_2$$




$$m_{f_{t_a} \rightarrow p_1}(p_1) = \int \mathcal{N}(p_2 | \mu_2, \sigma_2^2 + \beta^2) \Phi(p_1 | \mu_b - p_2, \sigma_b^2) dp_2$$

$$\frac{\partial}{\partial p_1} m_{f_{t_a} \rightarrow p_1}(p_1) = \int \mathcal{N}(p_2 | \mu_2, \sigma_2^2 + \beta^2) \frac{\partial}{\partial p_1} \Phi(p_1 | \mu_b - p_2, \sigma_b^2) dp_2$$




$$m_{f_{t_a} \rightarrow p_1}(p_1) = \int \mathcal{N}(p_2 | \mu_2, \sigma_2^2 + \beta^2) \Phi(p_1 | \mu_b - p_2, \sigma_b^2) dp_2$$

$$\frac{\partial}{\partial p_1} m_{f_{t_a} \rightarrow p_1}(p_1) = \int \mathcal{N}(p_2 | \mu_2, \sigma_2^2 + \beta^2) \mathcal{N}(p_1 | \mu_b - p_2, \sigma_b^2) dp_2$$




$$m_{f_{t_a} \rightarrow p_1}(p_1) = \int \mathcal{N}(p_2 | \mu_2, \sigma_2^2 + \beta^2) \Phi(p_1 | \mu_b - p_2, \sigma_b^2) dp_2$$

$$\frac{\partial}{\partial p_1} m_{f_{t_a} \rightarrow p_1}(p_1) = \int \mathcal{N}(p_2 | \mu_2, \sigma_2^2 + \beta^2) \mathcal{N}(p_2 | \mu_b - p_1, \sigma_b^2) dp_2$$



$$m_{f_{t_a} \rightarrow p_1}(p_1) = \int \mathcal{N}(p_2 | \mu_2, \sigma_2^2 + \beta^2) \Phi(p_1 | \mu_b - p_2, \sigma_b^2) dp_2$$


$$\frac{\partial}{\partial p_1} m_{f_{t_a} \rightarrow p_1}(p_1) = \int \underbrace{\mathcal{N}(\mu_2 | \mu_b - p_1, \sigma_b^2 + \sigma_2^2 + \beta^2)}_{\text{const.}} \underbrace{\mathcal{N}(p_2 | \mu_*, \sigma_*^2) dp_2}_1$$



$$m_{f_t \rightarrow p}(p)$$

$$m_{f_{t_a} \rightarrow p_1}(p_1) = \int \mathcal{N}(p_2 | \mu_2, \sigma_2^2 + \beta^2) \Phi(p_1 | \mu_b - p_2, \sigma_b^2) dp_2$$


$$\frac{\partial}{\partial p_1} m_{f_{t_a} \rightarrow p_1}(p_1) = \mathcal{N}(p_1 | \mu_b - \mu_2, \sigma_b^2 + \sigma_2^2 + \beta^2)$$



$$m_{f_{t_a} \rightarrow p_1}(p_1) = \int \mathcal{N}(p_2 | \mu_2, \sigma_2^2 + \beta^2) \Phi(p_1 | \mu_b - p_2, \sigma_b^2) dp_2$$

$$\frac{\partial}{\partial p_1} m_{f_{t_a} \rightarrow p_1}(p_1) = \mathcal{N}(p_1 | \mu_b - \mu_2, \sigma_b^2 + \sigma_2^2 + \beta^2)$$

$$m_{f_{t_a} \rightarrow p_1}(p_1) =$$




$$m_{f_t \rightarrow p}(p)$$


$$m_{f_{t_a} \rightarrow p_1}(p_1) = \int \mathcal{N}(p_2 | \mu_2, \sigma_2^2 + \beta^2) \Phi(p_1 | \mu_b - p_2, \sigma_b^2) dp_2$$

$$\frac{\partial}{\partial p_1} m_{f_{t_a} \rightarrow p_1}(p_1) = \mathcal{N}(p_1 | \mu_b - \mu_2, \sigma_b^2 + \sigma_2^2 + \beta^2)$$


$$m_{f_{t_a} \rightarrow p_1}(p_1) = \Phi(p_1 | \mu_b - \mu_2, \sigma_b^2 + \sigma_2^2 + \beta^2)$$



$$m_{f_{p_1} \rightarrow s_1}(s_1) =$$




$$m_{f_{p_1} \rightarrow s_1}(s_1) = \int \mathcal{N}(p_1 | s_1, \beta^2) \Phi(p_1 | \mu_b - \mu_2, \sigma_b^2 + \sigma_2^2 + \beta^2) dp_1$$




$$m_{f_{p_1} \rightarrow s_1}(s_1) = \int \mathcal{N}(p_1 | s_1, \beta^2) \Phi(p_1 | \mu_b - \mu_2, \sigma_b^2 + \sigma_2^2 + \beta^2) dp_1$$

¿Sobre cuál variable derivamos?




$$m_{f_{p_1} \rightarrow s_1}(s_1) = \int \mathcal{N}(p_1 | s_1, \beta^2) \Phi(\mu_2 | \mu_b - p_1, \sigma_b^2 + \sigma_2^2 + \beta^2) dp_1$$

¿Sobre cuál variable derivamos?




$$m_{f_{p_1} \rightarrow s_1}(s_1) = \int \mathcal{N}(p_1 | s_1, \beta^2) \Phi(\mu_2 | \mu_b - p_1, \sigma_b^2 + \sigma_2^2 + \beta^2) dp_1$$

$$\frac{\partial}{\partial \mu_2} m_{f_{s_1} \rightarrow s_1}(s_1) =$$




$$m_{f_{p_1} \rightarrow s_1}(s_1) = \int \mathcal{N}(p_1 | s_1, \beta^2) \Phi(\mu_2 | \mu_b - p_1, \sigma_b^2 + \sigma_2^2 + \beta^2) dp_1$$

$$\frac{\partial}{\partial \mu_2} m_{f_{s_1} \rightarrow s_1}(s_1) = \int \mathcal{N}(p_1 | s_1, \beta^2) \mathcal{N}(p_1 | \mu_b - \mu_2, \sigma_b^2 + \sigma_2^2 + \beta^2) dp_1$$



$$m_{f_{p_1} \rightarrow s_1}(s_1) = \int \mathcal{N}(p_1|s_1, \beta^2) \Phi(\mu_2|\mu_b - p_1, \sigma_b^2 + \sigma_2^2 + \beta^2) dp_1$$


$$\frac{\partial}{\partial \mu_2} m_{f_{s_1} \rightarrow s_1}(s_1) = \mathcal{N}(s_1|\mu_b - \mu_2, \sigma_b^2 + \sigma_2^2 + 2\beta^2)$$




$$m_{f_{p_1} \rightarrow s_1}(s_1) = \int \mathcal{N}(p_1 | s_1, \beta^2) \Phi(\mu_2 | \mu_b - p_1, \sigma_b^2 + \sigma_2^2 + \beta^2) dp_1$$

$$\frac{\partial}{\partial \mu_2} m_{f_{s_1} \rightarrow s_1}(s_1) = \mathcal{N}(s_1 | \mu_b - \mu_2, \sigma_b^2 + \sigma_2^2 + 2\beta^2)$$


$$m_{f_{p_1} \rightarrow s_1}(s_1) = \Phi(s_1 | \mu_b - \mu_2, \sigma_b^2 + \sigma_2^2 + 2\beta^2)$$



$$p(s_1|r) \propto p(s_1, r) =$$



$$p(s_1|r) \propto p(s_1, r) = \mathcal{N}(s_1|\mu_1, \sigma_1^2) \Phi(s_1|\mu_b - \mu_2, \sigma_b^2 + \sigma_2^2 + 2\beta^2)$$



$$p(s_1|r) \propto p(s_1, r) = \underbrace{\mathcal{N}(s_1|\mu_1, \sigma_1^2)}_{\text{Prior}} \underbrace{\Phi(s_1|\mu_b - \mu_2, \sigma_b^2 + \sigma_2^2 + 2\beta^2)}_{\text{Verosimilitud}}$$

Verosimilitud

$$p(r|s_1) = \Phi(s_1|\mu_b - \mu_2, \sigma_b^2 + \sigma_2^2 + 2\beta^2)$$

Verosimilitud

$$p(r|s_1) = \Phi(s_1|\mu_b - \mu_2, \sigma_b^2 + \sigma_2^2 + 2\beta^2)$$

$$= \Phi(0|\mu_b - \mu_2 - s_1, \sigma_b^2 + \sigma_2^2 + 2\beta^2)$$

Verosimilitud

$$\begin{aligned} p(r|s_1) &= \Phi(s_1|\mu_b - \mu_2, \sigma_b^2 + \sigma_2^2 + 2\beta^2) \\ &= \Phi(0|\boldsymbol{\mu}_b - \mu_2 - s_1, \boldsymbol{\sigma}_b^2 + \sigma_2^2 + 2\beta^2) \end{aligned}$$

Verosimilitud

$$p(r|s_1) = \Phi(s_1|\mu_b - \mu_2, \sigma_b^2 + \sigma_2^2 + 2\beta^2)$$

$$= \Phi(0|\boldsymbol{\mu_3} + \boldsymbol{\mu_4} - \mu_2 - s_1, \boldsymbol{\sigma_3^2} + \boldsymbol{\sigma_4^2} + \boldsymbol{2\beta^2} + \sigma_2^2 + 2\beta^2)$$

Verosimilitud

$$\begin{aligned} p(r|s_1) &= \Phi(s_1|\mu_b - \mu_2, \sigma_b^2 + \sigma_2^2 + 2\beta^2) \\ &= \Phi(0 | (\mu_3 + \mu_4) - (s_1 + \mu_2), 4\beta^2 + \sigma_2^2 + \sigma_3^2 + \sigma_4^2) \\ &= \end{aligned}$$

Verosimilitud

$$\begin{aligned} p(r|s_1) &= \Phi(s_1|\mu_b - \mu_2, \sigma_b^2 + \sigma_2^2 + 2\beta^2) \\ &= \Phi(0|(\mu_3 + \mu_4) - (s_1 + \mu_2), 4\beta^2 + \sigma_2^2 + \sigma_3^2 + \sigma_4^2) \\ &= 1 - \Phi(0|(s_1 + \mu_2) - (\mu_3 + \mu_4), 4\beta^2 + \sigma_2^2 + \sigma_3^2 + \sigma_4^2) \end{aligned}$$

Verosimilitud


$$\begin{aligned} p(r|s_1) &= \Phi(s_1|\mu_b - \mu_2, \sigma_b^2 + \sigma_2^2 + 2\beta^2) \\ &= \Phi(0|(\mu_3 + \mu_4) - (s_1 + \mu_2), 4\beta^2 + \sigma_2^2 + \sigma_3^2 + \sigma_4^2) \\ &= 1 - \Phi(0|\underbrace{(s_1 + \mu_2) - (\mu_3 + \mu_4)}_{\substack{\text{Diferencia esperada} \\ \text{si la habilidad fuera } s_1}}, \underbrace{4\beta^2 + \sigma_2^2 + \sigma_3^2 + \sigma_4^2}_{\substack{\text{Incertidumbre total} \\ \text{salvo la de la habilidad } s_1}}) \end{aligned}$$

Evidencia vs Verosimilitud

$$p(r) = 1 - \Phi\left(0 \mid \underbrace{(\mu_1 + \mu_2) - (\mu_3 + \mu_4)}_{\text{Diferencia esperada}}, \underbrace{4\beta^2 + \sigma_1^2 + \sigma_2^2 + \sigma_3^2 + \sigma_4^2}_{\text{Incertidumbre total}}\right)$$


$$p(r|s_1) = 1 - \Phi\left(0 \mid \underbrace{(s_1 + \mu_2) - (\mu_3 + \mu_4)}_{\text{Diferencia esperada si la habilidad fuera } s_1}, \underbrace{4\beta^2 + \sigma_2^2 + \sigma_3^2 + \sigma_4^2}_{\text{Incertidumbre total salvo la de la habilidad } s_1}\right)$$

Predicciones del resultado
usando todas las hipótesis
pesadas por la creencia a prior




$$\overbrace{P(s_1 \mid r, \text{Modelo})}^{\text{Posterior}} \propto \overbrace{\mathcal{N}(s_1 \mid \mu_1, \sigma_1^2)}^{\text{Prior}} \overbrace{1 - \Phi(0 \mid \delta - \mu_1 + s_1, \vartheta^2 - \sigma_1^2)}^{\text{Verosimilitud}} \quad \text{Caso ganador}$$


$$\overbrace{P(s_1 \mid r, \text{Modelo})}^{\text{Posterior}} \propto \overbrace{\mathcal{N}(s_1 \mid \mu_1, \sigma_1^2)}^{\text{Prior}} \overbrace{1 - \Phi(0 \mid \delta - \mu_1 + s_1, \vartheta^2 - \sigma_1^2)}^{\text{Verosimilitud}} \quad \text{Caso ganador}$$




$$\overbrace{P(s_1 \mid r, \text{Modelo})}^{\text{Posterior}} \propto \overbrace{\mathcal{N}(s_1 \mid \mu_1, \sigma_1^2)}^{\text{Prior}} \overbrace{1 - \Phi(0 \mid \delta - \mu_1 + s_1, \vartheta^2 - \sigma_1^2)}^{\text{Verosimilitud}} \quad \text{Caso ganador}$$




$$\overbrace{P(s_1 \mid r, \text{Modelo})}^{\text{Posterior}} \propto \overbrace{\mathcal{N}(s_1 \mid \mu_1, \sigma_1^2)}^{\text{Prior}} \overbrace{1 - \Phi(0 \mid \delta - \mu_1 + s_1, \vartheta^2 - \sigma_1^2)}^{\text{Verosimilitud}} \quad \text{Caso ganador}$$




$$\overbrace{P(s_1 \mid r, \text{Modelo})}^{\text{Posterior}} \propto \overbrace{\mathcal{N}(s_1 \mid \mu_1, \sigma_1^2)}^{\text{Prior}} \overbrace{1 - \Phi(0 \mid \delta - \mu_1 + s_1, \vartheta^2 - \sigma_1^2)}^{\text{Verosimilitud}} \quad \text{Caso ganador}$$




$$\overbrace{P(s_1 \mid r, \text{Modelo})}^{\text{Posterior}} \propto \overbrace{\mathcal{N}(s_1 \mid \mu_1, \sigma_1^2)}^{\text{Prior}} \overbrace{1 - \Phi(0 \mid \delta - \mu_1 + s_1, \vartheta^2 - \sigma_1^2)}^{\text{Verosimilitud}} \quad \text{Caso ganador}$$



$$\overbrace{P(s_1 \mid r, \text{Modelo})}^{\text{Posterior}} \propto \overbrace{\mathcal{N}(s_1 \mid \mu_1, \sigma_1^2)}^{\text{Prior}} \overbrace{1 - \Phi(0 \mid \delta - \mu_1 + s_1, \vartheta^2 - \sigma_1^2)}^{\text{Verosimilitud}} \quad \text{Caso ganador}$$



$$\overbrace{P(s_3 \mid r, \text{Modelo})}^{\text{Posteriori}} \propto \overbrace{N(s_3 \mid \mu_3, \sigma_2^2)}^{\text{Priori}} \overbrace{\Phi(0 \mid \delta - \mu_3 - s_3, \vartheta^2 - \sigma_3^2)}^{\text{Verosimilitud}} \quad \text{Caso perdedor}$$



TrueSkill

Posterior aproximado

$$\underbrace{\hat{p}(s_a | \text{Gana}, M)}_{\text{Aproximado}} = \arg \min_{\mu, \sigma} \mathcal{D}_{KL} \left(\underbrace{p(s_a | \text{Gana}, M)}_{\text{Exacto}} \parallel \underbrace{\mathcal{N}(s_a | \mu, \sigma^2)}_{\text{Familia}} \right)$$

Mínima Divergencia

Posterior aproximado


$$\underbrace{\hat{p}(s_a|\text{Gana}, M)}_{\text{Aproximado}} = \arg \min_{\mu, \sigma} \mathcal{D}_{KL} \left(\underbrace{p(s_a|\text{Gana}, M)}_{\text{Exacto}} \parallel \underbrace{\mathcal{N}(s_a|\mu, \sigma^2)}_{\text{Familia}} \right)$$

$$\mathcal{D}_{KL}(\text{Exacta}||\text{Familia}) = \sum_{s_a} p(s_a|\text{Gana}, M) \cdot \left(\log p(s_a|\text{Gana}, M) - \log \mathcal{N}(s_a|\mu, \sigma^2) \right)$$

Mínima Divergencia

Posterior aproximado

$$\underbrace{\hat{p}(s_a|\text{Gana}, M)}_{\text{Aproximado}} = \arg \min_{\mu, \sigma} \mathcal{D}_{KL} \left(\underbrace{p(s_a|\text{Gana}, M)}_{\text{Exacto}} \parallel \underbrace{\mathcal{N}(s_a|\mu, \sigma^2)}_{\text{Familia}} \right)$$



Mínima Divergencia

Posterior aproximado

$$\underbrace{\hat{p}(s_a | \text{Gana}, M)}_{\text{Aproximado}} = \arg \min_{\mu, \sigma} \mathcal{D}_{KL} \left(\underbrace{p(s_a | \text{Gana}, M)}_{\text{Exacto}} \parallel \underbrace{\mathcal{N}(s_a | \mu, \sigma^2)}_{\text{Familia}} \right)$$

$$p(d, \text{Gana} \mid \text{Modelo}) =$$

$$\underbrace{\hspace{10em}}_{\text{Marginal exacta}}$$

Mínima Divergencia

Posterior aproximado


$$\underbrace{\hat{p}(s_a | \text{Gana}, M)}_{\text{Aproximado}} = \arg \min_{\mu, \sigma} \mathcal{D}_{KL} \left(\underbrace{p(s_a | \text{Gana}, M)}_{\text{Exacto}} \parallel \underbrace{\mathcal{N}(s_a | \mu, \sigma^2)}_{\text{Familia}} \right)$$

$$\underbrace{p(d, \text{Gana} \mid \text{Modelo})}_{\text{Marginal exacta}} = \underbrace{\int_{s_a} \int_{p_a} \int_{s_b} \int_{p_b} p(s_a) p(s_b) p(p_a | s_a) p(p_b | s_b) p(d | p_a, p_b) P(\text{Gana} | d)}_{\text{Prior exacto } p(d) = \mathcal{N}(d \mid \underbrace{\mu_a - \mu_b}_{\text{Diferencia de medias}}, \underbrace{\sigma_a^2 + \sigma_b^2 + 2\beta^2}_{\text{Suma de incertidumbres})}$$

Mínima Divergencia

Posterior aproximado


$$p(d, \text{Gana}) = \mathcal{N}(d | \mu_a - \mu_b, \sigma_a^2 + \sigma_b^2 + 2\beta^2) \mathbb{I}(d > 0)$$



Mínima Divergencia

Posterior aproximado


$$p(d, \text{Gana}) = \mathcal{N}(d | \mu_a - \mu_b, \sigma_a^2 + \sigma_b^2 + 2\beta^2) \mathbb{I}(d > 0)$$



Mínima Divergencia

Posterior aproximado

$$p(d, \text{Gana}) = \mathcal{N}(d | \mu_a - \mu_b, \sigma_a^2 + \sigma_b^2 + 2\beta^2) \mathbb{I}(d > 0)$$



Mínima Divergencia

Posterior aproximado

$$p(d, \text{Gana}) = \mathcal{N}(d | \mu_a - \mu_b, \sigma_a^2 + \sigma_b^2 + 2\beta^2) \mathbb{I}(d > 0)$$

$$\hat{p}(d, \text{Gana}) \propto \mathcal{N}\left(d \mid \underbrace{E(d, \text{Gana} | d > 0)}_{\text{Misma media}}, \underbrace{V(d, \text{Gana} | d > 0)}_{\text{Misma varianza}}\right)$$

Mínima Divergencia

Posterior aproximado

$$p(d, \text{Gana}) = \mathcal{N}(d | \mu_a - \mu_b, \sigma_a^2 + \sigma_b^2 + 2\beta^2) \mathbb{I}(d > 0)$$

$$\hat{p}(d, \text{Gana}) \propto \mathcal{N}\left(d \mid \underbrace{E(d, \text{Gana} | d > 0)}_{\text{Misma media}}, \underbrace{V(d, \text{Gana} | d > 0)}_{\text{Misma varianza}}\right)$$

La divergencia es mínima cuando tienen mismos momentos.
(Expectation Propagation)

Mínima Divergencia

Aproximación del posterior de la diferencia

$$p(d, \text{Gana}) = m_{f_d \rightarrow d}(d) m_{f_r \rightarrow d}(d)$$

Mínima Divergencia

Aproximación del posterior de la diferencia

$$p(d, \text{Gana}) = m_{f_d \rightarrow d}(d) m_{f_r \rightarrow d}(d)$$

$$m_{f_r \rightarrow d}(d) = m_{d \rightarrow f_d}(d)$$

Mínima Divergencia

Aproximación del posterior de la diferencia

$$p(d, \text{Gana}) = m_{f_d \rightarrow d}(d) m_{d \rightarrow f_d}(d)$$

Mínima Divergencia

Aproximación del posterior de la diferencia

$$p(d, \text{Gana}) = \underbrace{m_{f_d \rightarrow d}(d)}_{P(d)} m_{d \rightarrow f_d}(d)$$

Mínima Divergencia

Aproximación del posterior de la diferencia

$$p(d, \text{Gana}) = \underbrace{m_{f_d \rightarrow d}(d)}_{P(d)} m_{d \rightarrow f_d}(d)$$

$$m_{d \rightarrow f_d}(d) = \frac{p(d, \text{Gana})}{p(d)}$$

Mínima Divergencia

Aproximación del posterior de la diferencia

$$p(d, \text{Gana}) = \underbrace{m_{f_d \rightarrow d}(d)}_{P(d)} m_{d \rightarrow f_d}(d)$$

$$m_{d \rightarrow f_d}(d) = \frac{p(d, \text{Gana})}{p(d)} \approx \frac{\hat{p}(d, \text{Gana})}{p(d)}$$

Mínima Divergencia

Aproximación del posterior de la diferencia

$$p(d, \text{Gana}) = \underbrace{m_{f_d \rightarrow d}(d)}_{P(d)} m_{d \rightarrow f_d}(d)$$

$$\begin{aligned} m_{d \rightarrow f_d}(d) &= \frac{p(d, \text{Gana})}{p(d)} \approx \frac{\hat{p}(d, \text{Gana})}{p(d)} \\ &= \frac{\mathcal{N}(d | \hat{\delta}, \hat{\vartheta}^2)}{\mathcal{N}(d | \delta, \vartheta^2)} \end{aligned}$$


Mínima Divergencia

Aproximación del posterior de la diferencia


$$p(d, \text{Gana}) = \underbrace{m_{f_d \rightarrow d}(d)}_{P(d)} m_{d \rightarrow f_d}(d)$$

$$\begin{aligned} m_{d \rightarrow f_d}(d) &= \frac{p(d, \text{Gana})}{p(d)} \approx \frac{\hat{p}(d, \text{Gana})}{p(d)} \\ &= \frac{\mathcal{N}(d | \hat{\delta}, \hat{\vartheta}^2)}{\mathcal{N}(d | \delta, \vartheta^2)} \propto \mathcal{N}(d | \delta_{\div}, \vartheta_{\div}^2) \end{aligned}$$


$$\text{con } \delta_{\div} = \frac{\hat{\delta}}{\hat{\vartheta}^2} - \frac{\delta}{\vartheta^2} \text{ y } \vartheta_{\div}^2 = \left(\frac{1}{\hat{\vartheta}^2} - \frac{1}{\vartheta^2} \right)^{-1}$$




$$\hat{m}_{f_d \rightarrow t_a}(t_a) \approx \iint \mathbb{I}(d = t_a - t_b) \mathcal{N}(d | \delta_{\div}, \vartheta_{\div}^2) \mathcal{N}(t_b | \mu_b, \sigma_b^2) dd dt_b$$




$$\begin{aligned}
 \hat{m}_{f_d \rightarrow t_a}(t_a) &\approx \iint \mathbb{I}(d = t_a - t_b) \mathcal{N}(d | \delta_{\div}, \vartheta_{\div}^2) \mathcal{N}(t_b | \mu_b, \sigma_b^2) dd dt_b \\
 &= \int \mathcal{N}(t_a - t_b | \delta_{\div}, \vartheta_{\div}^2) \mathcal{N}(t_b | \mu_b, \sigma_b^2) dt_b
 \end{aligned}$$




$$\begin{aligned}
 \hat{m}_{f_d \rightarrow t_a}(t_a) &\approx \iint \mathbb{I}(d = t_a - t_b) \mathcal{N}(d | \delta_{\div}, \vartheta_{\div}^2) \mathcal{N}(t_b | \mu_b, \sigma_b^2) dd dt_b \\
 &= \int \mathcal{N}(t_a - t_b | \delta_{\div}, \vartheta_{\div}^2) \mathcal{N}(t_b | \mu_b, \sigma_b^2) dt_b \\
 &= \mathcal{N}(t_a | \mu_b + \delta_{\div}, \vartheta_{\div}^2 + \sigma_b^2)
 \end{aligned}$$




$$\widehat{m}_{f_{t_a} \rightarrow p_1}(p_1) = \iint \mathbb{I}(t_a = p_1 + p_2) \mathcal{N}(t_a | \mu_b + \delta_{\div}, \vartheta_{\div}^2 + \sigma_b^2) \mathcal{N}(p_2 | \mu_2, \sigma_2^2 + \beta^2) dt_a dp_2$$




$$\begin{aligned}
 \hat{m}_{f_{t_a} \rightarrow p_1}(p_1) &= \iint \mathbb{I}(t_a = p_1 + p_2) \mathcal{N}(t_a \mid \mu_b + \delta_{\div}, \vartheta_{\div}^2 + \sigma_b^2) \mathcal{N}(p_2 \mid \mu_2, \sigma_2^2 + \beta^2) dt_a dp_2 \\
 &= \int \mathcal{N}(p_1 + p_2 \mid \mu_b + \delta_{\div}, \vartheta_{\div}^2 + \sigma_b^2) \mathcal{N}(p_2 \mid \mu_2, \sigma_2^2 + \beta^2) dp_2
 \end{aligned}$$



$$\begin{aligned}
 \hat{m}_{f_{t_a} \rightarrow p_1}(p_1) &= \iint \mathbb{I}(t_a = p_1 + p_2) \mathcal{N}(t_a | \mu_b + \delta_{\div}, \vartheta_{\div}^2 + \sigma_b^2) \mathcal{N}(p_2 | \mu_2, \sigma_2^2 + \beta^2) dt_a dp_2 \\
 &= \int \mathcal{N}(p_1 + p_2 | \mu_b + \delta_{\div}, \vartheta_{\div}^2 + \sigma_b^2) \mathcal{N}(p_2 | \mu_2, \sigma_2^2 + \beta^2) dp_2 \\
 &= \mathcal{N}(p_1 | \underbrace{\mu_b - \mu_2 + \delta_{\div}}_{\mu_1 - \delta}, \underbrace{\vartheta_{\div}^2 + \sigma_b^2 + \sigma_2^2 + \beta^2}_{\vartheta^2 - (\sigma_1^2 + \beta^2)})
 \end{aligned}$$



$$\hat{m}_{f_{p_1} \rightarrow s_1}(s_1) = \int \mathcal{N}(p_1 | s_1, \beta^2) \mathcal{N}(p_1 | \mu_1 - \delta + \delta_{\div}, \vartheta_{\div}^2 + \vartheta^2 - \sigma_1^2 - \beta^2) dp_1$$



$$\begin{aligned}
 \hat{m}_{f_{p_1} \rightarrow s_1}(s_1) &= \int \mathcal{N}(p_1 | s_1, \beta^2) \mathcal{N}(p_1 | \mu_1 - \delta + \delta_{\div}, \vartheta_{\div}^2 + \vartheta^2 - \sigma_1^2 - \beta^2) dp_1 \\
 &= \mathcal{N}(s_1 | \mu_1 - \delta + \delta_{\div}, \vartheta_{\div}^2 + \vartheta^2 - \sigma_1^2)
 \end{aligned}$$

Posterior aproximado

$$\hat{p}(s_1, r) = \mathcal{N}(s_1 | \mu_1, \sigma_1^2) \mathcal{N}(s_1 | \mu_1 - \delta + \delta_{\div}, \vartheta_{\div}^2 + \vartheta^2 - \sigma_1^2)$$

$p = \mathbf{b}$

Laboratorios de
Métodos Bayesianos

Bibliografía Unidad 4

- Bishop, C. **Pattern Recognition and Machine Learning**. 2006. ([Descargar](#)).
(lectura 8.1, 8.2 y 8.4)
- Neal. **Pattern Recognition and Machine Learning**. 2020 (Draft). ([Descargar](#)).
(lectura capítulo 1 y 3)