

Práctica 5.

Modelos lineales (o polinomiales).

Docente: Gustavo Landfried

Inferencia Bayesiana Causal 1
2do cuatrimestre 2025
UNSAM

1. Modelos polinomiales de complejidad creciente.

Pueden usar cualquier librería que implemente: 1. la regresión lineal por mínimos cuadrados (máxima verosimilitud); y 2. la regresión lineal bayesiana. En el primer caso proponemos el uso del métodos OLS de la librería `statsmodels`, en particular los métodos `fit()` que selecciona las hipótesis (atributo `params`) y el logaritmo del likelihood del modelo (atributo `llf`). En el segundo caso proponemos de la librería contenida en el archivo `ModeloLineal.py`, incluido en los materiales de esta práctica, y en particular los métodos `posterior()` que devuelve la media y la covarianza de los hipótesis y `log_evidence()` que devuelve la predicción que hace el modelo del conjunto de datos en escala logarítmica. Ambos librerías tienen un uso similar.

```
from statsmodels.api import OLS
import ModeloLineal as ml      # El archivo ModeloLineal.py debe estar en la misma carpeta
...
N = 20
X = np.random.rand(N,1)-0.5
Y = realidad_causal_subyacente(X)
assert Y.shape == (20,1)

# Transformacion de los X
def phi(X, complejidad):
    return(pd.DataFrame({'X{d}': X[:, 0]**d for d in range(complejidad+1)}))

assert phi(X, 2).shape == (20,3)

modelo = OLS(Y, phi(X,2)).fit()
modelo.params # La hipotesis seleccionadas
modelo.llf    # El likelihood del modelo en escala logaritmica

MU_2, COV_2 = ml.posterior(Y, phi(X, 2))
log_evidence_2 = ml.log_evidence(Y, phi(X, 2))
```

La gran mayoría de los modelos de inteligencia artificial, incluyendo las redes neuronales [?], se construyen a partir de modelos que postulan relaciones “lineales” entre las hipótesis. El modelo más básico es la famosa regresión lineal. Dado un conjunto de datos $\{(x_1, y_1), \dots, (x_T, y_T)\}$, un modelo causal lineal afirma que el valor de la variable y_i se generar en función de x_i y un conjunto

de hipótesis ocultas h , tal que

$$y \leftarrow h_0 + h_1 \cdot x$$

h_0 representa el valor base de y cuando x es neutral ($x = 0$), y h_1 representa el efecto causal que la variable x tiene sobre y , el cual es proporcional a su propio valor ($h_1 \cdot x$), dando una relación lineal entre el valor de la causa x y el valor de su efecto y . De modo similar, podemos construir relaciones más complejas, como son los polinomios de grado M .

$$y \leftarrow h_0 + h_1 \cdot x + h_2 \cdot x^2 + \dots + h_M \cdot x^M = \sum_{i=0}^M h_i \cdot x^i$$


Es interesante notar que un polinomio de grado $M - 1$ es un caso especial de un polinomio de grado M en el que el $h_M = 0$. Es decir, cuánto más complejo sea el polinomio, más flexibilidad tiene el modelo para representar la relación entre x e y . Debido a que los datos se miden con un error que se produce con desvío estándar β centrado en cero, la probabilidad condicional de observar un dato es,

$$p(y|x, \mathbf{h}, \text{Modelo} = M) = \mathcal{N}\left(y \mid \sum_{i=0}^M h_i \cdot x^i, \beta^2\right)$$

Como tenemos incertidumbre respecto de los valores de las hipótesis h_i , proponemos una distribución que creencias *a priori* alrededor del cero.

$$p(h_i) = \mathcal{N}(h_i \mid 0, \alpha_i^2)$$

Luego, la especificación gráfica del modelo lineal es



Quisiéramos actualizar nuestra creencia respecto de las hipótesis h al interior de cada modelo y actualizar nuestra creencia sobre los modelos causales alternativos. Ninguno de estas dos objetivos se pudo realizar de forma exacta hasta las vísperas del siglo 21. En este ejercicio nos interesa comparar los resultados que se obtienen mediante los métodos propuestos durante el siglo 20, basados en estimadores puntuales, respecto de los resultado que se obtienen de evaluar todo el espacio de hipótesis (y modelos) mediante la aplicación estricta de las reglas de la probabilidad. En el primer caso usaremos el método OLS (por *Ordinary Least Squares*) del paquete `statsmodels` y para el segundo caso usaremos nuestra propia implementación disponible en el archivo `ModeloLineal.py`¹.

1.1. Generar 20 datos alrededor de una período de una sinoidal

Supongamos que los datos se generan de una realidad causal subyacente completamente distinta, siguiendo una función sinoidal en el rango $x \in [-\frac{1}{2}, \frac{1}{2}]$.

$$p(x) = \text{Unif}(x \mid -0,5, 0,5)$$

$$p(y|x) = \mathcal{N}(y \mid \sin(2\pi x), \beta^2)$$

Al graficar la función objetivo (línea) y los datos (puntos) se soberva lo siguiente.

¹La derivación matemática de la regresión lineal la pueden encontrar en el capítulo 2 del libro de Bishop PRML. El presente ejercicio está extraído del capítulo 3 del mismo libro.





Figura 1: Datos generados de la “función objetivo” (realidad causal subyacente)

1.2. Graficar el valor de máxima verosimilitud obtenido por los modelos polinomiales de grado 0 a 9

Debido a la complejidad computacional de la aplicación estricta de las reglas de la probabilidad, durante el siglo 20 se propusieron una gran cantidad de criterios arbitrarios para la selección de una única hipótesis del espacio, como es el principio de máxima verosimilitud.

$$\arg \max_h p(\mathbf{y}|\mathbf{x}, \mathbf{h}, M_M) \stackrel{*}{=} \arg \min_h \sum_{j \in \{1, \dots, N\}} (y_j - \sum_i^M h_i \cdot x_j^i)^2$$

Por propiedades de este tipo de modelos ($\stackrel{*}{=}$) encontrar las hipótesis que mejor predicen es lo mismo que minimizar la suma de las distancias cuadradas entre el verdadero valor y el valor medio propuesto. Al graficar el valor de máxima verosimilitud obtenido con cada uno de los modelos veremos que a medida que aumentamos la complejidad de los modelos aumenta también el valor de máxima verosimilitud.



Esto ocurre debido a que cuanto más flexible es un modelo, más se puede acercar a todos los puntos. Por lo tanto, si usamos el criterio de máxima verosimilitud para seleccionar modelo, elegiríamos siempre el modelo más complejo.

1.3. Graficar las curvas obtenidas con cada modelo mediante máxima verosimilitud.

Seleccionar el modelo de mayor complejidad no es deseable. Para ver por qué, vamos a graficar las curvas obtenidas por cada uno de los modelos de grado 0 a 9.




Figura 3: Ajuste de los polinomios por máxima verosimilitud.

En la figura 3a podemos ver que los modelos de grado 0 a 2 no tienen la complejidad suficiente para acercarse a los datos como lo hacen los modelos de complejidad 3 o superior. En la figura 3b destacamos la curva que se obtiene con el modelo más complejo, de grado 9.

A diferencia del modelo 3 (color rojo en figura 3a) que se mantiene cerca de la función objetivo, el modelo de grado 9 se separa significativamente de la función objetivo alrededor de los valores $x = 0,3$ y $x = 0,5$. La excesiva flexibilidad hace que los modelos más complejos adopten formas extrañas que suelen alejarse más de la función objetivo oculta, por lo que la predicción sobre nuevos datos del modelo 3 termina siendo superior al del modelo 9 que habíamos elegido por máxima verosimilitud.

Esto se conoce y se conoce en el área de inteligencia artificial con el nombre de sobreajuste o *overfitting* y veremos que es efecto secundario de utilizar métodos arbitrarios de selección de hipótesis (como máxima verosimilitud) y no una propiedad indeseable del sistema de razonamiento probabilístico.

1.4. Evaluación de la predicción “en línea” que hacen los modelos ajustados por máxima verosimilitud.

Para evaluar correctamente los modelos alternativos deberíamos calcular la evidencia de los modelos ($P(\text{Datos}|\text{Modelo})$), que no es más que la predicción *a priori* que hace el modelo de todos los datos, lo que es lo mismo que el producto de las predicciones individuales del siguiente dato usando los datos ya observados como información previa.

$$P(\text{Datos} = \{d_1, d_2, \dots\} | M_D) = P(d_1 | M_D) P(d_2 | d_1, M_D) \dots$$

Este producto de predicciones representa lo que nos ocurriría efectivamente si usáramos el modelo en la vida real: ajustamos el modelo con los datos que ya tenemos disponibles (entrenamiento) y evaluamos el desempeño en los datos nuevos (testeo). Para simular este proceso, vamos a implementar un procedimiento en el cual predecimos los datos individuales ajustando los modelos por máxima verosimilitud sobre los datos observados previamente.




Figura 4: Producto de las predicciones a priori de los modelos ajustados por máxima verosimilitud.

Si evaluáramos los modelos en base al desempeño predictivo, dado por el producto de las predicciones a priori, rechazaríamos todos los modelos salvo el de grado 3. Esto también es un caso de sobreajuste (overfitting), pues en caso de recibir datos por fuera del período, tendríamos bajo desempeño predictivo debido a que el modelo de grado 3 no tendrá la flexibilidad suficiente para acercarse a la función objetivo. El problema del sobreajuste (overfitting) ocurre como efecto secundario de seleccionar una única hipótesis del espacio y no poder computar de forma exacta la evidencia de los modelos, $P(\text{Datos}|\text{Modelo})$.

Cuando seleccionamos de forma arbitraria una única hipótesis no podemos computar la evidencia de los modelos, $P(\text{Datos}|\text{Modelo})$, debido a que las predicciones que hacen los modelos debería realizarse con la contribución de todas las hipótesis, y no con una única hipótesis seleccionada previamente.

$$\begin{aligned}
 P(y_i | \underbrace{x_1, y_1, \dots, x_{i-1}, y_{i-1}}_{d_1}, x_i, M_D) &= \int_{\mathbf{h}} P(y_i | d_1, \dots, d_{i-1}, x_i, \mathbf{h}, M_D) P(\mathbf{h} | d_1, \dots, d_{i-1}, M_D) \\
 &\approx P(y_i | d_1, \dots, d_{i-1}, x_i, \underbrace{\arg \max_{\mathbf{h}} P(d_1, \dots, d_{i-1} | \mathbf{h}, M_D)}_{\text{Hipótesis de máxima verosimilitud}}, M_D)
 \end{aligned}$$

Es decir, aproximamos las predicciones que deberían hacer los modelos con la contribución de todas las hipótesis mediante la predicción que obtenemos con la hipótesis que maximizaba la verosimilitud en el paso anterior.

1.5. El balance natural de las reglas de la probabilidad.

Para evaluar correctamente las hipótesis y modelos causales alternativos es suficiente con actualizar las creencias aplicando estrictamente las reglas de la probabilidad. Para eso necesitamos calcular la probabilidad a posteriori de los modelos dado los datos.

$$P(\text{Modelo} = m | \text{Datos}) = \frac{\overbrace{P(\text{Datos} | \text{Modelo} = m) P(\text{Modelo} = m)}^{\text{Evidencia}}}{\sum_i P(\text{Datos} | \text{Modelo} = i) P(\text{Modelo} = i)}$$

Para calcular de forma exacta la evidencia del modelo (en órdenes de magnitud) podemos usar el método `lm.log_evidence()` de nuestro paquete `ModeloLineal.py`. Suponiendo que no tenemos preferencia a priori por ningún modelo, vamos a usar la evidencia para calcular el posterior exacto de los modelos.




Figura 5: Posterior exacto de los modelos.

Cuando evaluamos correctamente las hipótesis, encontramos que: el modelo que tiene la menor complejidad necesaria (grado 3) es el que obtiene mayor creencia a posteriori; los modelos que tienen menor complejidad de la necesaria (grado 0 a 2) son rechazados; y los modelos que tienen mayor complejidad de la necesaria (grado 4 a 9) tienen baja probabilidad, pero no son rechazados. A diferencia de lo que ocurría cuando seleccionábamos hipótesis de forma arbitraria, evaluando correctamente las hipótesis garantizamos nuestra capacidad para predecir potenciales datos que aparecieran en el futuro por fuera del período observado gracias a que tenemos disponibles todavía modelos más complejos capaces de explicarlos.

$$P(\text{Datos}) = \sum_m P(\text{Datos}|\text{Modelo} = m)P(\text{Modelo} = m)$$

En definitiva, los problemas que emergen cuando se seleccionan las hipótesis mediante criterios arbitrarios simplemente no forman parte del sistema de razonamiento en contextos de incertidumbre. Por eso, la aplicación estricta de las reglas de la probabilidad, siguiendo el principio de "no mentir", es el razonamiento óptimo en contextos de incertidumbre.

1.6. Cómo se explica el balance natural de las reglas de la probabilidad

En probabilidad las predicciones son distribuciones de probabilidad que deben integrar 1. Esto produce un balance natural entre los modelos debido a que ningún modelo es superior a otro en términos absolutos. Todos los modelos tienen una región en donde ganan y todos tienen una región en donde pierden. Veamos esto de forma concreta.

En la figura 6a graficamos la media del posterior de los modelos basado en un prior no informativo. No estamos graficando la incertidumbre de los modelos, que representaría la predicción que hacen los modelos de los datos. Para graficar esa incertidumbre vamos a hacer un corte en la figura 6a cuando x vale $-0,23$ (línea vertical).




Figura 6: El balance natural entre modelos

En la figura 6b hacemos un corte en línea punteada ($x = -0,23$) y graficamos la predicción que hace el modelo más rígido (grado 0), el modelo simple (grado 3) y el modelo más complejo (grado 9) luego de ver el cuarto dato, vamos a observar tres distribuciones gaussianas con diferente media y diferente desvío estándar. Podemos ver que el modelo más rígidos (grado 0) concentra su creencia en una región lejana al valor verdadero. Los modelos simples (grado 3) y complejo (grado 9) distribuyen su creencia alrededor del verdadero valor pero de forma distinta: cuanto mayor flexibilidad tienen los modelos, mayor tendencia a distribuir la creencia en una región más amplia de valores posibles. En términos un poco más esquemáticos (con $x = 0,1$) lo que ocurre es.




Figura 7: Esquema de la predicción de los modelos

De esta forma, el modelo rígido se rechaza por su incapacidad de llevar su creencia a la región correcta. Pero entre el modelo simple y el modelo complejo hay un balance en el cual existen ciertas regiones donde el modelo simple gana y ciertas regiones donde el modelo más complejo gana.

2. Efecto causal del sexo biológico sobre la altura.

Vamos a utilizar un conjunto de datos sobre alturas de un grupo de personas y 3 variables adicionales: sexo biológico, contextura de la madre, y altura de la madre. En este ejemplo vamos a proponer modelos causales alternativos entre estas variables.

2.1. Abrir el archivo alturas.csv y visualizar los datos

El archivo de datos tiene la siguiente estructura,.

```
id altura sexo contextura_madre altura_madre
0 1 172.7 M mediana 159.8
1 2 171.5 M mediana 160.3
```

2	3	162.6	F	mediana	160.5
3	4	174.1	M	mediana	159.8
4	5	168.3	M	mediana	158.3




Figura 8: Datos de alturas

2.2. Definir 3 modelos causales alternativos

Si bien los datos son de dudosa procedencia, vamos a jugar un juego de inferencia causal. Vamos a proponer y evaluar tres modelos causales alternativos. En el modelo base vamos a suponer que la altura de la madre tienen un efecto causal lineal sobre la altura de su descendencia.

$$\text{Modelo Base: } \text{altura} = h_0 + h_1 \cdot \text{altura_madre}$$

En el modelo biológico vamos a suponer que el sexo tiene un efecto causal adicional sobre la altura.

$$\text{Modelo Biológico: } \text{altura} = h_0 + h_1 \cdot \text{altura_madre} + h_2 \cdot \mathbb{I}(\text{sexo} = F)$$

Cuando el sexo es masculino, la función identidad $\mathbb{I}(\text{sexo} = M)$ vale 1 y en caso contrario vale 0, lo que prende y apaga la hipótesis h_2 , que representa el efecto causal adicional del sexo biológico.

Por último vamos a plantear el modelo identitario, en el que vamos a suponer que la identidad de la persona (y no el sexo) tiene efecto causal sobre la altura.

$$\text{Modelo grupos al azar: } \text{altura} = h_0 \cdot \text{altura_madre} + h_{1+(\text{ID} \bmod (\max(\text{ID})/2))}$$

Notar que los grupos al azar son todos de tamaño 2 y que cada grupo tiene su propia ordenada al origen pero comparten la misma pendiente. Es decir, cuando queramos usar `OLS(Y,phi)` o `log_evidence(Y,phi)`, el `phi` va a ser una matriz con 26 columnas: la primera con la altura de la madre y las siguientes 25 columnas con 0 y 1, indicando quién pertenece a un determinado grupo.

2.3. Computar la evidencia de los modelos causales alternativos

En la siguiente figura graficamos los órdenes de magnitud de evidencia ($P(\text{Datos}|\text{Modelo})$) de los 3 modelos causales alternativos.




Figura 9: Evidencia en escala logarítmica de los modelos causales alternativos

2.4. Computar la media geométrica de los modelos causales alternativos

La media geométrica

$$P(\text{Datos} = \{d_1, d_2, \dots, d_N\} | M) = P(d_1 | M) P(d_2 | d_1, M) \dots = \prod_{i \in \{1, \dots, N\}} \underbrace{(P(d_1 | M) P(d_2 | d_1, M) \dots)^{1/N}}_{\text{Media geométrica}}$$

2.5. Computar el posterior de los modelos

$$P(\text{Modelo} | \text{Datos}) = \frac{P(\text{Datos} | \text{Modelo}) P(\text{Modelo})}{P(\text{Datos})}$$

3. Predicciones sin correlaciones espurias

En la Tabla 1 se puede ver un resumen de las estructuras básicas en el flujo de asociación, donde el símbolo $\perp\!\!\!\perp$ denota independencia entre variables.

Cuadro 1: Resumen de las estructuras básicas del flujo de asociación

		Intermedio no observable	Intermedio observable
Fork:	$x \leftarrow w \rightarrow y$	$x \not\perp\!\!\!\perp y$	$x \perp\!\!\!\perp y w$
Pipe:	$x \rightarrow w \rightarrow y$	$x \not\perp\!\!\!\perp y$	$x \perp\!\!\!\perp y w$
Collider:	$x \rightarrow w \leftarrow y$	$x \perp\!\!\!\perp y$	$x \not\perp\!\!\!\perp y w$

El comportamiento de estas tres estructuras permite determinar cuándo los extremos de una cadena están asociados.

Definición 3.1 (*d-separation*). Hay asociación entre los extremos de una cadena (camino *d-conectado*) si se cumplen simultáneamente las siguientes condiciones.

- Todas las consecuencias comunes o *colliders* (o sus descendientes) son observables
- Ninguna otra variable es observable

Y no hay asociación (camino “d-separado”) cuando no se cumple alguna de las condiciones, es decir, cuando al menos un *collider* no es observado o al menos otra variable es no observada.

Uno de los objetivos principales del área de inferencia causal es estimar efectos causales en datos observados en los que no se ejecutó ningún tipo de experimento aleatorizado. Intuitivamente, las asociaciones espurias entre las variables tratamiento y objetivo, Z e Y , circulan a través de todos


los caminos ascendentes (no causales) que van de Z a Y . Por otro lado, la asociación no espuria entre Z e Y fluye por los caminos causales (de estructura pipe, descendente en todos los saltos) que conectan Z e Y . Esto motiva la definición del criterio *backdoor* para definir variables de control.

Definición 3.2 (*Backdoor criterion*). Un conjunto de variables Q satisface el backdoor criterion relativo a las variable Y y Z en un DAG si:

- Q cierra todos los caminos ascendentes de Z e Y (caminos no causales).
- Q no contiene ninguna variable descendente de Z a Y (caminos causales).

3.1. Realidad causal compleja

Hacer una predicción son correlaciones espurias mediante una regresión lineal.




```

1 N = 1000
2 z1 = np.random.uniform(-3,3, size=N)
3 w1 = 3*z1 + np.random.normal(size=N,scale=1)
4 z2 = np.random.uniform(-3,3, size=N)
5 w2 = 2*z2 + np.random.normal(size=N,scale=1)
6 z3 = -2*z1 + 2*z2 + np.random.normal(size=N,scale=1)
7 x = -1*w1 + 2*z3 + np.random.normal(size=N,scale=1)
8 w3 = 2*x + np.random.normal(size=N,scale=1)
9 y = 2 - 1*w3 - z3 + w2 + np.random.normal(size=N,scale=1)

```

3.2. Table 2 falacy

Hacer una predicción sin correlaciones espurias para el flujo de inferencia entre S e Y .



```

1 N = 1000
2 u = np.random.uniform(-3,3, size=N)
3 e = np.random.uniform(-3,3, size=N)
4 f = 3*u - 2*e + np.random.normal(size=N,scale=0.5)

```

```
5  s = e + 2*f + np.random.normal(size=N,scale=0.5)
6  y = u + 2*e + 3*f - 2*s + np.random.normal(size=N,scale=0.5)
```

4. Anexo. Gaussiana multivariada

La distribución gaussiana multivariada del vector D -dimensional $\mathbf{x}$ es

$$\mathcal{N}(\mathbf{x}|\boldsymbol{\mu}, \boldsymbol{\Sigma}) = \frac{1}{(2\pi)^{D/2}} \frac{1}{|\boldsymbol{\Sigma}|^{1/2}} \exp\left(-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1}(\mathbf{x} - \boldsymbol{\mu})\right)$$

donde $\boldsymbol{\mu}$ es un vector D -dimensional que representa la media, $\boldsymbol{\Sigma}$ es una matriz $D \times D$ que representa la covarianza y $|\boldsymbol{\Sigma}|$ su determinante.

4.1. Distribuciones condicionales y marginales

Dado la distribución conjunta

$$p(\mathbf{x}) = \mathcal{N}(\mathbf{x}|\boldsymbol{\mu}, \boldsymbol{\Sigma})$$

tal que

$$\mathbf{x} = \begin{pmatrix} \mathbf{x}_a \\ \mathbf{x}_b \end{pmatrix} \quad \boldsymbol{\mu} = \begin{pmatrix} \boldsymbol{\mu}_a \\ \boldsymbol{\mu}_b \end{pmatrix} \quad \boldsymbol{\Sigma} = \begin{pmatrix} \boldsymbol{\Sigma}_{aa} & \boldsymbol{\Sigma}_{ab} \\ \boldsymbol{\Sigma}_{ba} & \boldsymbol{\Sigma}_{bb} \end{pmatrix} \quad \boldsymbol{\Sigma}^{-1} = \boldsymbol{\Lambda} = \begin{pmatrix} \boldsymbol{\Lambda}_{aa} & \boldsymbol{\Lambda}_{ab} \\ \boldsymbol{\Lambda}_{ba} & \boldsymbol{\Lambda}_{bb} \end{pmatrix}$$

Queremos encontrar,

$$p(\mathbf{x}_a|\mathbf{x}_b) = \mathcal{N}(\mathbf{x}_a|\boldsymbol{\mu}_{a|b}, \boldsymbol{\Sigma}_{a|b})$$

$$p(\mathbf{x}_a) = \mathcal{N}(\mathbf{x}_a|\boldsymbol{\mu}_a, \boldsymbol{\Sigma}_a)$$

Notar que $\boldsymbol{\Lambda}_{aa} \neq \boldsymbol{\Sigma}_{aa}^{-1}$

4.1.1. Distribución condicional

En primer lugar notamos que la distribución condicional es proporcional a la conjunta, y que ella es proporcional al exponente de la distribución gaussiana multivariada.

$$p(\mathbf{x}_a|\mathbf{x}_b) \propto p(\mathbf{x}_a, \mathbf{x}_b) \propto \exp\left(-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1}(\mathbf{x} - \boldsymbol{\mu})\right)$$

Primero reordenamos los términos en su interior y los agrupamos por el grado en $\mathbf{x}$.

$$-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1}(\mathbf{x} - \boldsymbol{\mu}) = -\frac{1}{2} \underbrace{\mathbf{x}^T \boldsymbol{\Sigma}^{-1} \mathbf{x}}_{\text{Cuadrático}} + \underbrace{\mathbf{x}^T \boldsymbol{\Sigma}^{-1} \boldsymbol{\mu}}_{\text{Lineal}} + \text{const}$$

Esto mismo lo podemos hacer con un nivel de detalle superior, usando la definición de la precisión $\boldsymbol{\Sigma}^{-1}$ (inversa de la covarianza) para descomponer los términos, agrupando por el grado en $\mathbf{x}_a$.

$$\begin{aligned} & -\frac{1}{2}(\mathbf{x}_a - \boldsymbol{\mu}_a)^T \boldsymbol{\Lambda}_{aa}(\mathbf{x}_a - \boldsymbol{\mu}_a) - \frac{1}{2}(\mathbf{x}_a - \boldsymbol{\mu}_a)^T \boldsymbol{\Lambda}_{ab}(\mathbf{x}_b - \boldsymbol{\mu}_b) \\ & -\frac{1}{2}(\mathbf{x}_b - \boldsymbol{\mu}_b)^T \boldsymbol{\Lambda}_{ba}(\mathbf{x}_a - \boldsymbol{\mu}_a) - \frac{1}{2}(\mathbf{x}_b - \boldsymbol{\mu}_b)^T \boldsymbol{\Lambda}_{bb}(\mathbf{x}_b - \boldsymbol{\mu}_b) \\ & = \\ & -\frac{1}{2}\mathbf{x}_a^T \boldsymbol{\Lambda}_{aa} \mathbf{x}_a + \mathbf{x}_a^T (\boldsymbol{\Lambda}_{aa} \boldsymbol{\mu}_a - \boldsymbol{\Lambda}_{ab}(\mathbf{x}_b - \boldsymbol{\mu}_b)) + \text{const} \\ & -\frac{1}{2}\mathbf{x}_a^T \underbrace{\boldsymbol{\Lambda}_{aa}}_{\boldsymbol{\Sigma}_{a|b}^{-1}} \mathbf{x}_a + \mathbf{x}_a^T \underbrace{(\boldsymbol{\Lambda}_{aa} \boldsymbol{\mu}_a - \boldsymbol{\Lambda}_{ab}(\mathbf{x}_b - \boldsymbol{\mu}_b))}_{\boldsymbol{\Sigma}_{a|b}^{-1} \boldsymbol{\mu}_{a|b}} + \text{const} \end{aligned}$$

Donde Λ_{aa} va a representar la precisión de la distribución condicional $\Sigma_{a|b}^{-1}$ y el factor que acompaña a $\mathbf{x}$ va a representar el producto entre la precisión y la media de la distribución condicional $\Sigma_{a|b}^{-1}\boldsymbol{\mu}_{a|b}$.

$$\begin{aligned}\Sigma_{a|b} &= \Lambda_{aa}^{-1} & \boldsymbol{\mu}_{a|b} &= \Sigma_{a|b} \left(\Lambda_{aa} \boldsymbol{\mu}_a - \Lambda_{ab}(\mathbf{x}_b - \boldsymbol{\mu}_b) \right) \\ & & &= \boldsymbol{\mu}_a - \Lambda_{aa}^{-1} \Lambda_{ab}(\mathbf{x}_b - \boldsymbol{\mu}_b)\end{aligned}$$

Por lo tanto

$$p(\mathbf{x}_a|\mathbf{x}_b) = \mathcal{N}(\mathbf{x}|\boldsymbol{\mu}_{a|b}, \Lambda_{aa}^{-1})$$

Distribución condicional en función de la covarianza Éste resultado está expresado usando uno de los elementos que componen la matriz de precisión de la distribución conjunta. También podríamos expresar el resultado usando la matriz de covarianzas de la distribución conjunta. Para ello es necesario revisar cómo la inversa de la matriz de covarianzas está relacionada con la matriz de precisión.

$$\begin{pmatrix} \Sigma_{aa} & \Sigma_{ab} \\ \Sigma_{ba} & \Sigma_{bb} \end{pmatrix}^{-1} = \begin{pmatrix} \Lambda_{aa} & \Lambda_{ab} \\ \Lambda_{ba} & \Lambda_{bb} \end{pmatrix}$$

Es importante notar primero que la inversa de cualquier matriz cumple con la siguiente propiedad.

$$\begin{pmatrix} \mathbf{A} & \mathbf{B} \\ \mathbf{C} & \mathbf{D} \end{pmatrix} \begin{pmatrix} \mathbf{A} & \mathbf{B} \\ \mathbf{C} & \mathbf{D} \end{pmatrix}^{-1} = \begin{pmatrix} \mathbf{I} & \mathbf{O} \\ \mathbf{O} & \mathbf{I} \end{pmatrix}$$

Por lo tanto,

$$\begin{pmatrix} \mathbf{A} & \mathbf{B} \\ \mathbf{C} & \mathbf{D} \end{pmatrix} \begin{pmatrix} \mathbf{M} & -\mathbf{M}\mathbf{B}\mathbf{D}^{-1} \\ -\mathbf{D}^{-1}\mathbf{C}\mathbf{M} & \mathbf{D}^{-1}\mathbf{C}\mathbf{M}\mathbf{B}\mathbf{D}^{-1} \end{pmatrix} = \begin{pmatrix} \mathbf{I} & \mathbf{O} \\ \mathbf{O} & \mathbf{I} \end{pmatrix}$$

con $\mathbf{M} = (\mathbf{A} - \mathbf{B}\mathbf{D}^{-1}\mathbf{C})^{-1}$

Lo que define la siguiente relación.

$$\begin{aligned}\Lambda_{aa} &= (\Sigma_{aa} - \Sigma_{ab}\Sigma_{bb}^{-1}\Sigma_{ba})^{-1} \\ \Lambda_{ab} &= -(\Sigma_{aa} - \Sigma_{ab}\Sigma_{bb}^{-1}\Sigma_{ba})^{-1}\Sigma_{ab}\Sigma_{bb}^{-1}\end{aligned}$$

4.1.2. Distribución marginal

Vimos que si la distribución conjunta $p(\mathbf{x}_a, \mathbf{x}_b)$ es gaussiana, la condicional $p(\mathbf{x}_a|\mathbf{x}_b)$ también lo es. En esta sección veremos que la distribución marginal $P(\mathbf{x}_a)$ también será gaussiana.

$$p(\mathbf{x}_a) = \int p(\mathbf{x}_a, \mathbf{x}_b) d\mathbf{x}_b$$

Para integrar sobre $\mathbf{x}_b$ vamos a considerar los términos que involucren a $\mathbf{x}_b$ para facilitar la integración.

$$-\frac{1}{2}\mathbf{x}_b^T \Lambda_{bb} \mathbf{x}_b + \mathbf{x}_b^T \underbrace{(\Lambda_{bb}\boldsymbol{\mu}_b - \Lambda_{ba}(\mathbf{x}_a - \boldsymbol{\mu}_a))}_{\mathbf{m}}$$

Si completamos los cuadrados.

$$\begin{aligned} -\frac{1}{2}\mathbf{x}_b^T \mathbf{\Lambda}_{bb} \mathbf{x}_b + \mathbf{x}_b^T \mathbf{m} &= -\frac{1}{2}\mathbf{x}_b^T \mathbf{\Lambda}_{bb} \mathbf{x}_b + \mathbf{x}_b^T \mathbf{m} - \overbrace{\frac{1}{2}\mathbf{m}^T \mathbf{\Lambda}_{bb}^{-1} \mathbf{m}}^0 + \frac{1}{2}\mathbf{m}^T \mathbf{\Lambda}_{bb}^{-1} \mathbf{m} \\ &= -\underbrace{\frac{1}{2}(\mathbf{x}_b - \mathbf{\Lambda}_{bb}^{-1} \mathbf{m})^T \mathbf{\Lambda}_{bb} (\mathbf{x}_b - \mathbf{\Lambda}_{bb}^{-1} \mathbf{m})}_{\text{Exponente de la Gaussiana}} + \underbrace{\frac{1}{2}\mathbf{m}^T \mathbf{\Lambda}_{bb}^{-1} \mathbf{m}}_{\text{Libre de } \mathbf{x}_b} \end{aligned}$$

Luego, la integración se realizará sobre una gaussiana no normalizada, y por lo tanto el resultado va a ser el recíproco del coeficiente de normalización, que depende de $\mathbf{x}_a$.

$$p(\mathbf{x}_a) = f(\mathbf{x}_a) \int \exp\left(-\frac{1}{2}(\mathbf{x}_b - \mathbf{\Lambda}_{bb}^{-1} \mathbf{m})^T \mathbf{\Lambda}_{bb} (\mathbf{x}_b - \mathbf{\Lambda}_{bb}^{-1} \mathbf{m})\right) d\mathbf{x}_b$$

Esta integración se realiza fácilmente cuando notamos que corresponde a la integral de una Gaussiana no normalizada, por lo que el resultado será el recíproco del coeficiente de normalización. Sabemos, por la definición de la Gaussiana normalizada, que este coeficiente es independiente de la media y depende solo del determinante de la matriz de covarianza. Así, al completar el cuadrado con respecto a $\mathbf{x}_b$, podemos integrar $\mathbf{x}_b$, quedando los siguientes términos como recíproco.

$$\begin{aligned} f(\mathbf{x}_a) \frac{1}{2}\mathbf{m}^T \mathbf{\Lambda}_{bb}^{-1} \mathbf{m} - \frac{1}{2}\mathbf{x}_a^T \mathbf{\Lambda}_{aa} \mathbf{x}_a + \mathbf{x}_a^T (\mathbf{\Lambda}_{aa} \boldsymbol{\mu}_a + \mathbf{\Lambda}_{ab} \boldsymbol{\mu}_b) + \text{const} \\ = -\frac{1}{2}\mathbf{x}_a^T \underbrace{(\mathbf{\Lambda}_{aa} - \mathbf{\Lambda}_{ab} \mathbf{\Lambda}_{bb}^{-1} \mathbf{\Lambda}_{ba})}_{\boldsymbol{\Sigma}_a^{-1}} \mathbf{x}_a + \mathbf{x}_a^T \underbrace{(\mathbf{\Lambda}_{aa} - \mathbf{\Lambda}_{ab} \mathbf{\Lambda}_{bb}^{-1} \mathbf{\Lambda}_{ba})^{-1} \boldsymbol{\mu}_a}_{\boldsymbol{\Sigma}_a^{-1} \boldsymbol{\mu}_a} + \text{const} \end{aligned}$$

donde const refiere a elementos independientes de $\mathbf{x}_a$. Luego,

$$\boldsymbol{\Sigma}_a = \underbrace{(\mathbf{\Lambda}_{aa} - \mathbf{\Lambda}_{ab} \mathbf{\Lambda}_{bb}^{-1} \mathbf{\Lambda}_{ba})^{-1}}_{\boldsymbol{\Sigma}_{aa}}$$

y por lo tanto la distribución gaussiana marginal es,

$$p(\mathbf{x}_a) = \mathcal{N}(\mathbf{x}_a | \boldsymbol{\mu}_a, \boldsymbol{\Sigma}_{aa})$$

4.2. Modelo lineal multivariado

Dadas un modelo lineal

$$\begin{aligned} p(\mathbf{w}) &= \mathcal{N}(\mathbf{w} | \boldsymbol{\mu}, \mathbf{\Lambda}^{-1}) \\ p(\mathbf{y} | \mathbf{w}) &= \mathcal{N}(\mathbf{y} | \mathbf{A}\mathbf{w} + \mathbf{b}, \mathbf{L}^{-1}) \end{aligned}$$

Queremos probar,

$$\begin{aligned} p(\mathbf{y}) &= \mathcal{N}(\mathbf{y} | \cdot, \cdot) \\ p(\mathbf{w} | \mathbf{y}) &= \mathcal{N}(\mathbf{w} | \cdot, \cdot) \end{aligned}$$

Vamos a usar la probabilidad conjunta

$$\mathbf{z} = \begin{pmatrix} \mathbf{w} \\ \mathbf{y} \end{pmatrix}$$

Tomando el logaritmo

$$\begin{aligned} \log p(\mathbf{z}) &= \log p(w) + \log p(y|w) \\ &= -\frac{1}{2}(\mathbf{w} - \boldsymbol{\mu})^T \mathbf{\Lambda} (\mathbf{w} - \boldsymbol{\mu}) - \frac{1}{2}(\mathbf{y} - \mathbf{A}\mathbf{w} - \mathbf{b})^T \mathbf{L} (\mathbf{y} - \mathbf{A}\mathbf{w} - \mathbf{b}) + \text{const} \end{aligned}$$

Términos cuadráticos Analizamos primero los términos cuadráticos

$$\begin{aligned}
& -\frac{1}{2}\mathbf{w}^T(\mathbf{\Lambda} + \mathbf{A}^T\mathbf{L}\mathbf{A})\mathbf{w} - \frac{1}{2}\mathbf{y}^T(\mathbf{L})\mathbf{y} + \frac{1}{2}\mathbf{y}^T(\mathbf{L}\mathbf{A})\mathbf{w} + \frac{1}{2}\mathbf{w}^T(\mathbf{A}^T\mathbf{L})\mathbf{y} \\
& = -\frac{1}{2}\begin{pmatrix} \mathbf{w} \\ \mathbf{y} \end{pmatrix}^T \underbrace{\begin{pmatrix} \mathbf{\Lambda} + \mathbf{A}^T\mathbf{L}\mathbf{A} & -\mathbf{A}^T\mathbf{L} \\ -\mathbf{L}\mathbf{A} & \mathbf{L} \end{pmatrix}}_{\mathbf{R}} \begin{pmatrix} \mathbf{w} \\ \mathbf{y} \end{pmatrix}
\end{aligned}$$

Donde la covarianza

$$\text{cov}[\mathbf{z}] = \mathbf{R}^{-1} = \begin{pmatrix} \mathbf{\Lambda}^{-1} & \mathbf{\Lambda}^{-1}\mathbf{A}^T \\ \mathbf{A}\mathbf{\Lambda}^{-1} & \mathbf{L}^{-1} + \mathbf{A}\mathbf{\Lambda}^{-1}\mathbf{A}^T \end{pmatrix}$$

Términos lineales Analizamos ahora los términos lineales.

$$\mathbf{w}^T\mathbf{\Lambda}\boldsymbol{\mu} - \mathbf{w}^T\mathbf{A}^T\mathbf{L}\mathbf{b} + \mathbf{y}^T\mathbf{L}\mathbf{b} = \begin{pmatrix} \mathbf{w} \\ \mathbf{y} \end{pmatrix}^T \begin{pmatrix} \mathbf{\Lambda}\boldsymbol{\mu} - \mathbf{A}^T\mathbf{L}\mathbf{b} \\ \mathbf{L}\mathbf{b} \end{pmatrix}$$

Donde la media es

$$\mathbb{E}[\mathbf{z}] = \mathbf{R}^{-1} \begin{pmatrix} \mathbf{\Lambda}\boldsymbol{\mu} - \mathbf{A}^T\mathbf{L}\mathbf{b} \\ \mathbf{L}\mathbf{b} \end{pmatrix} = \begin{pmatrix} \boldsymbol{\mu} \\ \mathbf{A}\boldsymbol{\mu} + \mathbf{b} \end{pmatrix}$$

4.2.1. Evidencia y posterior

Hemos visto que dado,

$$p(\mathbf{w}) = \mathcal{N}(\mathbf{w}|\boldsymbol{\mu}, \mathbf{\Lambda}^{-1}) \quad p(\mathbf{y}|\mathbf{w}) = \mathcal{N}(\mathbf{y}|\mathbf{A}\mathbf{w} + \mathbf{b}, \mathbf{L}^{-1})$$

la distribución conjunta es,

$$\mathbf{z} = \begin{pmatrix} \mathbf{w} \\ \mathbf{y} \end{pmatrix} \quad \mathbb{E}_{\mathbf{z}} = \begin{pmatrix} \boldsymbol{\mu} \\ \mathbf{A}\boldsymbol{\mu} + \mathbf{b} \end{pmatrix} \quad \text{cov}_{\mathbf{z}} = \begin{pmatrix} \mathbf{\Lambda}^{-1} & \mathbf{\Lambda}^{-1}\mathbf{A}^T \\ \mathbf{A}\mathbf{\Lambda}^{-1} & \mathbf{L}^{-1} + \mathbf{A}\mathbf{\Lambda}^{-1}\mathbf{A}^T \end{pmatrix} \quad \text{cov}_{\mathbf{z}}^{-1} = \begin{pmatrix} \mathbf{\Lambda} + \mathbf{A}^T\mathbf{L}\mathbf{A} & -\mathbf{A}^T\mathbf{L} \\ -\mathbf{L}\mathbf{A} & \mathbf{L} \end{pmatrix}$$

Luego, usando las propiedades de la marginal y condicional sabemos que,

$$p(\mathbf{y}) = \mathcal{N}(\mathbf{y}|\mathbf{A}\boldsymbol{\mu} + \mathbf{b}, \mathbf{L}^{-1} + \mathbf{A}\mathbf{\Lambda}^{-1}\mathbf{A}^T)$$

$$\begin{aligned}
p(\mathbf{w}|\mathbf{y}) &= \mathcal{N}(\mathbf{w}|\boldsymbol{\Sigma}(\mathbf{A}^T\mathbf{L}(\mathbf{y} - \mathbf{b}) + \mathbf{\Lambda}\boldsymbol{\mu}), \boldsymbol{\Sigma}) \\
\text{con } \boldsymbol{\Sigma} &= (\mathbf{\Lambda} + \mathbf{A}^T\mathbf{L}\mathbf{A})^{-1}
\end{aligned}$$