

Modelos gaussianos



Modelos lineales

(lineales en las hipótesis)

Modelos lineales

(lineales en las hipótesis)

$$p(y|x, \mathbf{w}, \beta) = \mathcal{N} \left(y \mid \sum_i w_i \cdot \phi_i(x), \beta^2 \right)$$

Modelos lineales


(lineales en las hipótesis)

$$p(y|x, \mathbf{w}, \beta) = \mathcal{N}\left(y \mid \sum_i w_i \cdot \phi_i(x), \beta^2\right) \quad p(w_i) = \mathcal{N}(w_i \mid 0, \sigma_i^2)$$

Modelos lineales

(lineales en las hipótesis)


$$p(y|x, \mathbf{w}, \beta) = \mathcal{N}\left(y \mid \sum_i w_i \cdot \phi_i(x), \beta^2\right) \quad p(w_i) = \mathcal{N}(w_i \mid 0, \sigma_i^2)$$



Modelos lineales

(lineales en las hipótesis)


$$p(y|x, \mathbf{w}, \beta) = \mathcal{N}\left(y \mid \sum_i w_i \cdot \phi_i(x), \beta^2\right) \quad p(w_i) = \mathcal{N}(w_i \mid 0, \sigma_i^2)$$



Modelos lineales

Función objetivo


$$\mathcal{N}(y \mid \sin(2\pi x), \beta^2) \quad x \in \left[-\frac{1}{2}, \frac{1}{2}\right]$$



Modelos lineales

Función objetivo

$$\mathcal{N}(y \mid \sin(2\pi x), \beta^2) \quad x \in \left[-\frac{1}{2}, \frac{1}{2}\right]$$




$$y = w_0 + w_1 x + w_2 x^2 + w_3 x^3 + \dots$$

Modelos lineales

Función objetivo

$$\mathcal{N}(y \mid \sin(2\pi x), \beta^2) \quad x \in \left[-\frac{1}{2}, \frac{1}{2}\right]$$



$$y = w_0 + w_1 x + w_2 x^2 + w_3 x^3 + \dots$$

$$y = \sum_{i=0}^M w_i \cdot x^i$$

¿Cuál es el mejor modelo polinomial?

Siglo 20: Estimadores puntuales


~~Evaluación~~ Selección de hipótesis

$$\max_{\boldsymbol{w}} P(\boldsymbol{y}|\boldsymbol{x}, \boldsymbol{w}, \beta) = \min_{\boldsymbol{w}} \sum_{i=1}^n (y_i - f(x_i, \boldsymbol{w}))^2$$

Siglo 20: Estimadores puntuales

Evaluación Selección de hipótesis



$$\max_{\mathbf{w}} P(\mathbf{y}|\mathbf{x}, \mathbf{w}, \beta) = \min_{\mathbf{w}} \sum_{i=1}^n (y_i - f(x_i, \mathbf{w}))^2$$



Siglo 20: Estimadores puntuales

Evaluación Selección de hipótesis



$$\max_{\mathbf{w}} P(\mathbf{y}|\mathbf{x}, \mathbf{w}, \beta) = \min_{\mathbf{w}} \sum_{i=1}^n (y_i - f(x_i, \mathbf{w}))^2$$



Siglo 20: Estimadores puntuales

Evaluación Selección de hipótesis

$$\max_{\mathbf{w}} P(\mathbf{y}|\mathbf{x}, \mathbf{w}, \beta) = \min_{\mathbf{w}} \sum_{i=1}^n (y_i - f(x_i, \mathbf{w}))^2$$



Siglo 20: Estimadores puntuales

~~Evaluación~~ Selección de hipótesis

$$\max_{\boldsymbol{w}} P(\boldsymbol{y}|\boldsymbol{x}, \boldsymbol{w}, \beta) = \min_{\boldsymbol{w}} \sum_{i=1}^n (y_i - f(x_i, \boldsymbol{w}))^2$$

$$P(\text{dato}|\text{Modelo}) = \sum_{\text{hipótesis}} P(\text{dato} | \text{hipótesis}, \text{Modelo}) P(\text{hipótesis}|\text{Modelo})$$

Siglo 20: Estimadores puntuales

~~Evaluación~~ Selección de hipótesis

$$\max_{\boldsymbol{w}} P(\boldsymbol{y}|\boldsymbol{x}, \boldsymbol{w}, \beta) = \min_{\boldsymbol{w}} \sum_{i=1}^n (y_i - f(x_i, \boldsymbol{w}))^2$$

$$P(\text{dato}|\text{Modelo}) = P(\text{dato} \mid \text{hipótesis}, \text{Modelo})$$

Siglo 20: Estimadores puntuales

~~Evaluación~~ Selección de hipótesis

$$\max_{\mathbf{w}} P(\mathbf{y}|\mathbf{x}, \mathbf{w}, \beta) = \min_{\mathbf{w}} \sum_{i=1}^n (y_i - f(x_i, \mathbf{w}))^2$$

$$P(\text{dato}|\text{Modelo}) = P(\text{dato} \mid \text{hipótesis}, \text{Modelo})$$

$$= P(\text{dato} \mid \overbrace{\arg \max_h P(\text{dato}|h, \text{Modelo})}^{\text{Hipótesis que mejor predice}}, \text{Modelo})$$

Siglo 20: Estimadores puntuales

~~Evaluación~~ Selección de hipótesis

$$\max_{\mathbf{w}} P(\mathbf{y}|\mathbf{x}, \mathbf{w}, \beta) = \min_{\mathbf{w}} \sum_{i=1}^n (y_i - f(x_i, \mathbf{w}))^2$$

$$P(\text{dato}|\text{Modelo}) = P(\text{dato} \mid \text{hipótesis}, \text{Modelo})$$

$$= P(\text{dato} \mid \overbrace{\arg \max_h P(\text{dato}|h, \text{Modelo})}^{\text{Hipótesis que mejor predice}}, \text{Modelo})$$

¿Predecimos o “post-decimos”?

Siglo 20: Estimadores puntuales

~~Evaluación~~ Selección de hipótesis

$$\max_{\mathbf{w}} P(\mathbf{y}|\mathbf{x}, \mathbf{w}, \beta) = \min_{\mathbf{w}} \sum_{i=1}^n (y_i - f(x_i, \mathbf{w}))^2$$

$$P(\text{dato}|\text{Modelo}) = P(\text{dato} \mid \text{hipótesis}, \text{Modelo})$$

$$= P(\text{dato} \mid \overbrace{\arg \max_h P(\text{dato}|h, \text{Modelo})}^{\text{Hipótesis que mejor predice}}, \text{Modelo})$$

$$P(\text{dato}_{\text{Testear}}|\text{Modelo}) = P(\text{dato}_{\text{Testear}} \mid \arg \max_h P(\text{dato}_{\text{Entrenar}}|h, \text{Modelo}), \text{Modelo})$$



Testeo y Entrenamiento

Siglo 20: Estimadores puntuales

Evaluación Selección de hipótesis

$$\max_{\mathbf{w}} P(\mathbf{y}|\mathbf{x}, \mathbf{w}, \beta) = \min_{\mathbf{w}} \sum_{i=1}^n (y_i - f(x_i, \mathbf{w}))^2$$

Con testeo y entrenamiento





Siglo 20: Estimadores puntuales

Evaluación Selección de hipótesis

Perio si empezamos a ver datos $x \notin [-\frac{1}{2}, \frac{1}{2}]$ este modelo no sirve!

Con testeo y entrenamiento



¿Será que la aplicación estricta de las reglas de la probabilidad produce sobreajuste (*overfitting*)?

¿Será que la aplicación estricta de las reglas de la probabilidad produce sobreajuste (*overfitting*)?

¿Y entonces el sistema de razonamiento en contextos de incertidumbre funciona mal?

Siglo 21: Inferencia exacta

Aplicación estricta de las reglas de la probabilidad

Siglo 21: Inferencia exacta

Aplicación estricta de las reglas de la probabilidad

El modelo lineal tiene solución analítica!

Siglo 21: Inferencia exacta

Aplicación estricta de las reglas de la probabilidad

El modelo lineal tiene solución analítica!

- Para evaluar las hipótesis al interior de los modelos (**posterior**),

$$P(\text{Hipótesis}|\text{Datos}, \text{Modelo})$$

Siglo 21: Inferencia exacta

Aplicación estricta de las reglas de la probabilidad

El modelo lineal tiene solución analítica!

- Para evaluar las hipótesis al interior de los modelos (**posterior**),

$$P(\text{Hipótesis}|\text{Datos}, \text{Modelo})$$

- Y para evaluar modelos alternativos (**evidencia**),

$$P(\text{Datos}|\text{Modelos})$$

Evidencia y Posterior

Dado el prior $p(\mathbf{w})$ y el likelihood $p(\mathbf{y}|\mathbf{w})$

$$p(\mathbf{w}) = \mathcal{N}(\mathbf{w}|\boldsymbol{\mu}, \boldsymbol{\Lambda}^{-1}) \quad p(\mathbf{y}|\mathbf{w}) = \mathcal{N}(\mathbf{y}|\mathbf{A}\mathbf{w} + \mathbf{b}, \mathbf{L}^{-1})$$


Obtenemos la evidencia $p(\mathbf{y})$, y el posterior $p(\mathbf{w}|\mathbf{y})$.

$$p(\mathbf{y}) = \mathcal{N}(\mathbf{y}|\mathbf{A}\boldsymbol{\mu} + \mathbf{b}, \mathbf{L}^{-1} + \mathbf{A}\boldsymbol{\Lambda}^{-1}\mathbf{A}^T)$$

$$p(\mathbf{w}|\mathbf{y}) = \mathcal{N}(\mathbf{w}|\boldsymbol{\Sigma} (\mathbf{A}^T\mathbf{L}(\mathbf{y} - \mathbf{b}) + \boldsymbol{\Lambda}\boldsymbol{\mu}), \boldsymbol{\Sigma})$$


con $\boldsymbol{\Sigma} = (\boldsymbol{\Lambda} + \mathbf{A}^T\mathbf{L}\mathbf{A})^{-1}$

$$P(\text{Hipótesis}|\text{Datos, Modelo})$$




$$P(\text{Hipótesis}|\text{Datos, Modelo})$$

Priori



Espacio de datos








Verosimilitud

Priori/Posteriori

Espacio de datos

$$P(\text{Hipótesis}|\text{Datos, Modelo})$$




Verosimilitud

Priori/Posteriori

Espacio de datos

$$P(\text{Hipótesis}|\text{Datos, Modelo})$$



La función de costo epistémica

Todos los datos son de testeo y entrenamiento:

$$\underbrace{P(\text{Datos} = \{d_1, d_2, \dots\} | \text{Modelo})}_{\text{Evidencia: predicción del modelo}} = \underbrace{P(d_1 | \text{Modelo})}_{\text{Predicción 1}} \underbrace{P(d_2 | d_1, \text{Modelo})}_{\text{Predicción 2}} \dots$$

La función de costo epistémica

Todos los datos son de testeo y entrenamiento:


$$\underbrace{P(\text{Datos} = \{d_1, d_2, \dots\} | \text{Modelo})}_{\text{Evidencia: predicción del modelo}} = \underbrace{P(d_1 | \text{Modelo})}_{\text{Predicción 1}} \underbrace{P(d_2 | d_1, \text{Modelo})}_{\text{Predicción 2}} \dots$$

La predicción se hace con todas las hipótesis


$$P(\text{dato}_1 | \text{Modelo}) = \sum_{\text{hipótesis}} P(\text{dato}_1 | \text{hipótesis}, \text{Modelo}) P(\text{hipótesis} | \text{Modelo})$$

Siglo 21: Inferencia exacta

Aplicación estricta de las reglas de la probabilidad




$$P(\text{Modelo}|\text{Datos})$$





Evidencia

Balance natural entre complejidad y predicción



Evidencia

Balance natural entre complejidad y predicción



La verdadera predicción

Predicción con la contribución de todos los modelos


$$P(\text{Datos}) = \sum_{\text{Modelo}} P(\text{Datos}|\text{Modelo})P(\text{Modelo})$$

La verdadera predicción

Predicción con la contribución de todos los modelos


$$P(\text{Datos}) = \sum_{\text{Modelo}} P(\text{Datos}|\text{Modelo})P(\text{Modelo})$$

Si aparecen datos $x \notin [-\frac{1}{2}, \frac{1}{2}]$ van a poder ser explicados con los modelos más complejos



Altura y sexo.

Evaluación de modelos alternativos



Altura y sexo.

Evaluación de modelos alternativos


Modelo Base: $\text{altura} = h_0 + h_1 \cdot \text{altura_madre}$

Modelo Biológico: $\text{altura} = h_0 + h_1 \cdot \text{altura_madre} + h_2 \cdot \mathbb{I}(\text{sexo} = F)$


Modelo grupos al azar: $\text{altura} = h_0 \cdot \text{altura_madre} + h_{1+(\text{ID} \bmod (\max(\text{ID})/2))}$

Altura y sexo.


Evaluación de modelos alternativos



Estimación de efecto causal




Estimación de efecto causal



Estimación de efecto causal

Modelos lineales



Estimación de efecto causal

Modelos lineales


```
# https://github.com/glandfried/bayesian-linear-model
from linear_model import BayesianLinearModel
import numpy as np

N = 1000
z1 = np.random.uniform(-3,3, size=N)
w1 = 3*z1 + np.random.normal(size=N,scale=1)
z2 = np.random.uniform(-3,3, size=N)
w2 = 2*z2 + np.random.normal(size=N,scale=1)
z3 = -2*z1 + 2*z2 + np.random.normal(size=N,scale=1)
x = -1*w1 + 2*z3 + np.random.normal(size=N,scale=1)
w3 = 2*x + np.random.normal(size=N,scale=1)
y = 2 - 1*w3 - z3 + w2 + np.random.normal(size=N,scale=1)
```

Estimación de efecto causal

Modelos lineales

$$y \sim c_0 + c_1 x + c_2 z_3 + c_3 w_2$$



Estimación de efecto causal

Modelos lineales

$$y \sim c_0 + c_1 x + c_2 z_3 + c_3 w_2$$



Estimación de efecto causal


Table 2 Fallacy

Es una falacia presentar los coeficientes de los controles también como efectos causales

Estimación de efecto causal

Table 2 Fallacy

F : Fuma.
 E : Edad.
 S : Salud.
 Y : Síntoma



Estimación de efecto causal


Table 2 Fallacy

F : Fuma.

E : Edad.

S : Salud.

Y : Síntoma




$$S \longleftarrow F \longrightarrow Y$$

Estimación de efecto causal

Table 2 Fallacy

F : Fuma.
 E : Edad.
 S : Salud.
 Y : Síntoma



Estimación de efecto causal


Table 2 Fallacy

F : Fuma.

E : Edad.

S : Salud.

Y : Síntoma



Estimación de efecto causal


Table 2 Fallacy

F : Fuma.

E : Edad.

S : Salud.

Y : Síntoma



Estimación de efecto causal


Table 2 Fallacy

F : Fuma.

E : Edad.

S : Salud.

Y : Síntoma



Estimación de efecto causal


Table 2 Fallacy

F : Fuma.

E : Edad.

S : Salud.

Y : Síntoma



Estimación de efecto causal


Table 2 Fallacy

F : Fuma.

E : Edad.

S : Salud.

Y : Síntoma




$$y \sim c_0 + c_s s + c_f f + c_e e$$



Estimación de efecto causal

Table 2 Fallacy

F : Fuma.
 E : Edad.
 S : Salud.
 Y : Síntoma




$$y \sim c_0 + c_s s + \underbrace{c_f f + c_e e}_{\text{Efectos causales directos}}$$



Estimación de efecto causal

Table 2 Fallacy

F : Fuma.
 E : Edad.
 S : Salud.
 Y : Síntoma




$$y \sim c_0 + c_s s + c_f f + c_e e$$



Estimación de efecto causal

Table 2 Fallacy

F : Fuma.
 E : Edad.
 S : Salud.
 Y : Síntoma




$$y \sim c_0 + c_s s + c_f f + c_e e$$



Estimación de efecto causal

Table 2 Fallacy

F : Fuma.
 E : Edad.
 S : Salud.
 Y : Síntoma




$$y \sim c_0 + c_s s + c_f f + c_e e$$



Estimación de efecto causal

Table 2 Fallacy

F : Fuma.
 E : Edad.
 S : Salud.
 Y : Síntoma



$$y \sim c_0 + c_s s + \underbrace{c_f f + c_e e}_{\text{No son efectos causales!}}$$



$p = \mathbf{b}$

Laboratorios de
Métodos Bayesianos