




Efectos
causales

Bibliografía Unidad 7

- Neal. *Introduction to causal inference*. (Draft) 2020 ([Descargar](#)). (lecturas 1-4)
- Pearl et al. **Causal inference in statistics: A primer**. John Wiley & Sons Ltd; 2016 ([Descargar](#)). (lecturas 2 a 4)

Estimación de efecto causal


Paradoja de Simpson



Estimación de efecto causal

Paradoja de Simpson


$$P(\text{Derrumbes}|\text{Intensidad del sismo})$$



Estimación de efecto causal

Paradoja de Simpson

$P(\text{Derrumbes}|\text{Intensidad del sismo, Ciudad})$



Estimación de efecto causal

Paradoja de Simpson

¿Cómo determinar efecto causal
entre dos variables x e y ?

Estimación de efecto causal

Paradoja de Simpson

¿Cómo determinar efecto causal
entre dos variables x e y ?

Estimar efecto causal es predecir
el impacto de las intervenciones $P(y|\text{do}(x))$

Para predecir el impacto de las acciones
necesitamos conocer la estructura causal subyacente


$$P(Y|X)$$



Para predecir el impacto de las acciones
necesitamos conocer la estructura causal subyacente

$$P(Y|X) \neq P(Y|\text{do}(X))$$


Para predecir el impacto de las acciones
necesitamos conocer la estructura causal subyacente




$\neq$

$P(Y|\text{do}(X))$

Para predecir el impacto de las acciones necesitamos conocer la estructura causal subyacente




$\neq$




Para predecir el impacto de las acciones necesitamos conocer la estructura causal subyacente

Entrenamos

In-sample




$\neq$



Para predecir el impacto de las acciones necesitamos conocer la estructura causal subyacente

Entrenamos


In-sample



$\neq$

Predecimos


Out-of-sample




Para predecir el impacto de las acciones
necesitamos conocer la estructura causal subyacente

Los modelos causales son buenos para
predecir porque se adaptan al contexto

Para predecir el impacto de las acciones
necesitamos conocer la estructura causal subyacente




Para predecir el impacto de las acciones
necesitamos conocer la estructura causal subyacente



En los experimentos *aleatorizados* (y en las intervenciones determinísticas)
el tratamiento se asigna independientemente de sus causas naturales.


Para predecir el impacto de las acciones
necesitamos conocer la estructura causal subyacente



$\text{do}(X_i)$


La intervención modifica el mecanismo causal de X : $P(\text{do}(X_i = x)) = \mathbb{I}(X_i = x)$

Para predecir el impacto de las acciones
necesitamos conocer la estructura causal subyacente



$$\underbrace{P(y_i | \text{do}(x_i), M)}_{\text{El impacto de la intervención}} \underbrace{=}_{\text{es}} \underbrace{P(y_i | x_i, M_x)}_{\text{la distribución condicional en el modelo intervenido}}$$


Para predecir el impacto de las acciones
necesitamos conocer la estructura causal subyacente



$$P(y_i | \text{do}(x_i)) = P_{M_x}(y_i | x_i)$$

otra notación común


Para predecir el impacto de las acciones
necesitamos conocer la estructura causal subyacente



$$P(y_i | \text{do}(x_i)) = P_{M_x}(y_i | x_i)$$

el operador $\text{do}()$ modifica la realidad causal subyacente

Para predecir el impacto de las acciones
necesitamos conocer la estructura causal subyacente



$$P(y_i | \text{do}(x_i)) = P_{M_x}(y_i | x_i)$$

en el modelo intervenido toda la asociación es causal (no hay asociación espuria)

¿Cómo **predecir** el **impacto causal**
a partir de **datos observados sin intervenciones**?

Predicción/estimación de impacto causal

con datos observados sin intervenciones

- Estado inicial: $E_0 \in \{\text{Leve (0), Severo (1)}\}$
- Tratamiento: $T \in \{\text{Básico (0), Especial (1)}\}$
- Estado final: $E_1 \in \{\text{Leve (0), Severo (1)}\}$

Predicción/estimación de impacto causal

con datos observados sin intervenciones

- Estado inicial: $E_0 \in \{\text{Leve (0), Severo (1)}\}$
- Tratamiento: $T \in \{\text{Básico (0), Especial (1)}\}$
- Estado final: $E_1 \in \{\text{Leve (0), Severo (1)}\}$

¿El Tratamiento es efectivo para mejorar el estado del paciente?

Predicción/estimación de impacto causal

con datos observados sin intervenciones

- Estado inicial: $E_0 \in \{\text{Leve (0), Severo (1)}\}$
- Tratamiento: $T \in \{\text{Básico (0), Especial (1)}\}$
- Estado final: $E_1 \in \{\text{Leve (0), Severo (1)}\}$

	$E_0 = 0$	$E_0 = 1$	
$T = 0$			
$T = 1$			

Predicción/estimación de impacto causal

con datos observados sin intervenciones

- Estado inicial: $E_0 \in \{\text{Leve (0), Severo (1)}\}$
- Tratamiento: $T \in \{\text{Básico (0), Especial (1)}\}$
- Estado final: $E_1 \in \{\text{Leve (0), Severo (1)}\}$

	$E_0 = 0$	$E_0 = 1$
$T = 0$	$P(E_1 = 1 T = 0, E_0 = 0)$	
$T = 1$	$P(E_1 = 1 T = 1, E_0 = 0)$	

Predicción/estimación de impacto causal

con datos observados sin intervenciones

- Estado inicial: $E_0 \in \{\text{Leve (0), Severo (1)}\}$
- Tratamiento: $T \in \{\text{Básico (0), Especial (1)}\}$
- Estado final: $E_1 \in \{\text{Leve (0), Severo (1)}\}$

	$E_0 = 0$	$E_0 = 1$
$T = 0$	$P(E_1 = 1 T = 0, E_0 = 0)$	
$T = 1$	$P(E_1 = 1 T = 1, E_0 = 0)$	
	$P(E_1=1 \mathbf{T=0}, E_0=0)$ $-P(E_1=1 \mathbf{T=1}, E_0=0)$	

Predicción/estimación de impacto causal

con datos observados sin intervenciones

- Estado inicial: $E_0 \in \{\text{Leve (0), Severo (1)}\}$
- Tratamiento: $T \in \{\text{Básico (0), Especial (1)}\}$
- Estado final: $E_1 \in \{\text{Leve (0), Severo (1)}\}$

	$E_0 = 0$	$E_0 = 1$	
$T = 0$	$P(E_1 = 1 T = 0, E_0 = 0)$	$P(E_1 = 1 T = 0, E_0 = 1)$	
$T = 1$	$P(E_1 = 1 T = 1, E_0 = 0)$	$P(E_1 = 1 T = 1, E_0 = 1)$	
	$P(E_1=1 \mathbf{T=0}, E_0=0)$ $-P(E_1=1 \mathbf{T=1}, E_0=0)$		

Predicción/estimación de impacto causal

con datos observados sin intervenciones

- Estado inicial: $E_0 \in \{\text{Leve (0), Severo (1)}\}$
- Tratamiento: $T \in \{\text{Básico (0), Especial (1)}\}$
- Estado final: $E_1 \in \{\text{Leve (0), Severo (1)}\}$

	$E_0 = 0$	$E_0 = 1$	
$T = 0$	$P(E_1 = 1 T = 0, E_0 = 0)$	$P(E_1 = 1 T = 0, E_0 = 1)$	
$T = 1$	$P(E_1 = 1 T = 1, E_0 = 0)$	$P(E_1 = 1 T = 1, E_0 = 1)$	
	$P(E_1=1 \mathbf{T=0}, E_0=0)$ $-P(E_1=1 \mathbf{T=1}, E_0=0)$	$P(E_1=1 \mathbf{T=0}, E_0=1)$ $-P(E_1=1 \mathbf{T=1}, E_0=1)$	

Predicción/estimación de impacto causal

con datos observados sin intervenciones

- Estado inicial: $E_0 \in \{\text{Leve (0), Severo (1)}\}$
- Tratamiento: $T \in \{\text{Básico (0), Especial (1)}\}$
- Estado final: $E_1 \in \{\text{Leve (0), Severo (1)}\}$

	$E_0 = 0$	$E_0 = 1$	
$T = 0$	$P(E_1 = 1 T = 0, E_0 = 0)$	$P(E_1 = 1 T = 0, E_0 = 1)$	$P(E_1 = 1 T = 0)$
$T = 1$	$P(E_1 = 1 T = 1, E_0 = 0)$	$P(E_1 = 1 T = 1, E_0 = 1)$	$P(E_1 = 1 T = 1)$
	$P(E_1=1 \mathbf{T=0}, E_0=0)$ $-P(E_1=1 \mathbf{T=1}, E_0=0)$	$P(E_1=1 \mathbf{T=0}, E_0=1)$ $-P(E_1=1 \mathbf{T=1}, E_0=1)$	

Predicción/estimación de impacto causal

con datos observados sin intervenciones

- Estado inicial: $E_0 \in \{\text{Leve (0), Severo (1)}\}$
- Tratamiento: $T \in \{\text{Básico (0), Especial (1)}\}$
- Estado final: $E_1 \in \{\text{Leve (0), Severo (1)}\}$

	$E_0 = 0$	$E_0 = 1$	
$T = 0$	$P(E_1 = 1 T = 0, E_0 = 0)$	$P(E_1 = 1 T = 0, E_0 = 1)$	$P(E_1 = 1 T = 0)$
$T = 1$	$P(E_1 = 1 T = 1, E_0 = 0)$	$P(E_1 = 1 T = 1, E_0 = 1)$	$P(E_1 = 1 T = 1)$
	$P(E_1=1 \mathbf{T=0}, E_0=0)$ $-P(E_1=1 \mathbf{T=1}, E_0=0)$	$P(E_1=1 \mathbf{T=0}, E_0=1)$ $-P(E_1=1 \mathbf{T=1}, E_0=1)$	$P(E_1=1 \mathbf{T=0})$ $-P(E_1=1 \mathbf{T=1})$

Predicción/estimación de impacto causal


con datos observados sin intervenciones

- Estado inicial: $E_0 \in \{\text{Leve (0), Severo (1)}\}$
- Tratamiento: $T \in \{\text{Básico (0), Especial (1)}\}$
- Estado final: $E_1 \in \{\text{Leve (0), Severo (1)}\}$

	$E_0 = 0$	$E_0 = 1$	
$T = 0$	15% 210/1400	30% 30/100	16% 240/1500
$T = 1$	10% 5/50	20% 100/500	19% 105/550
	-5%	-10%	+4%


Predicción/estimación de impacto causal

con datos observados sin intervenciones



Predicción/estimación de impacto causal

con datos observados sin intervenciones



Predicción/estimación de impacto causal

con datos observados sin intervenciones

Para predecir el impacto causal de las acciones
necesitamos conocer la estructura causal subyacente


Estimación de efecto causal

Modelo causal (M)

- Estado inicial: $E_0 \in \{\text{Leve (0), Severo (1)}\}$
- Tratamiento: $T \in \{\text{Básico (0), Especial (1)}\}$
- Estado final: $E_1 \in \{\text{Leve (0), Severo (1)}\}$


Estimación de efecto causal

Modelo causal (M)



Estimación de efecto causal

Modelo causal (M)




	$E_0 = 0$	$E_0 = 1$	
$T = 0$	15% 210/1400	30% 30/100	16% 240/1500
$T = 1$	10% 5/50	20% 100/500	19% 105/550

Estimación de efecto causal

Modelo causal (M)

$P(E_0)$	
$E_0 = 0$	$E_0 = 1$
1450/2050	600/2050



	$E_0 = 0$	$E_0 = 1$	
$T = 0$	15% 210/1400	30% 30/100	16% 240/1500
$T = 1$	10% 5/50	20% 100/500	19% 105/550

Estimación de efecto causal


Modelo causal (M)

$P(E_0)$

$E_0 = 0$	$E_0 = 1$
1450/2050	600/2050

$P(T|E_0)$

	$T = 0$	$T = 1$
$E_0 = 0$	1400/1450	50/1450
$E_0 = 1$	100/600	500/600



	$E_0 = 0$	$E_0 = 1$	
$T = 0$	15% 210/1400	30% 30/100	16% 240/1500
$T = 1$	10% 5/50	20% 100/500	19% 105/550

Estimación de efecto causal


Modelo causal (M)

$P(E_0)$

$E_0 = 0$	$E_0 = 1$
1450/2050	600/2050

$P(T|E_0)$

	$T = 0$	$T = 1$
$E_0 = 0$	1400/1450	50/1450
$E_0 = 1$	100/600	500/600



$P(E_1|T, E_0)$

$(E_0 = 0)$	$E_1 = 0$	$E_1 = 1$
$T = 0$	0.85	0.15
$T = 1$	0.90	0.10
$(E_0 = 1)$	$E_1 = 0$	$E_1 = 1$
$T = 0$	0.70	0.30
$T = 1$	0.80	0.20


	$E_0 = 0$	$E_0 = 1$	
$T = 0$	15% 210/1400	30% 30/100	16% 240/1500
$T = 1$	10% 5/50	20% 100/500	19% 105/550

Estimación de efecto causal

Modelo causal (M)

$$P(E_0)$$

$E_0 = 0$	$E_0 = 1$
1450/2050	600/2050



$$P(T|E_0)$$

	$T = 0$	$T = 1$
$E_0 = 0$	1400/1450	50/1450
$E_0 = 1$	100/600	500/600

$$P(E_1|T, E_0)$$

$(E_0 = 0)$	$E_1 = 0$	$E_1 = 1$
$T = 0$	0.85	0.15
$T = 1$	0.90	0.10
$(E_0 = 1)$	$E_1 = 0$	$E_1 = 1$
$T = 0$	0.70	0.30
$T = 1$	0.80	0.20

$P(E_1|T, E_0)$ es una predicción sin asociación espuria


un efecto causal *heterogéneo*, específico a cada estado inicial E_0

Estimación de efecto causal

Modelo causal (M)

$$P(E_0)$$

$E_0 = 0$	$E_0 = 1$
1450/2050	600/2050



$$P(T|E_0)$$

	$T = 0$	$T = 1$
$E_0 = 0$	1400/1450	50/1450
$E_0 = 1$	100/600	500/600


$$P(E_1|T, E_0)$$

$(E_0 = 0)$	$E_1 = 0$	$E_1 = 1$
$T = 0$	0.85	0.15
$T = 1$	0.90	0.10
$(E_0 = 1)$	$E_1 = 0$	$E_1 = 1$
$T = 0$	0.70	0.30
$T = 1$	0.80	0.20

$$P(E_1|\text{do}(T))?$$

Estimación de efecto causal


Modelo causal intervenido (M_T)



Estimación de efecto causal

Modelo causal intervenido (M_T)

$$P_{M_T}(T) = \text{Bern}(0.5)$$




Estimación de efecto causal

Modelo causal intervenido (M_T)

$$P_{M_T}(T) = \text{Bern}(0.5)$$

$$P_{M_T}(E_0) = P(E_0)$$




Estimación de efecto causal

Modelo causal intervenido (M_T)

$$P_{M_T}(T) = \text{Bern}(0.5)$$

$$P_{M_T}(E_0) = P(E_0)$$

$$P_{M_T}(E_1|T, E_0) = P(E_1|T, E_0)$$




Estimación de efecto causal

Modelo causal intervenido (M_T)

$$P_{M_T}(T) = \text{Bern}(0.5)$$

$$P_{M_T}(E_0) = P(E_0)$$

$$P_{M_T}(E_1|T, E_0) = P(E_1|T, E_0)$$



$$P(e_1|\text{do}(t)) = P_{M_T}(e_1|t)$$


Estimación de efecto causal

Modelo causal intervenido (M_T)

$$P_{M_T}(T) = \text{Bern}(0.5)$$

$$P_{M_T}(E_0) = P(E_0)$$

$$P_{M_T}(E_1|T, E_0) = P(E_1|T, E_0)$$



$$P(e_1|\text{do}(t)) = P_{M_T}(e_1|t) = \frac{P_{M_T}(e_1, t)}{P_{M_T}(t)}$$


Estimación de efecto causal

Modelo causal intervenido (M_T)

$$P_{M_T}(T) = \text{Bern}(0.5)$$

$$P_{M_T}(E_0) = P(E_0)$$

$$P_{M_T}(E_1|T, E_0) = P(E_1|T, E_0)$$



$$P(e_1|\text{do}(t)) = P_{M_T}(e_1|t) = \frac{P_{M_T}(e_1, t)}{P_{M_T}(t)} = \frac{\sum_{e_0} P_{M_T}(e_0, t, e_1)}{P_{M_T}(t)}$$


Estimación de efecto causal

Modelo causal intervenido (M_T)

$$P_{M_T}(T) = \text{Bern}(0.5)$$

$$P_{M_T}(E_0) = P(E_0)$$

$$P_{M_T}(E_1|T, E_0) = P(E_1|T, E_0)$$



$$P(e_1|\text{do}(t)) = P_{M_T}(e_1|t) = \frac{P_{M_T}(e_1, t)}{P_{M_T}(t)} = \frac{\sum_{e_0} P_{M_T}(e_0) P_{M_T}(t) P_{M_T}(e_1|t, e_0)}{P_{M_T}(t)}$$


Estimación de efecto causal

Modelo causal intervenido (M_T)

$$P_{M_T}(T) = \text{Bern}(0.5)$$

$$P_{M_T}(E_0) = P(E_0)$$

$$P_{M_T}(E_1|T, E_0) = P(E_1|T, E_0)$$



$$P(e_1|\text{do}(t)) = P_{M_T}(e_1|t) = \frac{P_{M_T}(e_1, t)}{P_{M_T}(t)} = \frac{\sum_{e_0} P_{M_T}(e_0) \cancel{P_{M_T}(t)} P_{M_T}(e_1|t, e_0)}{\cancel{P_{M_T}(t)}}$$


Estimación de efecto causal

Modelo causal intervenido (M_T)

$$P_{M_T}(T) = \text{Bern}(0.5)$$

$$P_{M_T}(E_0) = P(E_0)$$

$$P_{M_T}(E_1|T, E_0) = P(E_1|T, E_0)$$



$$\begin{aligned} P(e_1|\text{do}(t)) &= P_{M_T}(e_1|t) = \frac{P_{M_T}(e_1, t)}{P_{M_T}(t)} = \frac{\sum_{e_0} P_{M_T}(e_0) \cancel{P_{M_T}(t)} P_{M_T}(e_1|t, e_0)}{\cancel{P_{M_T}(t)}} \\ &= \sum_{e_0} P_{M_T}(e_0) P_{M_T}(e_1|t, e_0) \end{aligned}$$


Estimación de efecto causal

Modelo causal intervenido (M_T)

$$P_{M_T}(T) = \text{Bern}(0.5)$$

$$P_{M_T}(E_0) = P(E_0)$$

$$P_{M_T}(E_1|T, E_0) = P(E_1|T, E_0)$$



$$\begin{aligned} P(e_1|\text{do}(t)) &= P_{M_T}(e_1|t) = \frac{P_{M_T}(e_1, t)}{P_{M_T}(t)} = \frac{\sum_{e_0} P_{M_T}(e_0) \cancel{P_{M_T}(t)} P_{M_T}(e_1|t, e_0)}{\cancel{P_{M_T}(t)}} \\ &= \sum_{e_0} P(e_0) P(e_1|t, e_0) \end{aligned}$$


Estimación de efecto causal

Modelo causal intervenido (M_T)

$$P_{M_T}(T) = \text{Bern}(0.5)$$

$$P_{M_T}(E_0) = P(E_0)$$

$$P_{M_T}(E_1|T, E_0) = P(E_1|T, E_0)$$



$$P(e_1|\text{do}(t)) = P_{M_T}(e_1|t) = \frac{P_{M_T}(e_1, t)}{P_{M_T}(t)} = \frac{\sum_{e_0} P_{M_T}(e_0) \cancel{P_{M_T}(t)} P_{M_T}(e_1|t, e_0)}{\cancel{P_{M_T}(t)}}$$

$$= \underbrace{\sum_{e_0} P(e_0) P(e_1|t, e_0)}$$

Distribuciones
observadas!


Estimación de efecto causal

Modelo causal intervenido (M_T)

$$P_{M_T}(T) = \text{Bern}(0.5)$$

$$P_{M_T}(E_0) = P(E_0)$$

$$P_{M_T}(E_1|T, E_0) = P(E_1|T, E_0)$$



$$P(e_1|\text{do}(t)) = P_{M_T}(e_1|t) = \frac{P_{M_T}(e_1, t)}{P_{M_T}(t)} = \frac{\sum_{e_0} P_{M_T}(e_0) \cancel{P_{M_T}(t)} P_{M_T}(e_1|t, e_0)}{\cancel{P_{M_T}(t)}}$$

$$= \underbrace{\sum_{e_0} P(e_0) P(e_1|t, e_0)}$$

- Distribuciones observadas!
- Encontramos los efectos causales en cada subgrupo $P(e_1|t, e_0)$
 - Y los ponderamos por el tamaño de cada subgrupo $P(e_0)$


Estimación de efecto causal

Modelo causal intervenido (M_T)

$$P_{M_T}(T) = \text{Bern}(0.5)$$

$$P_{M_T}(E_0) = P(E_0)$$

$$P_{M_T}(E_1|T, E_0) = P(E_1|T, E_0)$$



$$P(e_1|\text{do}(t)) = P_{M_T}(e_1|t) = \frac{P_{M_T}(e_1, t)}{P_{M_T}(t)} = \frac{\sum_{e_0} P_{M_T}(e_0) \cancel{P_{M_T}(t)} P_{M_T}(e_1|t, e_0)}{\cancel{P_{M_T}(t)}}$$

$$= \sum_{e_0} P(e_0) P(e_1|t, e_0)$$

$$\underbrace{P(E_1 = 1|\text{do}(T = 1)) - P(E_1 = 1|\text{do}(T = 0))}$$

Efecto causal general


Estimación de efecto causal

Modelo causal intervenido (M_T)

$$P_{M_T}(T) = \text{Bern}(0.5)$$

$$P_{M_T}(E_0) = P(E_0)$$

$$P_{M_T}(E_1|T, E_0) = P(E_1|T, E_0)$$



$$\begin{aligned} P(e_1|\text{do}(t)) &= P_{M_T}(e_1|t) = \frac{P_{M_T}(e_1, t)}{P_{M_T}(t)} = \frac{\sum_{e_0} P_{M_T}(e_0) \cancel{P_{M_T}(t)} P_{M_T}(e_1|t, e_0)}{\cancel{P_{M_T}(t)}} \\ &= \sum_{e_0} P(e_0) P(e_1|t, e_0) \end{aligned}$$

$$\underbrace{P(E_1 = 1|\text{do}(T = 1)) - P(E_1 = 1|\text{do}(T = 0))}_{\text{Efecto causal general}} = -0.0646$$

Los 4 pasos de la estimación de efecto causales

Los 4 pasos de la estimación de efecto causales

1. Especificar la estructura causal subyacente.

Los 4 pasos de la estimación de efecto causales

1. Especificar la estructura causal subyacente.
2. Encontrar las variables de control que eliminan las asociaciones espurias

Los 4 pasos de la estimación de efecto causales

1. Especificar la estructura causal subyacente.
2. Encontrar las variables de control que eliminan las asociaciones espurias
3. Computar las predicciones de impacto causal

Los 4 pasos de la estimación de efecto causales


1. Especificar la estructura causal subyacente.
2. Encontrar las variables de control que eliminan las asociaciones espurias
3. Computar las predicciones de impacto causal
4. Validar los resultados

Los 4 pasos de la estimación de efecto causales

1. **Especificar la estructura causal subyacente.**
2. Encontrar las variables de control que eliminan las asociaciones espurias
3. Computar las predicciones de impacto causal
4. Validar los resultados

Los 4 pasos de la estimación de efecto causales

Especificar la estructura causal subyacente



Los 4 pasos de la estimación de efecto causales

1. **Especificar la estructura causal subyacente.**
2. **Encontrar las variables de control que eliminan las asociaciones espurias**
3. Computar las predicciones de impacto causal
4. Validar los resultados

Los 4 pasos de la estimación de efecto causales

Encontrar las variables de control que eliminan las asociaciones espurias

Asociación en las estructuras básicas

Fork:	$x \leftarrow z \rightarrow y$	$x \not\perp\!\!\!\perp y$	$x \perp\!\!\!\perp y z$
Pipe:	$x \rightarrow z \rightarrow y$	$x \not\perp\!\!\!\perp y$	$x \perp\!\!\!\perp y z$
Collider:	$x \rightarrow z \leftarrow y$	$x \perp\!\!\!\perp y$	$x \not\perp\!\!\!\perp y z$
	$\downarrow$ w		$x \not\perp\!\!\!\perp y w$

Los 4 pasos de la estimación de efecto causales

Encontrar las variables de control que eliminan las asociaciones espurias


Hay asociación entre los extremos de una cadena (*d-conectado*) si:

- Todas las consecuencias comunes (o sus descendientes) son observables
- Ninguna otra variable es observable

Se cierra el flujo si está no *d-conectado*
d-separado


Los 4 pasos de la estimación de efecto causales

Encontrar las variables de control que eliminan las asociaciones espurias





Los 4 pasos de la estimación de efecto causales

Encontrar las variables de control que eliminan las asociaciones espurias





Los 4 pasos de la estimación de efecto causales

Encontrar las variables de control que eliminan las asociaciones espurias





Los 4 pasos de la estimación de efecto causales

Encontrar las variables de control que eliminan las asociaciones espurias





Los 4 pasos de la estimación de efecto causales

Encontrar las variables de control que eliminan las asociaciones espurias



Los 4 pasos de la estimación de efecto causales

Encontrar las variables de control que eliminan las asociaciones espurias



Los 4 pasos de la estimación de efecto causales

Encontrar las variables de control que eliminan las asociaciones espurias


Variables de control (Backdoor criterion)

Un conjunto de variable Q elimina la asociación espuria (*backdoor*) entre las variables Y y X en un DAG si:

1. Q cierra todos los caminos ascendentes de X a Y (camino no causales)
2. Q no contiene ninguna variable descendiente de X .


Los 4 pasos de la estimación de efecto causales

Encontrar las variables de control que eliminan las asociaciones espurias



Los 4 pasos de la estimación de efecto causales

Encontrar las variables de control que eliminan las asociaciones espurias



$$P(y|x, z_3, w_2)$$

predicción sin asociación espuria

Los 4 pasos de la estimación de efecto causales

1. **Especificar la estructura causal subyacente.**
2. **Encontrar las variables de control que eliminan las asociaciones espurias**
3. **Computar las predicciones de impacto causal**
4. Validar los resultados


Los 4 pasos de la estimación de efecto causales

Computar las predicciones de impacto causal

```
N = 1000
z1 = np.random.uniform(-3,3, size=N)
w1 = 3*z1 + np.random.normal(size=N,scale=1)
z2 = np.random.uniform(-3,3, size=N)
w2 = 2*z2 + np.random.normal(size=N,scale=1)
z3 = -2*z1 + 2*z2 + np.random.normal(size=N,scale=1)
x = -1*w1 + 2*z3 + np.random.normal(size=N,scale=1)
w3 = 2*x + np.random.normal(size=N,scale=1)
y = 2 - 1*w3 - z3 + w2 + np.random.normal(size=N,scale=1)
```

Los 4 pasos de la estimación de efecto causales

Computar las predicciones de impacto causal



Los 4 pasos de la estimación de efecto causales

1. **Especificar la estructura causal subyacente.**
2. **Encontrar las variables de control que eliminan las asociaciones espurias**
3. **Computar las predicciones de impacto causal**
4. **Validar los resultados**

Los 4 pasos de la estimación de efecto causales

Validar los resultados

1. **Especificar la estructura causal subyacente.**
2. **Encontrar las variables de control que eliminan las asociaciones espurias**
3. **Computar las predicciones de impacto causal**
4. **Validar los resultados**

Estimamos correctamente los efectos causales heterogéneos

$$P(y|x, z_3, w_2)$$

Los 4 pasos de la estimación de efecto causales

Validar los resultados

1. **Especificar la estructura causal subyacente.**
2. **Encontrar las variables de control que eliminan las asociaciones espurias**
3. **Computar las predicciones de impacto causal**
4. **Validar los resultados**

Estimamos correctamente los efectos causales heterogéneos

$$P(y|x, z_3, w_2)$$

pero todavía no estimamos el efecto causal general

$$P(y|\text{do}(x)) = P_{M_x}(y|x)$$

Estimador del efecto causal general

Adjustment formula

Adjustment formula

Si un conjunto de variables Q cumple con el criterio *backdoor* de X a Y , entonces el efecto causal de X en Y es estimable (identificable) a través de la siguiente fórmula:

Estimador del efecto causal general

Adjustment formula

Adjustment formula

Si un conjunto de variables Q cumple con el criterio *backdoor* de X a Y , entonces el efecto causal de X en Y es estimable (identificable) a través de la siguiente fórmula:

$$P(Y = y | \text{do}(X = x)) = P_{M_x}(Y = y | X = x)$$

Estimador del efecto causal general

Adjustment formula

Adjustment formula

Si un conjunto de variables Q cumple con el criterio *backdoor* de X a Y , entonces el efecto causal de X en Y es estimable (identificable) a través de la siguiente fórmula:

$$\begin{aligned}P(Y = y | \text{do}(X = x)) &= P_{M_x}(Y = y | X = x) \\ &= \sum_q P_{M_x}(Y = y, Q = q | X = x)\end{aligned}$$

Estimador del efecto causal general

Adjustment formula

Adjustment formula

Si un conjunto de variables Q cumple con el criterio *backdoor* de X a Y , entonces el efecto causal de X en Y es estimable (identificable) a través de la siguiente fórmula:

$$\begin{aligned}P(Y = y | \text{do}(X = x)) &= P_{M_x}(Y = y | X = x) \\&= \sum_q P_{M_x}(Y = y, Q = q | X = x) \\&= \sum_q P_{M_x}(Q = q | X = x) P_{M_x}(Y = y | X = x, Q = q)\end{aligned}$$

Estimador del efecto causal general

Adjustment formula

Adjustment formula

Si un conjunto de variables $\mathbf{Q}$ cumple con el criterio *backdoor* de X a Y , entonces el efecto causal de X en Y es estimable (identificable) a través de la siguiente fórmula:

$$\begin{aligned}P(Y = y | \text{do}(X = x)) &= P_{M_x}(Y = y | X = x) \\&= \sum_q P_{M_x}(Y = y, Q = q | X = x) \\&= \sum_q P_{M_x}(Q = q | X = x) P_{M_x}(Y = y | X = x, Q = q) \\&\stackrel{*}{=} \sum_q P(Q = q) P(Y = y | X = x, Q = q)\end{aligned}$$

Estimador del efecto causal general

Adjustment formula

Adjustment formula

Si un conjunto de variables $\mathbf{Q}$ cumple con el criterio *backdoor* de X a Y , entonces el efecto causal de X en Y es estimable (identificable) a través de la siguiente fórmula:

$$\begin{aligned}P(Y = y | \text{do}(X = x)) &= P_{M_x}(Y = y | X = x) \\&= \sum_q P_{M_x}(Y = y, Q = q | X = x) \\&= \sum_q P_{M_x}(Q = q | X = x) P_{M_x}(Y = y | X = x, Q = q) \\&\stackrel{*}{=} \sum_q P(Q = q) \underbrace{P(Y = y | X = x, Q = q)}_{\text{Estimación del efecto causal específico a } q}\end{aligned}$$

Estimador del efecto causal general

Adjustment formula

Adjustment formula

Si un conjunto de variables $\mathbf{Q}$ cumple con el criterio *backdoor* de X a Y , entonces el efecto causal de X en Y es estimable (identificable) a través de la siguiente fórmula:

$$\begin{aligned}P(Y = y | \text{do}(X = x)) &= P_{M_x}(Y = y | X = x) \\&= \sum_q P_{M_x}(Y = y, Q = q | X = x) \\&= \sum_q P_{M_x}(Q = q | X = x) P_{M_x}(Y = y | X = x, Q = q) \\&= \sum_q^* \underbrace{P(Q = q)}_{\text{Peso de } q} \underbrace{P(Y = y | X = x, Q = q)}_{\text{Estimación del efecto causal específico a } q}\end{aligned}$$

Estimador del efecto causal general

Adjustment formula

Demostración

Estimador del efecto causal general

Adjustment formula

Demostración

Parte 1. $P_{M_x}(Y = y|X = x, Q = q) \stackrel{?}{=} P(Y = y|X = x, Q = q)$

Estimador del efecto causal general

Adjustment formula

Demostración

Parte 1. $P_{M_x}(Y = y|X = x, Q = q) \stackrel{?}{=} P(Y = y|X = x, Q = q)$

Parte 2. $P_{M_x}(Q = q|X = x) \stackrel{?}{=} P(Q = q)$

Estimador del efecto causal general

Adjustment formula

Demostración

Parte 1. $P_{M_x}(Y = y|X = x, Q = q) \stackrel{?}{=} P(Y = y|X = x, Q = q)$

1.a Del lado izquierdo toda la asociación es causal porque X no recibe flechas.

Estimador del efecto causal general

Adjustment formula

Demostración

Parte 1. $P_{M_x}(Y = y|X = x, Q = q) \stackrel{?}{=} P(Y = y|X = x, Q = q)$

- 1.a Del lado izquierdo toda la asociación es causal porque X no recibe flechas.
- 1.b Del lado derecho toda la asociación es causal porque Q corta el flujo trasero.

Estimador del efecto causal general

Adjustment formula

Demostración

Parte 1. $P_{M_x}(Y = y|X = x, Q = q) = P(Y = y|X = x, Q = q)$

- 1.a Del lado izquierdo toda la asociación es causal porque X no recibe flechas.
- 1.b Del lado derecho toda la asociación es causal porque Q corta el flujo trasero.

Estimador del efecto causal general

Adjustment formula

Demostración

Parte 1. $P_{M_x}(Y = y|X = x, Q = q) = P(Y = y|X = x, Q = q)$

1.a Del lado izquierdo toda la asociación es causal porque X no recibe flechas.

1.b Del lado derecho toda la asociación es causal porque Q corta el flujo trasero.

Parte 2. $P_{M_x}(Q = q|X = x) \stackrel{?}{=} P(Q = q)$

Estimador del efecto causal general

Adjustment formula

Demostración

Parte 1. $P_{M_x}(Y = y|X = x, Q = q) = P(Y = y|X = x, Q = q)$

1.a Del lado izquierdo toda la asociación es causal porque X no recibe flechas.

1.b Del lado derecho toda la asociación es causal porque Q corta el flujo trasero.

Parte 2. $P_{M_x}(Q = q|X = x) \stackrel{?}{=} P(Q = q)$

2.a En el lado izquierdo X no recibe flechas, se conecta con Q solo por caminos con collider ocultos.

Estimador del efecto causal general

Adjustment formula

Demostración

Parte 1. $P_{M_x}(Y = y|X = x, Q = q) = P(Y = y|X = x, Q = q)$

1.a Del lado izquierdo toda la asociación es causal porque X no recibe flechas.

1.b Del lado derecho toda la asociación es causal porque Q corta el flujo trasero.

Parte 2. $P_{M_x}(Q = q|X = x) \stackrel{?}{=} P(Q = q)$

2.a En el lado izquierdo X no recibe flechas, se conecta con Q solo por caminos con collider ocultos. Luego, $P_{M_x}(Q = q|X = x) = P_{M_x}(Q = q)$

Estimador del efecto causal general

Adjustment formula

Demostración

Parte 1. $P_{M_x}(Y = y|X = x, Q = q) = P(Y = y|X = x, Q = q)$

1.a Del lado izquierdo toda la asociación es causal porque X no recibe flechas.

1.b Del lado derecho toda la asociación es causal porque Q corta el flujo trasero.

Parte 2. $P_{M_x}(Q = q|X = x) = P_{M_x}(Q = q) \stackrel{?}{=} P(Q = q)$

2.a En el lado izquierdo X no recibe flechas, se conecta con Q solo por caminos con collider ocultos. Luego, $P_{M_x}(Q = q|X = x) = P_{M_x}(Q = q)$

Estimador del efecto causal general

Adjustment formula

Demostración

Parte 1. $P_{M_x}(Y = y|X = x, Q = q) = P(Y = y|X = x, Q = q)$

1.a Del lado izquierdo toda la asociación es causal porque X no recibe flechas.

1.b Del lado derecho toda la asociación es causal porque Q corta el flujo trasero.

Parte 2. $P_{M_x}(Q = q|X = x) = P_{M_x}(Q = q) \stackrel{?}{=} P(Q = q)$

2.a En el lado izquierdo X no recibe flechas, se conecta con Q solo por caminos con collider ocultos. Luego, $P_{M_x}(Q = q|X = x) = P_{M_x}(Q = q)$

2.b Ambas marginales se obtienen integrando sus conjuntas respectivas (la única diferencia es la condicional de X).

Estimador del efecto causal general

Adjustment formula

Demostración

Parte 1. $P_{M_x}(Y = y|X = x, Q = q) = P(Y = y|X = x, Q = q)$

1.a Del lado izquierdo toda la asociación es causal porque X no recibe flechas.

1.b Del lado derecho toda la asociación es causal porque Q corta el flujo trasero.

Parte 2. $P_{M_x}(Q = q|X = x) = P_{M_x}(Q = q) \stackrel{?}{=} P(Q = q)$

2.a En el lado izquierdo X no recibe flechas, se conecta con Q solo por caminos con collider ocultos. Luego, $P_{M_x}(Q = q|X = x) = P_{M_x}(Q = q)$

2.b Ambas marginales se obtienen integrando sus conjuntas respectivas (la única diferencia es la condicional de X). Sea W el resto de las variables.

$$P(Q) = \sum_{W, X, Y} P(Q, W, X, Y)$$

Estimador del efecto causal general

Adjustment formula

Demostración

Parte 1. $P_{M_x}(Y = y|X = x, Q = q) = P(Y = y|X = x, Q = q)$

1.a Del lado izquierdo toda la asociación es causal porque X no recibe flechas.

1.b Del lado derecho toda la asociación es causal porque Q corta el flujo trasero.

Parte 2. $P_{M_x}(Q = q|X = x) = P_{M_x}(Q = q) \stackrel{?}{=} P(Q = q)$

2.a En el lado izquierdo X no recibe flechas, se conecta con Q solo por caminos con collider ocultos. Luego, $P_{M_x}(Q = q|X = x) = P_{M_x}(Q = q)$

2.b Ambas marginales se obtienen integrando sus conjuntas respectivas (la única diferencia es la condicional de X). Sea W el resto de las variables.

$$P(Q) = \sum_{W, X, Y} P(Q)P(W, X, Y|Q)$$

Estimador del efecto causal general

Adjustment formula

Demostración

Parte 1. $P_{M_x}(Y = y|X = x, Q = q) = P(Y = y|X = x, Q = q)$

1.a Del lado izquierdo toda la asociación es causal porque X no recibe flechas.

1.b Del lado derecho toda la asociación es causal porque Q corta el flujo trasero.

Parte 2. $P_{M_x}(Q = q|X = x) = P_{M_x}(Q = q) \stackrel{?}{=} P(Q = q)$

2.a En el lado izquierdo X no recibe flechas, se conecta con Q solo por caminos con collider ocultos. Luego, $P_{M_x}(Q = q|X = x) = P_{M_x}(Q = q)$

2.b Ambas marginales se obtienen integrando sus conjuntas respectivas (la única diferencia es la condicional de X). Sea W el resto de las variables.

$$P(Q) = P(Q) \sum_{W, X, Y} P(W, X, Y|Q)$$

Estimador del efecto causal general

Adjustment formula

Demostración

Parte 1. $P_{M_x}(Y = y|X = x, Q = q) = P(Y = y|X = x, Q = q)$

1.a Del lado izquierdo toda la asociación es causal porque X no recibe flechas.

1.b Del lado derecho toda la asociación es causal porque Q corta el flujo trasero.

Parte 2. $P_{M_x}(Q = q|X = x) = P_{M_x}(Q = q) \stackrel{?}{=} P(Q = q)$

2.a En el lado izquierdo X no recibe flechas, se conecta con Q solo por caminos con collider ocultos. Luego, $P_{M_x}(Q = q|X = x) = P_{M_x}(Q = q)$

2.b Ambas marginales se obtienen integrando sus conjuntas respectivas (la única diferencia es la condicional de X). Sea W el resto de las variables.

$$P(Q) = P(Q) \underbrace{\sum_{W, X, Y} P(W, X, Y|Q)}_1$$

Estimador del efecto causal general

Adjustment formula

Demostración

Parte 1. $P_{M_x}(Y = y|X = x, Q = q) = P(Y = y|X = x, Q = q)$

1.a Del lado izquierdo toda la asociación es causal porque X no recibe flechas.

1.b Del lado derecho toda la asociación es causal porque Q corta el flujo trasero.

Parte 2. $P_{M_x}(Q = q|X = x) = P_{M_x}(Q = q) \stackrel{?}{=} P(Q = q)$

2.a En el lado izquierdo X no recibe flechas, se conecta con Q solo por caminos con collider ocultos. Luego, $P_{M_x}(Q = q|X = x) = P_{M_x}(Q = q)$

2.b Ambas marginales se obtienen integrando sus conjuntas respectivas (la única diferencia es la condicional de X). Sea W el resto de las variables.

$$P(Q) = P(Q) \sum_{W, X, Y} P(W, Y|Q)P(X|Q, W, Y)$$

Estimador del efecto causal general

Adjustment formula

Demostración

Parte 1. $P_{M_x}(Y = y|X = x, Q = q) = P(Y = y|X = x, Q = q)$

1.a Del lado izquierdo toda la asociación es causal porque X no recibe flechas.

1.b Del lado derecho toda la asociación es causal porque Q corta el flujo trasero.

Parte 2. $P_{M_x}(Q = q|X = x) = P_{M_x}(Q = q) \stackrel{?}{=} P(Q = q)$

2.a En el lado izquierdo X no recibe flechas, se conecta con Q solo por caminos con collider ocultos. Luego, $P_{M_x}(Q = q|X = x) = P_{M_x}(Q = q)$

2.b Ambas marginales se obtienen integrando sus conjuntas respectivas (la única diferencia es la condicional de X). Sea W el resto de las variables.

$$P(Q) = P(Q) \sum_{W,Y} P(W,Y|Q) \sum_X P(X|Q,W,Y)$$

Estimador del efecto causal general

Adjustment formula

Demostración

Parte 1. $P_{M_x}(Y = y|X = x, Q = q) = P(Y = y|X = x, Q = q)$

1.a Del lado izquierdo toda la asociación es causal porque X no recibe flechas.

1.b Del lado derecho toda la asociación es causal porque Q corta el flujo trasero.

Parte 2. $P_{M_x}(Q = q|X = x) = P_{M_x}(Q = q) \stackrel{?}{=} P(Q = q)$

2.a En el lado izquierdo X no recibe flechas, se conecta con Q solo por caminos con collider ocultos. Luego, $P_{M_x}(Q = q|X = x) = P_{M_x}(Q = q)$

2.b Ambas marginales se obtienen integrando sus conjuntas respectivas (la única diferencia es la condicional de X). Sea W el resto de las variables.

$$P(Q) = P(Q) \sum_{W,Y} P(W,Y|Q) \underbrace{\sum_X P(X|Q,W,Y)}_1$$

Estimador del efecto causal general

Adjustment formula

Demostración

Parte 1. $P_{M_x}(Y = y|X = x, Q = q) = P(Y = y|X = x, Q = q)$

1.a Del lado izquierdo toda la asociación es causal porque X no recibe flechas.

1.b Del lado derecho toda la asociación es causal porque Q corta el flujo trasero.

Parte 2. $P_{M_x}(Q = q|X = x) = P_{M_x}(Q = q) \stackrel{?}{=} P(Q = q)$

2.a En el lado izquierdo X no recibe flechas, se conecta con Q solo por caminos con collider ocultos. Luego, $P_{M_x}(Q = q|X = x) = P_{M_x}(Q = q)$

2.b Ambas marginales se obtienen integrando sus conjuntas respectivas (la única diferencia es la condicional de X). Sea W el resto de las variables.

$$P(Q) = P(Q) \sum_{W,Y} P(W,Y|Q)$$

Estimador del efecto causal general

Adjustment formula

Demostración

Parte 1. $P_{M_x}(Y = y|X = x, Q = q) = P(Y = y|X = x, Q = q)$

1.a Del lado izquierdo toda la asociación es causal porque X no recibe flechas.

1.b Del lado derecho toda la asociación es causal porque Q corta el flujo trasero.

Parte 2. $P_{M_x}(Q = q|X = x) = P_{M_x}(Q = q) \stackrel{?}{=} P(Q = q)$

2.a En el lado izquierdo X no recibe flechas, se conecta con Q solo por caminos con collider ocultos. Luego, $P_{M_x}(Q = q|X = x) = P_{M_x}(Q = q)$

2.b Ambas marginales se obtienen integrando sus conjuntas respectivas (la única diferencia es la condicional de X). Sea W el resto de las variables.

$$P(Q) = P(Q) \sum_{W,Y} P(W,Y|Q) \quad \text{la condicional de } X \text{ no afecta la marginal}$$

Estimador del efecto causal general

Adjustment formula

Demostración

Parte 1. $P_{M_x}(Y = y|X = x, Q = q) = P(Y = y|X = x, Q = q)$

1.a Del lado izquierdo toda la asociación es causal porque X no recibe flechas.

1.b Del lado derecho toda la asociación es causal porque Q corta el flujo trasero.

Parte 2. $P_{M_x}(Q = q|X = x) = P_{M_x}(Q = q) = P(Q = q)$

2.a En el lado izquierdo X no recibe flechas, se conecta con Q solo por caminos con collider ocultos. Luego, $P_{M_x}(Q = q|X = x) = P_{M_x}(Q = q)$

2.b Ambas marginales se obtienen integrando sus conjuntas respectivas (la única diferencia es la condicional de X). Sea W el resto de las variables.

$$P(Q) = P(Q) \sum_{W,Y} P(W,Y|Q) \quad \text{la condicional de } X \text{ no afecta la marginal}$$

Estimador del efecto causal general

Adjustment formula

Adjustment formula

Si un conjunto de variables Q cumple con el criterio *backdoor* de X a Y , entonces el efecto causal de X en Y es estimable (identificable) a través de la siguiente fórmula:

$$\underbrace{P(y|\text{do}(x))}_{\text{Realidad intervenida}} = \sum_q \underbrace{P(q) P(y|x, q)}_{\text{Realidad sin intervenir}}$$

Estimador del efecto causal general

Adjustment formula

Adjustment formula

Si un conjunto de variables Q cumple con el criterio *backdoor* de X a Y , entonces el efecto causal de X en Y es estimable (identificable) a través de la siguiente fórmula:

$$P(y|\text{do}(x)) = \sum_q P(q) P(y|x, q) \underbrace{\frac{P(x|q)}{P(x|q)}}_1$$

Estimador del efecto causal general

Adjustment formula

Adjustment formula

Si un conjunto de variables Q cumple con el criterio *backdoor* de X a Y , entonces el efecto causal de X en Y es estimable (identificable) a través de la siguiente fórmula:

$$P(y|\text{do}(x)) = \sum_q P(q) P(y|x, q) \underbrace{\frac{P(x|q)}{P(x|q)}}_1 = \sum_q \frac{P(y, x, q)}{P(x|q)}$$

Estimador del efecto causal general

Adjustment formula

Adjustment formula

Si un conjunto de variables Q cumple con el criterio *backdoor* de X a Y , entonces el efecto causal de X en Y es estimable (identificable) a través de la siguiente fórmula:

$$P(y|\text{do}(x)) = \sum_q P(q) P(y|x, q) \underbrace{\frac{P(x|q)}{P(x|q)}}_1 = \sum_q \underbrace{\frac{P(y, x, q)}{P(x|q)}}_{\text{IPW}}$$

IPW: Inverse Probability Weighting

Estimación de efecto causal general


Modelo polinomial

$$P(z) = \mathcal{N}(z|0, 1)$$

$$P(x|z) = \mathcal{N}(x|z^2, 1)$$

$$P(m|x, z) = \mathcal{N}(m|2z^2 + 10x, 1)$$

$$P(y|m) = \mathcal{N}(y|-1 + 2m^2, 1)$$



Estimación de efecto causal general


Modelo polinomial

$$P(z) = \mathcal{N}(z|0, 1)$$

$$P(\text{do}(x)) = \mathbb{I}(X = x)$$

$$P(m|x, z) = \mathcal{N}(m|2z^2 + 10x, 1)$$

$$P(y|m) = \mathcal{N}(y|-1 + 2m^2, 1)$$



Estimación de efecto causal general


Modelo polinomial

$$P(z) = \mathcal{N}(z|0, 1)$$

$$P(x|z) = \mathcal{N}(x|z^2, 1)$$

$$P(m|x, z) = \mathcal{N}(m|2z^2 + 10x, 1)$$

$$P(y|m) = \mathcal{N}(y|-1 + 2m^2, 1)$$



Estimación de efecto causal general


Modelo polinomial

$$P(z) = \mathcal{N}(z|0, 1)$$

$$P(x|z) = \mathcal{N}(x|z^2, 1)$$

$$P(m|x, z) = \mathcal{N}(m|2z^2 + 10x, 1)$$

$$P(y|m) = \mathcal{N}(y|-1 + 2m^2, 1)$$



Estimación de efecto causal general


Modelo polinomial

$$P(z) = \mathcal{N}(z|0, 1)$$

$$P(x|z) = \mathcal{N}(x|z^2, 1)$$

$$P(m|x, z) = \mathcal{N}(m|2z^2 + 10x, 1)$$

$$P(y|m) = \mathcal{N}(y|-1 + 2m^2, 1)$$



$$P(y|\text{do}(x), z) = P(y|x, z) = \mathcal{N}(y|\mathbb{E}[y|x, z], \mathbb{V}[y|x, z])$$

Estimación de efecto causal general


Modelo polinomial

$$P(z) = \mathcal{N}(z|0, 1)$$

$$P(x|z) = \mathcal{N}(x|z^2, 1)$$

$$P(m|x, z) = \mathcal{N}(m|2z^2 + 10x, 1)$$

$$P(y|m) = \mathcal{N}(y|-1 + 2m^2, 1)$$



$$P(y|\text{do}(x), z) = P(y|x, z) = \mathcal{N}(y|\mathbb{E}[y|x, z], \mathbb{V}[y|x, z])$$

¿Qué polinomio debemos usar para modelar la regresión lineal?

Estimación de efecto causal general


Modelo polinomial

$$P(z) = \mathcal{N}(z|0, 1)$$

$$P(x|z) = \mathcal{N}(x|z^2, 1)$$

$$P(m|x, z) = \mathcal{N}(m|2z^2 + 10x, 1)$$

$$P(y|m) = \mathcal{N}(y|-1 + 2m^2, 1)$$



$$P(y|\text{do}(x), z) = P(y|x, z) = \mathcal{N}(y|\mathbb{E}[y|x, z], \mathbb{V}[y|x, z])$$

Siempre podemos evaluar modelos alternativos en base a la evidencia

Estimación de efecto causal general


Modelo polinomial

$$P(z) = \mathcal{N}(z|0, 1)$$

$$P(x|z) = \mathcal{N}(x|z^2, 1)$$

$$P(m|x, z) = \mathcal{N}(m|2z^2 + 10x, 1)$$

$$P(y|m) = \mathcal{N}(y|-1 + 2m^2, 1)$$



$$P(y|\text{do}(x), z) = P(y|x, z) = \mathcal{N}(y|\mathbb{E}[y|x, z], \mathbb{V}[y|x, z])$$

Pero acá conocemos la función.

Estimación de efecto causal general


Modelo polinomial

$$P(z) = \mathcal{N}(z|0, 1)$$

$$P(x|z) = \mathcal{N}(x|z^2, 1)$$

$$P(m|x, z) = \mathcal{N}(m|2z^2 + 10x, 1)$$

$$P(y|m) = \mathcal{N}(y|-1 + 2m^2, 1)$$



$$P(y|\text{do}(x), z) = P(y|x, z) = \mathcal{N}(y|\mathbb{E}[y|x, z], \mathbb{V}[y|x, z])$$

$$\mathbb{E}[y|m] = -1 + 2m^2$$

Estimación de efecto causal general


Modelo polinomial

$$P(z) = \mathcal{N}(z|0, 1)$$

$$P(x|z) = \mathcal{N}(x|z^2, 1)$$

$$P(m|x, z) = \mathcal{N}(m|2z^2 + 10x, 1)$$

$$P(y|m) = \mathcal{N}(y|-1 + 2m^2, 1)$$



$$P(y|\text{do}(x), z) = P(y|x, z) = \mathcal{N}(y|\mathbb{E}[y|x, z], \mathbb{V}[y|x, z])$$

$$\mathbb{E}[y|m] = -1 + 2m^2 = -1 + 2(2z^2 + 10x)^2$$

Estimación de efecto causal general


Modelo polinomial

$$P(z) = \mathcal{N}(z|0, 1)$$

$$P(x|z) = \mathcal{N}(x|z^2, 1)$$

$$P(m|x, z) = \mathcal{N}(m|2z^2 + 10x, 1)$$

$$P(y|m) = \mathcal{N}(y|-1 + 2m^2, 1)$$



$$P(y|\text{do}(x), z) = P(y|x, z) = \mathcal{N}(y|\mathbb{E}[y|x, z], \mathbb{V}[y|x, z])$$

$$\begin{aligned}\mathbb{E}[y|m] &= -1 + 2m^2 = -1 + 2(2z^2 + 10x)^2 \\ &= -1 + 200x^2 + 80xz^2 + 8z^4\end{aligned}$$

Estimación de efecto causal general


Modelo polinomial

$$P(z) = \mathcal{N}(z|0, 1)$$

$$P(x|z) = \mathcal{N}(x|z^2, 1)$$

$$P(m|x, z) = \mathcal{N}(m|2z^2 + 10x, 1)$$

$$P(y|m) = \mathcal{N}(y|-1 + 2m^2, 1)$$



$$P(y|\text{do}(x), z) = P(y|x, z) = \mathcal{N}(y|\mathbb{E}[y|x, z], \mathbb{V}[y|x, z])$$

$$\mathbb{E}[y|m] = -1 + 2m^2 = -1 + 2(2z^2 + 10x)^2$$

$$= -1 + 200x^2 + 80xz^2 + 8z^4 = \mathbb{E}[y|x, z]$$

Estimación de efecto causal general


Modelo polinomial

$$P(z) = \mathcal{N}(z|0, 1)$$

$$P(x|z) = \mathcal{N}(x|z^2, 1)$$

$$P(m|x, z) = \mathcal{N}(m|2z^2 + 10x, 1)$$

$$P(y|m) = \mathcal{N}(y|-1 + 2m^2, 1)$$



$$P(y|\text{do}(x), z) = P(y|x, z) = \mathcal{N}(y|\mathbb{E}[y|x, z], \mathbb{V}[y|x, z])$$

$$\mathbb{E}[y|x, z] = -1 + 200x^2 + 80xz^2 + 8z^4$$

Estimación de efecto causal general

Modelo polinomial

```
Z4s = np.random.normal(size=N, scale=1)
X4s = Z4s**2 + np.random.normal(size=N,scale=1)
M4s = 2*Z4s**2 + 10*X4s + np.random.normal(size=N,scale=1)
Y4s = -1 + 2*M4s**2 + np.random.normal(size=N,scale=1)
```

Estimación de efecto causal general

Modelo polinomial

```
Z4s = np.random.normal(size=N, scale=1)
X4s = Z4s**2 + np.random.normal(size=N,scale=1)
M4s = 2*Z4s**2 + 10*X4s + np.random.normal(size=N,scale=1)
Y4s = -1 + 2*M4s**2 + np.random.normal(size=N,scale=1)

PHI4 = np.concatenate([
    np.ones(N).reshape(N, 1),
    (X4s**2).reshape(N, 1),
    (X4s*Z4s**2).reshape(N, 1),
    (Z4s**4).reshape(N, 1)], axis=1)
```

Estimación de efecto causal general

Modelo polinomial

```
Z4s = np.random.normal(size=N, scale=1)
X4s = Z4s**2 + np.random.normal(size=N,scale=1)
M4s = 2*Z4s**2 + 10*X4s + np.random.normal(size=N,scale=1)
Y4s = -1 + 2*M4s**2 + np.random.normal(size=N,scale=1)

beta4 = np.inf; ev = -np.inf
for beta in betas_grilla:
    new_ev = ml.log_evidence(Y4s, PHI4, beta=beta)[0][0]
    if new_ev > ev:
        beta4 = beta; ev = new_ev
```

Estimación de efecto causal general

Modelo polinomial


```
Z4s = np.random.normal(size=N, scale=1)
X4s = Z4s**2 + np.random.normal(size=N,scale=1)
M4s = 2*Z4s**2 + 10*X4s + np.random.normal(size=N,scale=1)
Y4s = -1 + 2*M4s**2 + np.random.normal(size=N,scale=1)

beta4 = np.inf; ev = -np.inf
for beta in betas_grilla:
    new_ev = ml.log_evidence(Y4s, PHI4, beta=beta)[0][0]
    if new_ev > ev:
        beta4 = beta; ev = new_ev

m4, S4 = ml.posterior(Y4s, PHI4, beta=beta4)
```


Estimación de efecto causal general

Modelo polinomial



Estimación de efecto causal general


Modelo polinomial



$$\mathbb{E}[y|x, z] = -1 + 200x^2 + 80xz^2 + 8z^4$$

Estimación de efecto causal general


Modelo polinomial



$$\mathbb{E}[y|x, z = \pm 1] = 7 + 200x^2 + 80x$$

Estimación de efecto causal general

Modelo polinomial




$$\mathbb{E}[y|x, z = \pm 1] = 7 + 200x^2 + 80x$$

$$\mathbb{E}[y|x, z = \pm 2] = 47 + 200x^2 + 320x$$

Estimación de efecto causal general

Modelo polinomial



¿Y si queremos saber el efecto global $P(y|\text{do}(x))$?


Estimación de efecto causal general

Modelo polinomial

```
def p4_Y_doX(y,x, beta=beta4):  
    res = 0  
    z_grilla = np.linspace(-4,4,201)  
    dz = z_grilla[1]-z_grilla[0]  
    for z in z_grilla:  
        pz = normal(0,1).pdf(z)  
        new_Phi= np.array([1,x**2,x*z**2,z**4]).reshape((1,4))  
        mu, sigma2 = moments_predictive(new_Phi, beta = beta4,  
            t_priori=Y4s, Phi_priori=PHI4)  
        py_xz = norm(loc=mu, scale=np.sqrt(sigma2)).pdf(y)  
        res += (pz*py_xz)*dz  
    return res
```

Estimación de efecto causal general

Modelo polinomial



Casos especiales


La disputa contra el industria del tabaco

::

F : Fumar

C : Cancer

U : Otras variables





Casos especiales


La disputa contra el industria del tabaco

F : Fumar

C : Cancer

U : Otras variables

D : Depósitos en pulmones



Casos especiales


La disputa contra el industria del tabaco

F : Fumar

C : Cancer

U : Otras variables

D : Depósitos en pulmones



	$D = 0$		$D = 1$			
	$F = 0$	$F = 1$	$F = 0$	$F = 1$	$F = 0$	$F = 1$
$C = 0$	10% 38/380	90% 18/20	5% 1/20	85% 323/380	9.75% 39/400	85% 341/400
$C = 1$	90% 342/380	10% 2/20	95% 19/20	15% 57/380	90.25% 361/400	15% 59/400

Casos especiales


La disputa contra el industria del tabaco

F : Fumar

C : Cancer

U : Otras variables

D : Depósitos en pulmones



	$D = 0$		$D = 1$			
	$F = 0$	$F = 1$	$F = 0$	$F = 1$	$F = 0$	$F = 1$
$C = 0$	10% 38/380	90% 18/20	5% 1/20	85% 323/380	9.75% 39/400	85% 341/400
$C = 1$	90% 342/380	10% 2/20	95% 19/20	15% 57/380	90.25% 361/400	15% 59/400

Casos especiales


La disputa contra el industria del tabaco

F : Fumar

C : Cancer

U : Otras variables

D : Depósitos en pulmones



	$F = 0$		$F = 1$			
	$D = 0$	$D = 1$	$D = 0$	$D = 1$	$D = 0$	$D = 1$
$C = 0$	10% 38/380	5% 1/20	90% 18/20	85% 323/380	19% 56/400	81% 324/400
$C = 1$	90% 342/380	95% 19/20	10% 2/20	15% 57/380	81% 344/400	9% 76/400

Casos especiales


La disputa contra el industria del tabaco

F : Fumar

C : Cancer

U : Otras variables

D : Depósitos en pulmones



	$F = 0$		$F = 1$			
	$D = 0$	$D = 1$	$D = 0$	$D = 1$	$D = 0$	$D = 1$
$C = 0$	10% 38/380	5% 1/20	90% 18/20	85% 323/380	19% 56/400	81% 324/400
$C = 1$	90% 342/380	95% 19/20	10% 2/20	15% 57/380	81% 344/400	9% 76/400

Casos especiales


La disputa contra el industria del tabaco

F : Fumar

C : Cancer

U : Otras variables

D : Depósitos en pulmones



	$F = 0$		$F = 1$			
	$D = 0$	$D = 1$	$D = 0$	$D = 1$	$D = 0$	$D = 1$
$C = 0$	10% 38/380	5% 1/20	90% 18/20	85% 323/380	19% 56/400	81% 324/400
$C = 1$	90% 342/380	95% 19/20	10% 2/20	15% 57/380	81% 344/400	9% 76/400

Casos especiales


La disputa contra el industria del tabaco

F : Fumar

C : Cancer

U : Otras variables

D : Depósitos en pulmones



$P(d f)$	$D = 0$	$D = 1$
$F = 0$		
$F = 1$		

	$F = 0$		$F = 1$			
	$D = 0$	$D = 1$	$D = 0$	$D = 1$	$D = 0$	$D = 1$
$C = 0$	10% 38/380	5% 1/20	90% 18/20	85% 323/380	19% 56/400	81% 324/400
$C = 1$	90% 342/380	95% 19/20	10% 2/20	15% 57/380	81% 344/400	9% 76/400

Casos especiales


La disputa contra el industria del tabaco

F : Fumar

C : Cancer

U : Otras variables

D : Depósitos en pulmones



$P(d f)$	$D = 0$	$D = 1$
$F = 0$	380/400	20/400
$F = 1$		

	$F = 0$		$F = 1$			
	$D = 0$	$D = 1$	$D = 0$	$D = 1$	$D = 0$	$D = 1$
$C = 0$	10% 38/380	5% 1/20	90% 18/20	85% 323/380	19% 56/400	81% 324/400
$C = 1$	90% 342/380	95% 19/20	10% 2/20	15% 57/380	81% 344/400	9% 76/400

Casos especiales


La disputa contra el industria del tabaco

F : Fumar

C : Cancer

U : Otras variables

D : Depósitos en pulmones



$P(d f)$	$D = 0$	$D = 1$
$F = 0$	0.95	0.05
$F = 1$		

	$F = 0$		$F = 1$			
	$D = 0$	$D = 1$	$D = 0$	$D = 1$	$D = 0$	$D = 1$
$C = 0$	10% 38/380	5% 1/20	90% 18/20	85% 323/380	19% 56/400	81% 324/400
$C = 1$	90% 342/380	95% 19/20	10% 2/20	15% 57/380	81% 344/400	9% 76/400

Casos especiales


La disputa contra el industria del tabaco

F : Fumar

C : Cancer

U : Otras variables

D : Depósitos en pulmones



$P(d f)$	$D = 0$	$D = 1$
$F = 0$	0.95	0.05
$F = 1$	20/400	380/400

	$F = 0$		$F = 1$			
	$D = 0$	$D = 1$	$D = 0$	$D = 1$	$D = 0$	$D = 1$
$C = 0$	10% 38/380	5% 1/20	90% 18/20	85% 323/380	19% 56/400	81% 324/400
$C = 1$	90% 342/380	95% 19/20	10% 2/20	15% 57/380	81% 344/400	9% 76/400

Casos especiales


La disputa contra el industria del tabaco

F : Fumar

C : Cancer

U : Otras variables

D : Depósitos en pulmones



$P(d f)$	$D = 0$	$D = 1$
$F = 0$	0.95	0.05
$F = 1$	0.05	0.95

	$F = 0$		$F = 1$			
	$D = 0$	$D = 1$	$D = 0$	$D = 1$	$D = 0$	$D = 1$
$C = 0$	10% 38/380	5% 1/20	90% 18/20	85% 323/380	19% 56/400	81% 324/400
$C = 1$	90% 342/380	95% 19/20	10% 2/20	15% 57/380	81% 344/400	9% 76/400

Casos especiales


La disputa contra el industria del tabaco

F : Fumar

C : Cancer

U : Otras variables

D : Depósitos en pulmones



$P(d f)$	$D = 0$	$D = 1$
$F = 0$	0.95	0.05
$F = 1$	0.05	0.95

	$F = 0$		$F = 1$			
	$D = 0$	$D = 1$	$D = 0$	$D = 1$	$D = 0$	$D = 1$
$C = 0$	10% 38/380	5% 1/20	90% 18/20	85% 323/380	19% 56/400	81% 324/400
$C = 1$	90% 342/380	95% 19/20	10% 2/20	15% 57/380	81% 344/400	9% 76/400

Casos especiales


La disputa contra el industria del tabaco

F : Fumar

C : Cancer

U : Otras variables

D : Depósitos en pulmones



$P(d f)$	$D = 0$	$D = 1$
$F = 0$	0.95	0.05
$F = 1$	0.05	0.95

¿Podemos evaluar el efecto causal de F en C
sin controlar por U ?

Casos especiales


La disputa contra el industria del tabaco

F : Fumar

C : Cancer

U : Otras variables

D : Depósitos en pulmones



$P(d f)$	$D = 0$	$D = 1$
$F = 0$	0.95	0.05
$F = 1$	0.05	0.95

$P(d|\text{do}(f)) = ?$ (se puede controlar?)

Casos especiales


La disputa contra el industria del tabaco

F : Fumar

C : Cancer

U : Otras variables

D : Depósitos en pulmones



$P(d f)$	$D = 0$	$D = 1$
$F = 0$	0.95	0.05
$F = 1$	0.05	0.95

$$P(d|\text{do}(f)) = P(d|f)$$

Casos especiales


La disputa contra el industria del tabaco

F : Fumar

C : Cancer

U : Otras variables

D : Depósitos en pulmones



$P(d f)$	$D = 0$	$D = 1$
$F = 0$	0.95	0.05
$F = 1$	0.05	0.95

$$P(d|\text{do}(f)) = P(d|f)$$

$$P(c|\text{do}(d)) = ?$$

Casos especiales


La disputa contra el industria del tabaco

F : Fumar

C : Cancer

U : Otras variables

D : Depósitos en pulmones



$P(d f)$	$D = 0$	$D = 1$
$F = 0$	0.95	0.05
$F = 1$	0.05	0.95

$$P(d|\text{do}(f)) = P(d|f)$$

$$P(c|\text{do}(d)) = \sum_f P(c|d, f)P(f)$$

Casos especiales


La disputa contra el industria del tabaco

F : Fumar

C : Cancer

U : Otras variables

D : Depósitos en pulmones



$P(d f)$	$D = 0$	$D = 1$
$F = 0$	0.95	0.05
$F = 1$	0.05	0.95

$$P(d|\text{do}(f)) = P(d|f)$$

$$P(c|\text{do}(d)) = \sum_f P(c|d, f)P(f)$$

$P(c d, f)$	$F = 0$		$F = 1$	
	$D = 0$	$D = 1$	$D = 0$	$D = 1$
$C = 0$	0.1 38/380	0.05 1/20	0.9 18/20	0.85 323/380
$C = 1$	0.9 342/380	0.95 19/20	0.1 2/20	0.15 57/380

Casos especiales

La disputa contra el industria del tabaco


$F = 0$	$F = 1$
0.5	0.5

F : Fumar

C : Cancer

U : Otras variables

D : Depósitos en pulmones



$P(d f)$	$D = 0$	$D = 1$
$F = 0$	0.95	0.05
$F = 1$	0.05	0.95

$$P(d|\text{do}(f)) = P(d|f)$$

$$P(c|\text{do}(d)) = \sum_f P(c|d, f) P(f)$$

$P(c d, f)$	$F = 0$		$F = 1$	
	$D = 0$	$D = 1$	$D = 0$	$D = 1$
$C = 0$	0.1 38/380	0.05 1/20	0.9 18/20	0.85 323/380
$C = 1$	0.9 342/380	0.95 19/20	0.1 2/20	0.15 57/380

Casos especiales

La disputa contra el industria del tabaco


$F = 0$	$F = 1$
0.5	0.5

F : Fumar

C : Cancer

U : Otras variables

D : Depósitos en pulmones



$P(d f)$	$D = 0$	$D = 1$
$F = 0$	0.95	0.05
$F = 1$	0.05	0.95

$$P(d|\text{do}(f)) = P(d|f)$$

$$P(c|\text{do}(d)) = \sum_f P(c|d, f)P(f)$$

$P(c d, f)$	$F = 0$		$F = 1$	
	$D = 0$	$D = 1$	$D = 0$	$D = 1$
$C = 0$	0.1 38/380	0.05 1/20	0.9 18/20	0.85 323/380
$C = 1$	0.9 342/380	0.95 19/20	0.1 2/20	0.15 57/380

$$P(c|\text{do}(f)) = ?$$

Casos especiales

La disputa contra el industria del tabaco


$F = 0$	$F = 1$
0.5	0.5

F : Fumar

C : Cancer

U : Otras variables

D : Depósitos en pulmones



$P(d f)$	$D = 0$	$D = 1$
$F = 0$	0.95	0.05
$F = 1$	0.05	0.95

$$P(d|\text{do}(f)) = P(d|f)$$

$$P(c|\text{do}(d)) = \sum_f P(c|d, f)P(f)$$

$P(c d, f)$	$F = 0$		$F = 1$	
	$D = 0$	$D = 1$	$D = 0$	$D = 1$
$C = 0$	0.1 38/380	0.05 1/20	0.9 18/20	0.85 323/380
$C = 1$	0.9 342/380	0.95 19/20	0.1 2/20	0.15 57/380

$$P(c|\text{do}(f)) = \sum_d P(c|\text{do}(d))P(d|\text{do}(f))$$

Casos especiales

La disputa contra el industria del tabaco


$F = 0$	$F = 1$
0.5	0.5

F : Fumar

C : Cancer

U : Otras variables

D : Depósitos en pulmones



$P(d f)$	$D = 0$	$D = 1$
$F = 0$	0.95	0.05
$F = 1$	0.05	0.95

$$P(d|\text{do}(f)) = P(d|f)$$


$$P(c|\text{do}(d)) = \sum_f P(c|d, f)P(f)$$

$P(c d, f)$	$F = 0$		$F = 1$	
	$D = 0$	$D = 1$	$D = 0$	$D = 1$
$C = 0$	0.1 38/380	0.05 1/20	0.9 18/20	0.85 323/380
$C = 1$	0.9 342/380	0.95 19/20	0.1 2/20	0.15 57/380

$$P(c|\text{do}(f)) = \sum_d P(c|\text{do}(d))P(d|\text{do}(f)) = \sum_d P(d|f) \sum_{f'} P(c|d, f')P(f')$$

Frontdoor criterion


Doble aplicación de backdoor



$$P(y|\text{do}(t)) = \sum_m P(m|t) \sum_{t'} P(y|m, t') P(t')$$

Frontdoor criterion

Doble aplicación de backdoor



$$P(y|\text{do}(t)) = \sum_m P(m|t) \sum_{t'} P(y|m, t') P(t')$$


Frontdoor criterion

Un conjunto de variables mediadoras M satisfacen el criterio *frontdoor* entre un tratamiento T y una variable objetivo Y si:

1. M media completamente el efecto causal de T en Y
2. No hay caminos traseros abiertos entre M y T
3. Todos los caminos traseros entre M e Y están bloqueados por T

¿Frontdoor criterion?

Doble aplicación de backdoor




Frontdoor criterion

Un conjunto de variables mediadoras M satisfacen el criterio *frontdoor* entre un tratamiento T y una variable objetivo Y si:

1. M media completamente el efecto causal de T en Y
2. No hay caminos traseros abiertos entre M y T
3. Todos los caminos traseros entre M e Y están bloqueados por T

Frontdoor criterion

Doble aplicación de backdoor




Frontdoor criterion

Un conjunto de variables mediadoras M satisfacen el criterio *frontdoor* entre un tratamiento T y una variable objetivo Y si:

1. M media completamente el efecto causal de T en Y
2. No hay caminos traseros abiertos entre M y T
3. Todos los caminos traseros entre M e Y están bloqueados por T


Criterio propio

Doble aplicación de backdoor



Criterio propio


Doble aplicación de backdoor



$$P(m|\text{do}(t)) =$$

Criterio propio


Doble aplicación de backdoor



$$P(m|\text{do}(t)) = ? \text{ (hay controles?)}$$

Criterio propio


Doble aplicación de backdoor



$$P(m|\text{do}(t)) = ? \text{ (hay controles?)}$$

Criterio propio


Doble aplicación de backdoor



$$P(m|\text{do}(t)) = ? \text{ (hay controles?)}$$

Criterio propio


Doble aplicación de backdoor



$$P(m|\text{do}(t)) = \sum_{w_1} P(m|t, w_1)P(w_1)$$

Criterio propio

Doble aplicación de backdoor




$$P(m|\text{do}(t)) = \sum_{w_1} P(m|t, w_1)P(w_1)$$

$$P(y|\text{do}(m)) = ?$$

Criterio propio

Doble aplicación de backdoor




$$P(m|\text{do}(t)) = \sum_{w_1} P(m|t, w_1)P(w_1)$$

$$P(y|\text{do}(m)) = ?$$

Criterio propio

Doble aplicación de backdoor




$$P(m|\text{do}(t)) = \sum_{w_1} P(m|t, w_1)P(w_1)$$

$$P(y|\text{do}(m)) = ?$$

Criterio propio

Doble aplicación de backdoor




$$P(m|\text{do}(t)) = \sum_{w_1} P(m|t, w_1)P(w_1)$$

$$P(y|\text{do}(m)) = \sum_{t, w_1, w_2} P(y|m, t, w_1, w_2)P(t, w_1, w_2)$$

Criterio propio

Doble aplicación de backdoor

$$P(y|\text{do}(t)) = \sum_m P(y|\text{do}(m))P(m|\text{do}(t))$$




$$P(m|\text{do}(t)) = \sum_{w_1} P(m|t, w_1)P(w_1)$$

$$P(y|\text{do}(m)) = \sum_{t, w_1, w_2} P(y|m, t, w_1, w_2)P(t, w_1, w_2)$$


Instrumental variables

Diferencia entre efectos causales




Instrumental variables

Diferencia entre efectos causales



Instrumental variables

Diferencia entre efectos causales



$$P(y|\text{do}(z)) = \alpha \beta z$$

$$P(x|\text{do}(z)) = \alpha z$$

$$P(y|\text{do}(x)) = P(y|\text{do}(z))/P(x|\text{do}(z))$$

do-calculus

Criterio general

do-calculus

Criterio general

Determina el estimador de un efecto causal entre los tratamientos $\mathbf{T}$ y los objetivos $\mathbf{Y}$ dadas las co-variables $\mathbf{Q}$ (siempre que sea identificable).

$$P(\mathbf{y}|\text{do}(\mathbf{t}), \mathbf{q})$$

do-calculus

Criterio general

Determina el estimador de un efecto causal entre los tratamientos T y los objetivos Y dadas las co-variables Q (siempre que sea identificable).

$$P(\mathbf{y}|\text{do}(\mathbf{t}), \mathbf{q})$$

Regla 1 (Ignorar una observación):

$$P(\mathbf{v}|\mathbf{x}, \mathbf{c}) = P(\mathbf{v}|\mathbf{c}) \quad \text{si} \quad \mathbf{V} \perp\!\!\!\perp_G \mathbf{X} \mid \mathbf{C} \quad (\text{d-separación})$$

do-calculus

Criterio general

Determina el estimador de un efecto causal entre los tratamientos T y los objetivos Y dadas las co-variables Q (siempre que sea identificable).

$$P(\mathbf{y}|\text{do}(\mathbf{t}), \mathbf{q})$$

Regla 1 (Ignorar una observación):

$$P(\mathbf{v}|\text{do}(\mathbf{z}), \mathbf{x}, \mathbf{c}) = P(\mathbf{v}|\text{do}(\mathbf{z}), \mathbf{c}) \quad \text{si} \quad \mathbf{V} \perp\!\!\!\perp_{G_{\overline{\mathbf{Z}}}} \mathbf{X} \mid \mathbf{C} \quad (\text{d-separación})$$

do-calculus

Criterio general

Determina el estimador de un efecto causal entre los tratamientos T y los objetivos Y dadas las co-variables Q (siempre que sea identificable).

$$P(\mathbf{y}|\text{do}(\mathbf{t}), \mathbf{q})$$

Regla 1 (Ignorar una observación):

$$P(\mathbf{v}|\mathbf{x}, \mathbf{c}) = P(\mathbf{v}|\mathbf{c}) \quad \text{si} \quad \mathbf{V} \perp\!\!\!\perp_G \mathbf{X} \mid \mathbf{C} \quad (\text{d-separación})$$

do-calculus

Criterio general

Determina el estimador de un efecto causal entre los tratamientos T y los objetivos Y dadas las co-variables Q (siempre que sea identificable).

$$P(\mathbf{y}|\text{do}(\mathbf{t}), \mathbf{q})$$

Regla 1 (Ignorar una observación):

$$P(\mathbf{v}|\mathbf{x}, \mathbf{c}) = P(\mathbf{v}|\mathbf{c}) \quad \text{si} \quad \mathbf{V} \perp\!\!\!\perp_G \mathbf{X} \mid \mathbf{C} \quad (\text{d-separación})$$

Regla 2 (Intervención como observación):

$$P(\mathbf{v}|\text{do}(\mathbf{x}), \mathbf{c}) = P(\mathbf{v}|\mathbf{x}, \mathbf{c}) \quad \text{si} \quad \mathbf{V} \perp\!\!\!\perp_{G_{\underline{\mathbf{X}}}} \mathbf{X} \mid \mathbf{C} \quad (\text{no backdoor})$$

do-calculus

Criterio general

Determina el estimador de un efecto causal entre los tratamientos T y los objetivos Y dadas las co-variables Q (siempre que sea identificable).

$$P(\mathbf{y}|\text{do}(\mathbf{t}), \mathbf{q})$$

Regla 1 (Ignorar una observación):

$$P(\mathbf{v}|\mathbf{x}, \mathbf{c}) = P(\mathbf{v}|\mathbf{c}) \quad \text{si} \quad \mathbf{V} \perp\!\!\!\perp_G \mathbf{X} \mid \mathbf{C} \quad (\text{d-separación})$$

Regla 2 (Intervención como observación):

$$P(\mathbf{v}|\text{do}(\mathbf{z}), \text{do}(\mathbf{x}), \mathbf{c}) = P(\mathbf{v}|\text{do}(\mathbf{z}), \mathbf{x}, \mathbf{c}) \quad \text{si} \quad \mathbf{V} \perp\!\!\!\perp_{G_{\overline{\mathbf{Z}}, \mathbf{X}}} \mathbf{X} \mid \mathbf{C} \quad (\text{no backdoor})$$

do-calculus

Criterio general

Determina el estimador de un efecto causal entre los tratamientos T y los objetivos Y dadas las co-variables Q (siempre que sea identificable).

$$P(\mathbf{y}|\text{do}(\mathbf{t}), \mathbf{q})$$

Regla 1 (Ignorar una observación):

$$P(\mathbf{v}|\mathbf{x}, \mathbf{c}) = P(\mathbf{v}|\mathbf{c}) \quad \text{si} \quad \mathbf{V} \perp\!\!\!\perp_G \mathbf{X} \mid \mathbf{C} \quad (\text{d-separación})$$

Regla 2 (Intervención como observación):

$$P(\mathbf{v}|\text{do}(\mathbf{x}), \mathbf{c}) = P(\mathbf{v}|\mathbf{x}, \mathbf{c}) \quad \text{si} \quad \mathbf{V} \perp\!\!\!\perp_{G_{\underline{\mathbf{X}}}} \mathbf{X} \mid \mathbf{C} \quad (\text{no backdoor})$$

do-calculus

Criterio general

Determina el estimador de un efecto causal entre los tratamientos T y los objetivos Y dadas las co-variables Q (siempre que sea identificable).

$$P(\mathbf{y}|\text{do}(\mathbf{t}), \mathbf{q})$$

Regla 1 (Ignorar una observación):

$$P(\mathbf{v}|\mathbf{x}, \mathbf{c}) = P(\mathbf{v}|\mathbf{c}) \quad \text{si} \quad \mathbf{V} \perp\!\!\!\perp_G \mathbf{X} \mid \mathbf{C} \quad (\text{d-separación})$$

Regla 2 (Intervención como observación):

$$P(\mathbf{v}|\text{do}(\mathbf{x}), \mathbf{c}) = P(\mathbf{v}|\mathbf{x}, \mathbf{c}) \quad \text{si} \quad \mathbf{V} \perp\!\!\!\perp_{G_{\underline{\mathbf{X}}}} \mathbf{X} \mid \mathbf{C} \quad (\text{no backdoor})$$

Regla 3 (Ignorar una intervención):

$$P(\mathbf{c}|\text{do}(\mathbf{x})) = P(\mathbf{c}) \quad \text{si} \quad \mathbf{C} \perp\!\!\!\perp_{G_{\overline{\mathbf{X}}}} \mathbf{X} \quad (\text{controles } \mathbf{c})$$

do-calculus

Criterio general

Determina el estimador de un efecto causal entre los tratamientos T y los objetivos Y dadas las co-variables Q (siempre que sea identificable).

$$P(\mathbf{y}|\text{do}(\mathbf{t}), \mathbf{q})$$

Regla 1 (Ignorar una observación):

$$P(\mathbf{v}|\mathbf{x}, \mathbf{c}) = P(\mathbf{v}|\mathbf{c}) \quad \text{si} \quad \mathbf{V} \perp\!\!\!\perp_G \mathbf{X} \mid \mathbf{C} \quad (\text{d-separación})$$

Regla 2 (Intervención como observación):

$$P(\mathbf{v}|\text{do}(\mathbf{x}), \mathbf{c}) = P(\mathbf{v}|\mathbf{x}, \mathbf{c}) \quad \text{si} \quad \mathbf{V} \perp\!\!\!\perp_{G_{\underline{\mathbf{X}}}} \mathbf{X} \mid \mathbf{C} \quad (\text{no backdoor})$$

Regla 3 (Ignorar una intervención):

$$P(\mathbf{c}|\text{do}(\mathbf{x}), \mathbf{v}) = P(\mathbf{c}|\mathbf{v}) \quad \text{si} \quad \mathbf{C} \perp\!\!\!\perp_{G_{\overline{\mathbf{X}(\mathbf{V})}}} \mathbf{X} \mid \mathbf{V} \quad (\text{controles } \mathbf{c})$$

do-calculus

Criterio general

Determina el estimador de un efecto causal entre los tratamientos T y los objetivos Y dadas las co-variables Q (siempre que sea identificable).

$$P(\mathbf{y}|\text{do}(\mathbf{t}), \mathbf{q})$$

Regla 1 (Ignorar una observación):

$$P(\mathbf{v}|\mathbf{x}, \mathbf{c}) = P(\mathbf{v}|\mathbf{c}) \quad \text{si} \quad \mathbf{V} \perp\!\!\!\perp_G \mathbf{X} \mid \mathbf{C} \quad (\text{d-separación})$$

Regla 2 (Intervención como observación):

$$P(\mathbf{v}|\text{do}(\mathbf{x}), \mathbf{c}) = P(\mathbf{v}|\mathbf{x}, \mathbf{c}) \quad \text{si} \quad \mathbf{V} \perp\!\!\!\perp_{G_{\underline{\mathbf{X}}}} \mathbf{X} \mid \mathbf{C} \quad (\text{no backdoor})$$

Regla 3 (Ignorar una intervención):

$$P(\mathbf{c}|\text{do}(\mathbf{x}), \mathbf{v}) = P(\mathbf{c}|\mathbf{v}) \quad \text{si} \quad \mathbf{C} \perp\!\!\!\perp_{G_{\overline{\mathbf{X}(V)}}} \mathbf{X} \mid \mathbf{V} \quad (\text{controles } \mathbf{c})$$

Seguro vale para intervenciones que no son ancestros de V , $X(V)$, porque V puede ser collider

do-calculus

Criterio general

Determina el estimador de un efecto causal entre los tratamientos T y los objetivos Y dadas las co-variables Q (siempre que sea identificable).

$$P(\mathbf{y}|\text{do}(\mathbf{t}), \mathbf{q})$$

Regla 1 (Ignorar una observación):

$$P(\mathbf{v}|\mathbf{x}, \mathbf{c}) = P(\mathbf{v}|\mathbf{c}) \quad \text{si} \quad \mathbf{V} \perp\!\!\!\perp_G \mathbf{X} \mid \mathbf{C} \quad (\text{d-separación})$$

Regla 2 (Intervención como observación):

$$P(\mathbf{v}|\text{do}(\mathbf{x}), \mathbf{c}) = P(\mathbf{v}|\mathbf{x}, \mathbf{c}) \quad \text{si} \quad \mathbf{V} \perp\!\!\!\perp_{G_{\underline{\mathbf{X}}}} \mathbf{X} \mid \mathbf{C} \quad (\text{no backdoor})$$

Regla 3 (Ignorar una intervención):

$$P(\mathbf{c}|\text{do}(\mathbf{z}), \text{do}(\mathbf{x}), \mathbf{v}) = P(\mathbf{c}|\text{do}(\mathbf{z}), \mathbf{v}) \quad \text{si} \quad \mathbf{C} \perp\!\!\!\perp_{G_{\overline{\mathbf{Z}}, \overline{\mathbf{X}(V)}}} \mathbf{X} \mid \mathbf{V} \quad (\text{controles } \mathbf{c})$$

Seguro vale para intervenciones que no son ancestros de V , $X(V)$, porque V puede ser collider

do-calculus

Criterio general

Determina el estimador de un efecto causal entre los tratamientos T y los objetivos Y dadas las co-variables Q (siempre que sea identificable).

$$P(\mathbf{y}|\text{do}(\mathbf{t}), \mathbf{q})$$

Regla 1 (Ignorar una observación):

$$P(\mathbf{v}|\mathbf{x}, \mathbf{c}) = P(\mathbf{v}|\mathbf{c}) \quad \text{si} \quad \mathbf{V} \perp\!\!\!\perp_G \mathbf{X} \mid \mathbf{C} \quad (\text{d-separación})$$

Regla 2 (Intervención como observación):

$$P(\mathbf{v}|\text{do}(\mathbf{x}), \mathbf{c}) = P(\mathbf{v}|\mathbf{x}, \mathbf{c}) \quad \text{si} \quad \mathbf{V} \perp\!\!\!\perp_{G_{\underline{\mathbf{X}}}} \mathbf{X} \mid \mathbf{C} \quad (\text{no backdoor})$$


Regla 3 (Ignorar una intervención):

$$P(\mathbf{c}|\text{do}(\mathbf{x}), \mathbf{v}) = P(\mathbf{c}|\mathbf{v}) \quad \text{si} \quad \mathbf{C} \perp\!\!\!\perp_{G_{\overline{\mathbf{X}(V)}}} \mathbf{X} \mid \mathbf{V} \quad (\text{controles } \mathbf{c})$$

Seguro vale para intervenciones que no son ancestros de V , $X(V)$, porque V puede ser collider

do-calculus

Regla 3. Ignorar una intervención.




$$P(q|\text{do}(t)) = P(q)$$

Si q son variables ascendentes a t ,
 q no se ve afectado por la intervención en t

do-calculus

Regla 3. Ignorar una intervención.




$$P(q|\text{do}(t), y) \neq P(q|y)$$

Si q son variables ascendentes a t ,
 q no se ve afectado por la intervención en t

salvo que algún collider abra el flujo de inferencia

do-calculus


Derivando frontdoor y backdoor



do-calculus

Derivando frontdoor y backdoor


$$P(y|\text{do}(t)) = \sum_m P(y, m|\text{do}(t))$$



do-calculus

Derivando frontdoor y backdoor


$$\begin{aligned}P(y|\text{do}(t)) &= \sum_m P(y, m|\text{do}(t)) \\&= \sum_m P(y|\text{do}(t), m)P(m|\text{do}(t))\end{aligned}$$




do-calculus

Derivando frontdoor y backdoor

$$\begin{aligned}P(y|\text{do}(t)) &= \sum_m P(y, m|\text{do}(t)) \\&= \sum_m P(y|\text{do}(t), m)P(m|\text{do}(t))\end{aligned}$$




$$P(m|\text{do}(t)) =$$



do-calculus


Derivando frontdoor y backdoor

$$\begin{aligned} P(y|\text{do}(t)) &= \sum_m P(y, m|\text{do}(t)) \\ &= \sum_m P(y|\text{do}(t), m)P(m|\text{do}(t)) \end{aligned}$$



$$P(m|\text{do}(t)) =$$


Intervención como observación
no backdoor entre t y m



do-calculus


Derivando frontdoor y backdoor

$$\begin{aligned}P(y|\text{do}(t)) &= \sum_m P(y, m|\text{do}(t)) \\&= \sum_m P(y|\text{do}(t), m)P(m|\text{do}(t))\end{aligned}$$



$$P(m|\text{do}(t)) \stackrel{2}{=} P(m|t)$$

Intervención como observación
no backdoor entre t y m




do-calculus

Derivando frontdoor y backdoor

$$\begin{aligned} P(y|\text{do}(t)) &= \sum_m P(y, m|\text{do}(t)) \\ &= \sum_m P(y|\text{do}(t), m) \textcolor{red}{P}(m|t) \end{aligned}$$

$$P(m|\text{do}(t)) \stackrel{2}{=} P(m|t)$$





do-calculus

Derivando frontdoor y backdoor

$$\begin{aligned}P(y|\text{do}(t)) &= \sum_m P(y, m|\text{do}(t)) \\&= \sum_m P(y|\text{do}(t), m)P(m|t)\end{aligned}$$

$$P(m|\text{do}(t)) \stackrel{2}{=} P(m|t)$$


$$P(y|\text{do}(t), m) =$$



do-calculus

Derivando frontdoor y backdoor


$$\begin{aligned}P(y|\text{do}(t)) &= \sum_m P(y, m|\text{do}(t)) \\&= \sum_m P(y|\text{do}(t), m)P(m|t)\end{aligned}$$



$$P(m|\text{do}(t)) \stackrel{2}{=} P(m|t)$$

$$P(y|\text{do}(t), m) \stackrel{2}{=} P(y|\text{do}(t), \text{do}(m))$$


Intervención como observación
No hay backdoor entre m e y dado $\text{do}(t)$



do-calculus


Derivando frontdoor y backdoor

$$\begin{aligned}P(y|\text{do}(t)) &= \sum_m P(y, m|\text{do}(t)) \\&= \sum_m P(y|\text{do}(t), m)P(m|t)\end{aligned}$$



$$P(m|\text{do}(t)) \stackrel{2}{=} P(m|t)$$


$$P(y|\text{do}(t), m) \stackrel{2}{=} P(y|\text{do}(t), \text{do}(m)) =$$



do-calculus

Derivando frontdoor y backdoor



$$\begin{aligned} P(y|\text{do}(t)) &= \sum_m P(y, m|\text{do}(t)) \\ &= \sum_m P(y|\text{do}(t), m)P(m|t) \end{aligned}$$



$$P(m|\text{do}(t)) \stackrel{2}{=} P(m|t)$$

$$P(y|\text{do}(t), m) \stackrel{2}{=} P(y|\text{do}(t), \text{do}(m)) \stackrel{3}{=} P(y|\text{do}(m))$$


Ignorar una intervención
No hay controles descendentes a t



do-calculus

Derivando frontdoor y backdoor

$$\begin{aligned}P(y|\text{do}(t)) &= \sum_m P(y, m|\text{do}(t)) \\&= \sum_m P(y|\text{do}(t), m)P(m|t)\end{aligned}$$




$$P(m|\text{do}(t)) \stackrel{2}{=} P(m|t)$$

$$P(y|\text{do}(t), m) \stackrel{2}{=} P(y|\text{do}(t), \text{do}(m)) \stackrel{3}{=} P(y|\text{do}(m)) = \sum_{t'} P(y, t'|\text{do}(m))$$

do-calculus

Derivando frontdoor y backdoor

$$\begin{aligned}P(y|\text{do}(t)) &= \sum_m P(y, m|\text{do}(t)) \\&= \sum_m P(y|\text{do}(t), m)P(m|t)\end{aligned}$$




$$P(m|\text{do}(t)) \stackrel{2}{=} P(m|t)$$

$$P(y|\text{do}(t), m) \stackrel{2}{=} P(y|\text{do}(t), \text{do}(m)) \stackrel{3}{=} P(y|\text{do}(m)) = \sum_{t'} P(y|\text{do}(m), t')P(t'|\text{do}(m))$$

do-calculus


Derivando frontdoor y backdoor

$$\begin{aligned} P(y|\text{do}(t)) &= \sum_m P(y, m|\text{do}(t)) \\ &= \sum_m P(y|\text{do}(t), m)P(m|t) \end{aligned}$$



$$P(m|\text{do}(t)) \stackrel{2}{=} P(m|t)$$


$$P(y|\text{do}(t), m) \stackrel{2}{=} P(y|\text{do}(t), \text{do}(m)) \stackrel{3}{=} P(y|\text{do}(m)) = \sum_{t'} P(y|\text{do}(m), t') \textcolor{red}{P(t'|\text{do}(m))}$$



do-calculus


Derivando frontdoor y backdoor

$$\begin{aligned} P(y|\text{do}(t)) &= \sum_m P(y, m|\text{do}(t)) \\ &= \sum_m P(y|\text{do}(t), m)P(m|t) \end{aligned}$$



$$P(m|\text{do}(t)) \stackrel{2}{=} P(m|t)$$

$$P(y|\text{do}(t), m) \stackrel{2}{=} P(y|\text{do}(t), \text{do}(m)) \stackrel{3}{=} P(y|\text{do}(m)) \stackrel{3}{=} \sum_{t'} P(y|\text{do}(m), t') P(t')$$




Ignorar una intervención
Intervenir en m no afecta a t

do-calculus


Derivando frontdoor y backdoor

$$\begin{aligned}P(y|\text{do}(t)) &= \sum_m P(y, m|\text{do}(t)) \\&= \sum_m P(y|\text{do}(t), m)P(m|t)\end{aligned}$$



$$P(m|\text{do}(t)) \stackrel{2}{=} P(m|t)$$


$$P(y|\text{do}(t), m) \stackrel{2}{=} P(y|\text{do}(t), \text{do}(m)) \stackrel{3}{=} P(y|\text{do}(m)) \stackrel{3}{=} \sum_{t'} P(y|\text{do}(m), t')P(t')$$



do-calculus

Derivando frontdoor y backdoor



$$\begin{aligned} P(y|\text{do}(t)) &= \sum_m P(y, m|\text{do}(t)) \\ &= \sum_m P(y|\text{do}(t), m)P(m|t) \end{aligned}$$



$$P(m|\text{do}(t)) \stackrel{2}{=} P(m|t)$$

$$P(y|\text{do}(t), m) \stackrel{2}{=} P(y|\text{do}(t), \text{do}(m)) \stackrel{3}{=} P(y|\text{do}(m)) \stackrel{3}{=} \sum_{t'} P(y|m, t')P(t')$$


Intervención como observación
No hay backdoor entre m e y dado t



do-calculus

Derivando frontdoor y backdoor

$$\begin{aligned} P(y|\text{do}(t)) &= \sum_m P(y, m|\text{do}(t)) \\ &= \sum_m P(y|\text{do}(t), m)P(m|t) \end{aligned}$$



$$P(m|\text{do}(t)) \stackrel{2}{=} P(m|t)$$

$$P(y|\text{do}(t), m) \stackrel{2}{=} P(y|\text{do}(t), \text{do}(m)) \stackrel{3}{=} P(y|\text{do}(m)) \stackrel{3}{=} \sum_{t'} P(y|m, t')P(t')$$


Derivamos:

- Dos casos especiales de backdoor, $P(m|\text{do}(t))$ y $P(y|\text{do}(m))$.
- Y un caso especial de frontdoor, $P(y|\text{do}(t))$.

do-calculus

Derivando frontdoor y backdoor

$$\begin{aligned}P(y|\text{do}(t)) &= \sum_m P(y, m|\text{do}(t)) \\&= \sum_m P(m|t) \sum_{t'} P(y|m, t')P(t')\end{aligned}$$



$$P(m|\text{do}(t)) \stackrel{2}{=} P(m|t)$$

$$P(y|\text{do}(t), m) \stackrel{2}{=} P(y|\text{do}(t), \text{do}(m)) \stackrel{3}{=} P(y|\text{do}(m)) \stackrel{3}{=} \sum_{t'} P(y|m, t')P(t')$$