

Final

Inferencia Bayesiana Causal

2do cuatrimestre 2025 | ECyT UNSAM

Profesor: Gustavo Landfried

UNSAM | Muttdata | Bayes Plurinacional

Índice

1. Monty Hall extendido (obligatorio)	1
2. Efectos causales en la industria (obligatorio)	2
3. Toma de decisiones temporales (optativo)	3
3.1. Inferencia	3

1. Monty Hall extendido (obligatorio)

El archivo `datos/NoMontyHall.csv` contiene datos de la posición de la caja elegida c , la pista s , y la posición de la caja r para 2000 episodios, similar a la que vimos en la práctica 1. En este ejercicio únicamente se pide que suban un archivo `csv` con la evidencia (predicción del dato observado) que cada uno de los modelos (Base, Monty Hall y Alternativo) hace de cada uno de los los 2000 episodios. El archivo debe llamarse `EvidenciasNoMontyHall.csv` y debe contener 3 columnas (`base`, `montyHall`, `alternativo`) y 2000 filas (una por episodio). Los datos fueron generados con el modelo Monty Hall, salvo en algunas ocasiones en los que la persona que da la pista se olvida de tener en cuenta la caja elegida, y actúa siguiendo el modelo Base. Los tres modelos se especifican a continuación.




Figura 1: Extensión de los modelos causales alternativos a T episodios mediante la notación de “placas”. El subíndice t representa las repeticiones.

Las distribuciones condicionales a priori sobre r y c son iguales en ambos modelos.

$$P(r|M) = P(r) = \frac{r=0}{1/3} \mid \frac{r=1}{1/3} \mid \frac{r=2}{1/3} \quad P(c|M) = P(c) = \frac{c=0}{1/3} \mid \frac{c=1}{1/3} \mid \frac{c=2}{1/3}$$

La única diferencia entre los modelos aparece en la distribución condicional sobre la pista. En el modelo Base solo depende del regalo r .

$$P(s|r, M_0) = \begin{array}{c|ccc} & s=0 & s=1 & s=2 \\ \hline r=0 & 0 & 1/2 & 1/2 \\ r=1 & 1/2 & 0 & 1/2 \\ r=2 & 1/2 & 1/2 & 0 \end{array}$$

Y en el modelo Monty Hall depende del regalo r y la caja cerrada c . Para simplificar, mostraremos los valores cuando $c = 1$.

$$P(s|r, c=1, M_1) = \begin{array}{c|ccc} (c=0) & s=0 & s=1 & s=2 \\ \hline r=0 & 0 & 1/2 & 1/2 \\ r=1 & 0 & 0 & 1 \\ r=2 & 0 & 1 & 0 \end{array}$$

Por último mostramos la especificación del modelo Alternativo. En este modelo se agregan dos variables. La primera es una variable de “acción” (a_t) que indica el comportamiento adquirido por la persona que da la pista en el episodio t . La segunda es la probabilidad de realizar la acción p . En este caso, ambas variables son ocultas.




Figura 2: Realidad causal subyacente que generó el conjunto de datos del archivo NoMontyHall.csv, especificado mediante la notación de *factor graph*.

2. Efectos causales en la industria (obligatorio)

Una de las empresas más importantes de Latinoamérica, dedicada a vender productos a supermercados, restaurantes y otro tipo de comercios, ofrece créditos a sus clientes con el objetivo de aumentar las ventas. Estos créditos tienen dos características: el monto disponible a usar como crédito (`monto_credito`) y los días de plazo que tienen para cancelar el crédito (`plazo`). El sistema de créditos fue implementado por un equipo externo, el cuál creó un modelo determinista de caja negra que determina el nivel `monto_credito` en función del promedio de compras del año pasado (`compras_pasadas`), un nivel de riesgo creado por ellos mediante un sistema de scoring

absolutamente desconocido (`nivel_riesgo`) y de la cantidad de días que se le otorga para hacer el pago del crédito (`plazo`), que sabemos está calculado en función del nivel de riesgo y otras variables que desconocemos. Conocemos algunas variables relevantes de los clientes como son su sector comercial (`sector`) y los años que lleva como cliente de la empresa (`antiguedad`).

La empresa quiere conocer el efecto causal que el `monto_credito` tiene sobre el volumen de ventas del mes (`ventas`). Sin embargo, hasta ahora no se ha realizado ningún experimento aleatorizado (de tipo A/B testing) para evaluar el efecto causal, por lo que nos piden hacer un análisis de efecto causal analizando únicamente los datos observados. El problema es que no conocemos la estructura causal subyacente, ni las variables forman parte de esa estructura causal. Pero en la empresa nos insisten que quieren conocer el efecto causal. Y como empleados nos vemos obligados a reportar un número que sea lo más razonable posible.

Por razones de permisos, solo tuvimos acceso los datos de un mes determinado. El archivo `data_credito.csv` contiene la información de `compras_pasadas`, `nivel_riesgo`, `plazo`, `monto_credito`, `sector`, `antiguedad` y los ingresos por ventas de ese mes `ventas`. Cada fila representa un cliente distinto.

Subir un archivo con el análisis, llamado `analisis_credito.py`. El archivo debe contener dos funciones finales. La primera debe reportar el la esperanza del efecto causal condicional dado el plazo (`def CATE(plazo: int) -> float:`) y la segunda debe reportar la esperanza del efecto causal general ATE (`def ATE(mean_plazo: float) -> float:`).

3. Toma de decisiones temporales (optativo)

El ejercicio de inferencia es una Monty Hall en el cual el sesgo de la persona que esconde el regalo cambia a lo largo del año y se repite todos los años. Para ello se provee un archivo `regalos.csv` con la cantidad de veces n_{ij} que se observó el regalo en una caja (columna i) en cierto día del año (fila j). El objetivo de esta tarea es crear un archivo de respuesta `temporal.csv`, con las mismas columnas y filas, pero que contenga la estimación de la probabilidad de la posición del regalo en la caja i el día j del año, $\mathbb{P}(r_j = i)$. La evaluación del examen de inferencia será el producto de todas las predicciones elevadas por la probabilidad correcta $P(r_j = i)$.

$$\mathcal{V} = \prod_j \prod_i \mathbb{P}(r_j = i)^{P(r_j=i)} \quad (1)$$

Además, el `temporal.csv` debe incluir una columna adicional que indique la caja que se decide elegir en cada día j del año, c_j . Tener en cuenta que la persona que da la pista no tiene sesgo, elige con misma probabilidad cualquiera de las cajas que están libres (cajas que no contienen el regalo y que no son la caja elegida en ese día c_j). La evaluación del problema de toma decisiones será el producto de las distribuciones de probabilidad a posteriori sobre la posición del regalo para cada posible pista, s_j , elevada por el producto de la probabilidad a posteriori real de la posición del regalo multiplicada por la probabilidad de recibir la pista, s_j .

$$\mathcal{V} = \prod_j \prod_i \prod_{\substack{\text{Pista} \\ k \neq c_j}} \mathbb{P}(r_j = i | s_j = k, c_j)^{P(r_j=i | s_j=k, c_j) P(s_j=k | c_j)} \quad (2)$$

3.1. Inferencia

En esta sección se dan algunas ideas para resolver el problema. En primer lugar empezamos pensando un problema más simple, visto en la unidad 1. Para inferir la probabilidad p de una variable aleatoria binaria b podemos proponer un modelo conjugado Beta-Binomial.

$$\begin{aligned} P(p) &= \text{Beta}(p | \alpha, \beta) \\ P(b | p) &= \text{Bernoulli}(b | p) \end{aligned}$$

Si en nuestra base de datos observamos N_0 realizaciones de $b = 0$ y N_1 realizaciones de $b = 1$, luego el posterior de p es

$$P(p|\text{Datos}) = \text{Beta}(\alpha + N_0, \beta + N_1)$$

Cuando la variable aleatoria no es binarias, como ocurre con la posición del regalo r en el problema Monty Hall, $r \in \{0, 1, 2\}$, se puede proponer un modelo conjugado Dirichlet-Categórica.

$$P(\mathbf{p}) = \text{Dirichlet}(\mathbf{p}|\alpha_0, \alpha_1, \alpha_2)$$

$$P(r|\mathbf{p}) = \text{Categorical}(r|\mathbf{p})$$

donde $\mathbf{p}$ es un vector de probabilidades. Si en nuestra base de datos observamos N_0 realizaciones de $r = 0$ y N_1 realizaciones de $r = 1$, y N_2 realizaciones de $r = 2$, luego el posterior de $\mathbf{p}$ es $\text{Dirichlet}(\alpha_0 + N_0, \alpha_1 + N_1, \alpha_2 + N_2)$. En la siguiente figura se muestran el 2-simplex de tres distribución Dirichlet distintas.




Figura 3: Distribuciones Dirichlet

Lo más sencillo para resolver este problema sería entonces proponer un modelo Dirichlet-Categórico independiente para cada día del año y computar el posterior con la información específica a la cantidad de observaciones N_0 , N_1 y N_2 correspondientes a ese día, $\text{Dirichlet}(\alpha_0 + N_0, \alpha_1 + N_1, \alpha_2 + N_2)$.




Figura 4: Modelo con sesgos independientes

Si bien el sesgo cambia, esto no significa que sea independiente del sesgo en los pasos temporales contiguos. Por el contrario, verán que el cambio en el sesgo es lento, es decir, el sesgo en un período temporal se parece mucho al sesgo en los períodos temporales contiguos. Para aprovechar esta información vamos a proponer un modelo de historia completa, en el que todos los días están conectados entre sí por la influencia que el sesgo de un día tiene en el sesgo del día siguiente, donde el sesgo del día 365 afecta al sesgo del día 1, el sesgo del día 1 afecta al sesgo del día 2 y así sucesivamente.




Figura 5: Especificación mediante factor graph del modelo Monty Hall con sesgo cíclico.

Notar que si el sesgo de la persona se repite todos los años, la especificación del modelo mediante factor graph tendrá naturalmente un ciclo. Esto contrasta con los modelos causales vistos en la materia, en los que se requería que fueran DAGs (Directed Acyclic Graphs). Una de las razones por las cuales se requiere que los modelos sean DAGs tiene que ver con preservar la relación causa-efecto. Pero además, solo los DAGs inducen descomposiciones válidas respecto de la regla de la cadena.

Sin embargo, es posible especificar modelos con ciclos y usar métodos eficientes de inferencia. En particular, el algoritmo *loopy belief propagation* visto en la unidad de series temporales de la materia, también alcanza convergencia respecto de las distribuciones marginales del modelo luego de una cantidad finita de iteraciones. En este ejercicio proponemos que realicen una simplificación y aproximen el posterior del sesgo mediante un promedio ponderado de las últimas estimaciones del sesgo de sus vecinos y la contribución de los datos.

$$p(\mathbf{p}) = \text{Dirichlet} \left(\lambda \left(\frac{\alpha_{0,t-1}}{2} + \frac{\alpha_{0,t+1}}{2} \right) + N_{0,t}, \dots \right) \quad (3)$$

Donde el parámetro λ controla la memoria respecto de los datos vecinos. Existen otras formas de resolver este problema. Elijan la que prefieran. Pueden usar Chat Bots para realizar el trabajo mientras entiendan lo que están haciendo. Lo único que importa es que las predicciones de los regalos reportadas en el csv sean lo más parecidas a las probabilidades reales con la que se generaron los datos. Notar que dado que el modelo es,

$$P(\mathbf{p}) = \text{Dirichlet}(\mathbf{p} | \alpha_0, \alpha_1, \alpha_2) \quad P(r | \mathbf{p}) = \text{Categorical}(r | \mathbf{p})$$

la predicción marginal de r es,

$$p(r = 0) = \frac{\alpha_0}{\alpha_0 + \alpha_1 + \alpha_2}$$

Suban en el `temporal.csv` estas probabilidades para cada caja (columna) y para cada día (fila). Por último, no se olviden de agregar una columna adicional en el `temporal.csv` con la caja que conviene elegir para recibir la pista.