

Parcial 2

Inferencia Bayesiana Causal

2do cuatrimestre 2025 | ECyT UNSAM

Profesor: Gustavo Landfried

UNSAM | Muttdata | Bayes Plurinacional

Índice

1. Flujo	1
2. Backdoor	2
3. do-operator	2
4. Ignorability	2
5. Decisiones	3

Introducción

Este parcial contiene una lista de preguntas junto con una lista exhaustiva de respuestas mutuamente contradictorias. A diferencia de los enunciados de tipo “multiple choice” en los que se pide seleccionar una única opción, aquí se pide que distribuyan creencias entre las diferentes opciones, asegurándose que el valor asignado sea positivo y la suma sea 1. La evaluación será el producto de las creencias asignadas a las respuestas correctas. En caso de que la respuesta sea una variable aleatoria, se considerará la predicción típica a largo plazo, es decir, su media geométrica. Notar que asignar cero a una posible respuesta correcta hace que el producto sea cero. Por ello, en caso de duda, no conviene que concentren toda su creencia en una sola opción, sino distribuir algo de creencia en todas las opciones que consideran posibles. Noten también que conviene asignar más a la opción en la que más creen, porque distribuir creencias en partes iguales entre todas las opciones no es mucho mejor que el azar (baseline).

1. Flujo

La alarma (a) de una casa se activa cuando alguien entra (e) sin apagarla. Si la alarma se activa, la dueña recibe una llamada (l) de la central de seguridad. La alarma se puede activar por otros motivos, como los terremotos (t) que no son infrecuentes en la ciudad. Siempre que se produce un terremoto, en las redes (r) se habla casi exclusivamente de eso. El producto de los mecanismos causales probabilísticos definen la distribución conjunta, $P(\text{letra}) = P(e)P(t)P(a|t, e)P(r|t)P(l|a)$. ¿Está cerrado el flujo de inferencia entre de la entradera (e) y el terremoto (t) dado la llamada (l)? ¿Más precisamente, $P(e, t|l) = P(e|l)P(t|l)$?

1. No

2. Sí

Justifique en profundidad.

2. Backdoor

Una empresa ofrece créditos a sus clientes con el objetivo de aumentar las ventas. Los créditos tienen dos características: el monto disponible a usar como crédito (**monto_credito**) y los días de plazo que tienen para cancelar el crédito (**plazo**). La empresa quiere conocer el efecto causal que el **monto_credito** tiene sobre el volumen de ventas del mes (**ventas**). El problema es que no hay disponible ningún experimento aleatorizado ni conocemos la estructura causal subyacente completa. Solo sabemos lo siguiente.

El **monto_credito** lo asigna un modelo de caja negra en función del promedio de compras del año pasado (**compras_pasadas**), un nivel de riesgo creado por una empresa externa (**nivel_riesgo**) y la cantidad de días otorgados para hacer el pago del crédito (**plazo**), el cuál está calculado en función del nivel de riesgo y otras variables que desconocemos. Además conocemos algunas variables relevantes de los clientes como son su sector comercial (**sector**) y los años que lleva como cliente de la empresa (**antigüedad**). Todas estas variables, relativas a un único mes del año, están en un archivo csv, donde cada fila representa un cliente distinto.

¿Es posible estimar el efecto causal que el **monto_credito** tuvo sobre las **ventas** en ese mes? Explique por qué. En caso de asignar creencia mayor a 0 a la respuesta “Sí” indique además cuáles serían las variables de control.

1. No
2. Sí

Justifique en profundidad.

3. do-operator

En la empresa nos pidieron un análisis de efectos causales. Estuvimos trabajando arduamente y tenemos bastante certeza que el efecto causal de interés es $P(y|do(x)) \approx 0$. Cuando entregamos estos resultados el cliente nos afirma que hay un error, que es imposible porque ellos saben que la variable x afecta muy fuertemente a todas las personas sin excepción. ¿Si la afirmación del cliente fuera cierta implica que en nuestro análisis cometimos un error? ¿Por qué? ¿Qué pasos a seguir le propondría al cliente?

1. No
2. Sí

Justifique en profundidad.

4. Ignorability

Nos piden participar como jurado de una tesis de licenciatura en ciencia de datos sobre inferencia causal. El objetivo de la tesis es analizar el desempeño de distintos algoritmos de aprendizaje automático para la estimación de efectos causales heterogéneos. La tesis tiene varios errores de redacción. En la introducción de la tesis además encuentran, en contra de toda la literatura de referencia, la afirmación de que el criterio para determinar variables de control del enfoque de potential outcomes (el criterio de ignorabilidad condicional) no implica el cumplimiento del criterio backdoor de forma general en cualquier modelo causal generativo. ¿Este es un error grave de la tesis? Resuelva la contradicción entre la afirmación que se realiza en la introducción y toda la literatura de referencia explicando en profundidad por qué hay un error o por qué no lo hay.

1. No
2. Sí

Justifique en profundidad.

5. Decisiones

Una decisión factual es óptima si ninguna de las decisiones contrafactuales alternativas hubieran mejorado el resultado de la variable objetivo. Ya hemos especificado distribuciones conjuntas entre factuales y contrafactual mediante modelos causales conocidos como Twin Networks. En la figura 1 modelamos el juego, varias veces discutido, en el que una casa de apuestas paga $Q_c = 3$ por Caras y $Q_s = 1,2$ por Sellos, donde la riqueza en un tiempo ω_t depende de la decisión b (proporción que se apuesta a Cara) y del resultado de la moneda m_t .

$$\omega_t = \begin{cases} \omega_{t-1} \cdot b \cdot Q_c & m_t = 1 \\ \omega_{t-1} \cdot (1 - b) \cdot Q_s & m_t = 0 \end{cases} \quad (1)$$

Arrancamos con una riqueza inicial (factual) de $\omega_0 = 1$. Queremos tomar una decisión factual b . Para ello modelamos una secuencia infinita de pasos temporales contrafactuales, en el que cada una de las riquezas contrafactuales ω'_t depende de la decisión contrafactual b' global y del valor factual (pero oculto) de la moneda en cada uno de los pasos temporales, m_t .

Nuestra decisión factual b es óptima ($\mathcal{O}$) si es igual a la decisión contrafactual que maximiza la riqueza contrafactual a largo plazo ω'_T (o una transformación determinista de ella, como es $r'_T = (\omega'_T)^{1/T}$). Todas las variables contrafactuales están notadas con el subíndice prima, y son resultados potenciales, funciones que tienen a la decisión contrafactual como parámetro: $\omega'_t(b')$, $r'_T(b')$. Luego,

$$P(\mathcal{O}|b, r'_T(b')) = \mathbb{I} \left(\mathcal{O} = (b = \arg \max_{b'} r'_T(b')) \right) \quad (2)$$

Para inferir la decisión factual óptima analizamos el caso en el que la variable de optimalidad es verdadera, $\mathcal{O} = 1$. Por el momento, podemos evitar modelar las riquezas factuales, que van a ocurrir luego de que tomemos la decisión factual (a modo de referencia dibujamos el primer paso factual en gris claro). Notar que, a diferencia de la Twin Networks, la variable de optimalidad no es ni puramente factual ni puramente contrafactual, sino una combinación de ambas que abre el flujo de inferencia de un lado al otro.




Figura 1: Toma de decisiones como inferencia basada en contrafactuales

Sabemos que el mensaje que envía el factor hacia la variable r'_T es.

$$\begin{aligned} m_{f_{r'_T} \rightarrow r'_T}(r'_T) &\propto \mathbb{I}\left(r'_T = (\omega'_T)^{1/T}\right) \mathbb{I}\left(\omega'_T = (b' \cdot Q_c)^{n_c} ((1 - b') \cdot Q_s)^{n_s}\right) \\ &= \mathbb{I}\left(r'_T = (b' \cdot Q_c)^p ((1 - b') \cdot Q_s)^{(1-p)}\right) \end{aligned} \quad (3)$$

¿El posterior de la variable factual b garantiza la maximización de las ganancias factuales a largo plazo bajo en este juego de apuestas? Explique por qué, indicando cuál es el mensaje que envía el factor de la variable optimalidad a la decisión factual b .

1. No
2. Sí

Justifique en profundidad.